Vorabfragen

- Wann würden Sie eher ein klassisches Programm (mit festen Regeln) verwenden – und wann Machine Learning? Woran würden Sie diese Entscheidung festmachen?
- Ein Spamfilter lernt aus Beispielen: Welche Arten von Daten und Merkmalen (Features) könnten dabei Ihrer Meinung nach hilfreich sein?
- Was könnte schiefgehen, wenn ein Machine-Learning-Modell mit schlechten oder nicht repräsentativen Daten trainiert wird?
- Stellen Sie sich vor, ein Modell hat auf den Trainingsdaten perfekte Ergebnisse. Bedeutet das automatisch, dass es auch in der Praxis gut funktioniert? Warum (nicht)?

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln



Mensch-zentrierte Künstliche Intelligenz – WS 26/27

Gelesen von Prof. Dr. Daniel Gaida und Prof. Dr. Elisabeth Kaliva

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
-
-
-
-
  -
-

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
- Training von Machine Learning Modellen mit und ohne Überwachung

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
- Training von Machine Learning Modellen mit und ohne Überwachung

- Grundlegende Visualisierungsmöglichkeiten von Daten

- Wie gut ist das trainierte Machine Learning Modell?

-
  -

-

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
- Training von Machine Learning Modellen mit und ohne Überwachung

- Grundlegende Visualisierungsmöglichkeiten von Daten

- Wie gut ist das trainierte Machine Learning Modell?

- Machine Learning und Deep Learning Algorithmen
  - Logistische Regression, Entscheidungsbäume, neuronale Netze

- Wie funktioniert ChatGPT & Co.?

Lernziele von heute und Fragen zur Überprüfung der Lernziele

Was:

Die Studierenden beurteilen eigenständig, ob und wie maschinelles Lernen für eine gegebene Problemstellung sinnvoll eingesetzt werden kann.

Lernziele von heute und Fragen zur Überprüfung der Lernziele

Was:
Die Studierenden beurteilen eigenständig, ob und wie maschinelles Lernen für eine gegebene Problemstellung sinnvoll eingesetzt werden kann.

Womit:
Dies erreichen sie durch die Auseinandersetzung mit Beispielen aus der Praxis, durch die Analyse und das Training zentraler ML-Algorithmen sowie durch den Vergleich traditioneller Programmierung und maschinellen Lernens.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Lernziele von heute und Fragen zur Überprüfung der Lernziele

Was:
Die Studierenden beurteilen eigenständig, ob und wie maschinelles Lernen für eine gegebene Problemstellung sinnvoll eingesetzt werden kann.

Womit:
Dies erreichen sie durch die Auseinandersetzung mit Beispielen aus der Praxis, durch die Analyse und das Training zentraler ML-Algorithmen sowie durch den Vergleich traditioneller Programmierung und maschinellen Lernens.

Wozu:
Dadurch sind sie in der Lage, in Teams die Entwicklung von ML-Modellen mitzugestalten und die Stärken und Grenzen verschiedener ML-Algorithmen im Kontext menschzentrierter KI abzuwägen.

Lernziele von heute und Fragen zur Überprüfung der Lernziele

Was:
Die Studierenden beurteilen eigenständig, ob und wie maschinelles Lernen für eine gegebene Problemstellung sinnvoll eingesetzt werden kann.

Womit:
Dies erreichen sie durch die Auseinandersetzung mit Beispielen aus der Praxis, durch die Analyse und das Training zentraler ML-Algorithmen sowie durch den Vergleich traditioneller Programmierung und maschinellen Lernens.

Wozu:
Dadurch sind sie in der Lage, in Teams die Entwicklung von ML-Modellen mitzugestalten und die Stärken und Grenzen verschiedener ML-Algorithmen im Kontext menschzentrierter KI abzuwägen.

s. Übungsaufgaben von heute

Was ist Maschinelles Lernen?

- Ein Spamfilter ist ein maschinelles Lernprogramm, das aus Beispielen für Spam-E-Mails (z.B. vom Nutzer gelabelten) und gewöhnlichen E-Mails (Nicht-Spam) lernt, Spam zu erkennen.
-

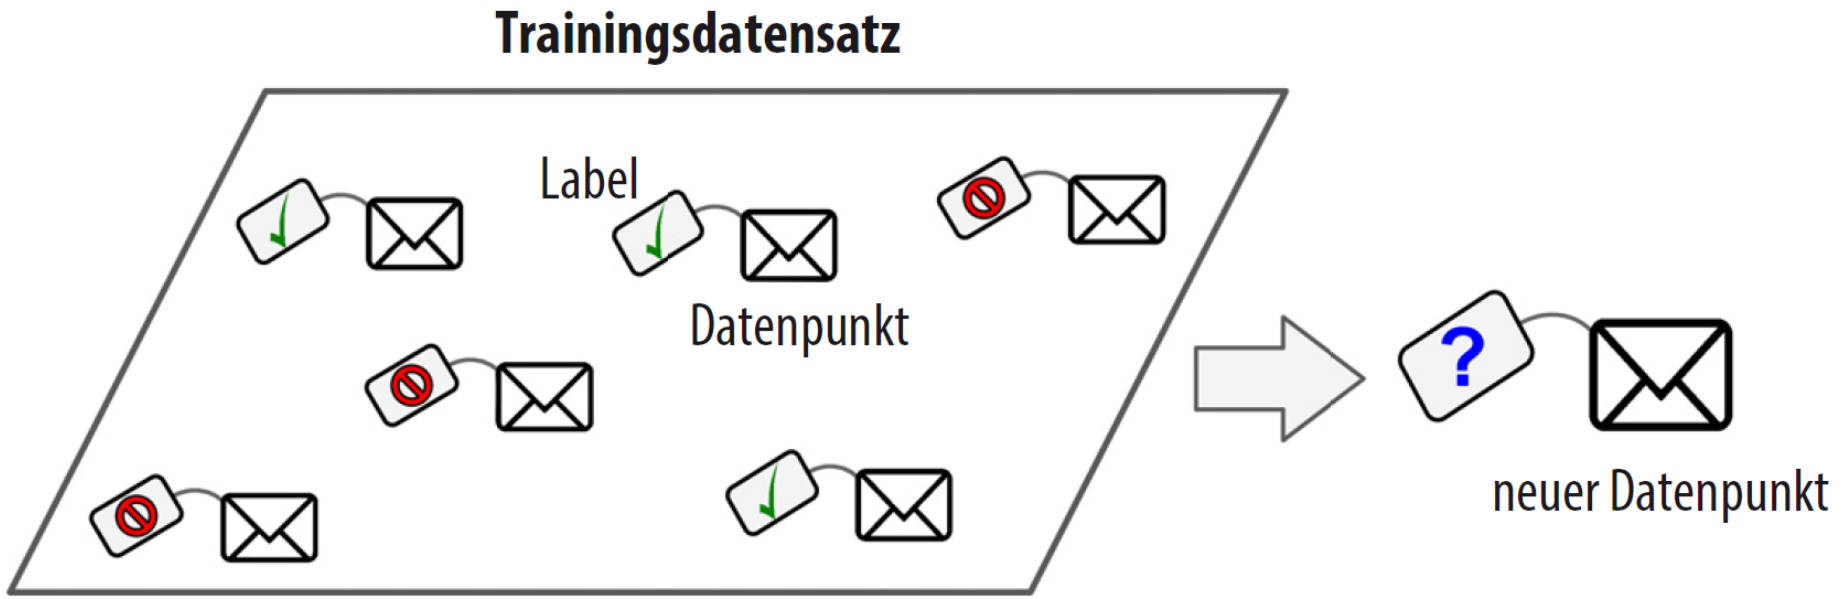


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Was ist Maschinelles Lernen?

- Ein Spamfilter ist ein maschinelles Lernprogramm, das aus Beispielen für Spam-E-Mails (z.B. vom Nutzer gelabelten) und gewöhnlichen E-Mails (Nicht-Spam) lernt, Spam zu erkennen.
- Maschinelles Lernen lernt diese Aufgabe aus dem Trainingsdatensatz, in dem es Muster/Zusammenhänge erkennt und wendet das erlernte Wissen auf neue E-Mails an, um Spam zu erkennen.

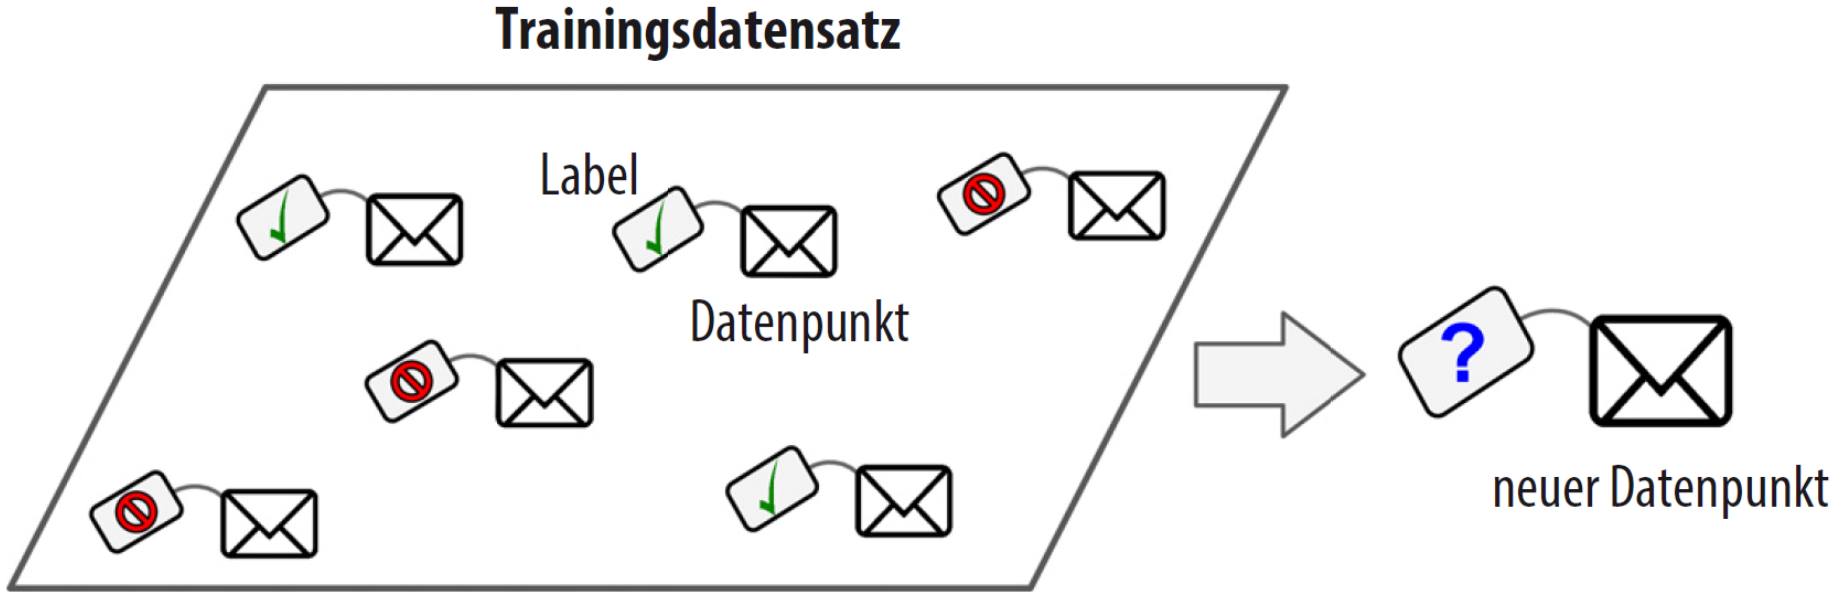
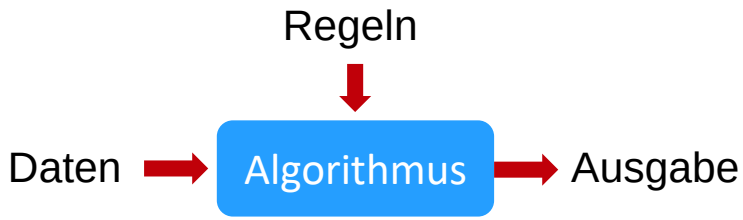


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Warum wird Maschinelles Lernen verwendet?

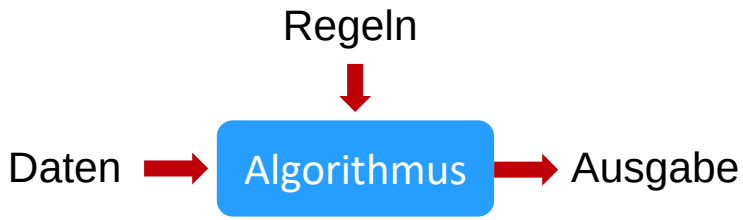
Traditionelles Programmieren vs. Maschinelles Lernen



Traditionelle Programmierung

Warum wird Maschinelles Lernen verwendet?

Traditionelles Programmieren vs. Maschinelles Lernen

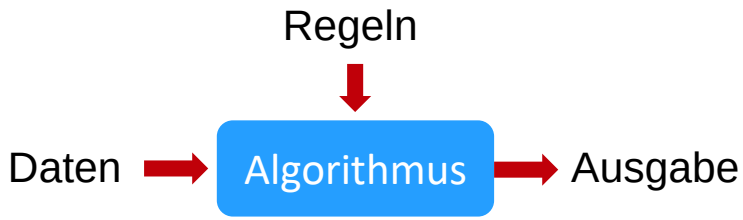


Traditionelle Programmierung

- Alle Regeln werden explizit programmiert
- Jede Regel basiert auf einer logischen Grundlage
- Der Algorithmus gibt eine Ausgabe aus, die der logischen Anweisung folgt
- Komplexe Systeme benötigen viele Regeln

Warum wird Maschinelles Lernen verwendet?

Traditionelles Programmieren vs. Maschinelles Lernen



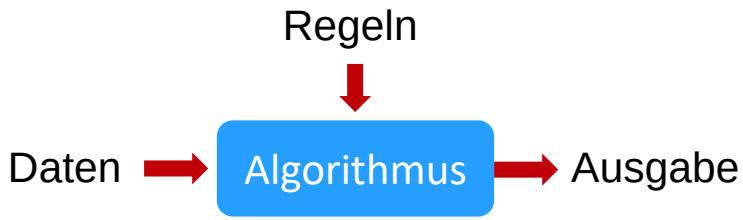
Traditionelle Programmierung

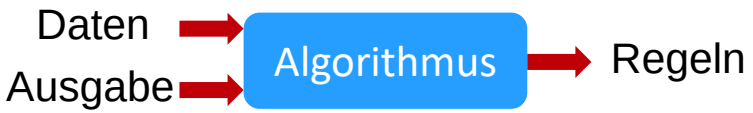
- Alle Regeln werden explizit programmiert
- Jede Regel basiert auf einer logischen Grundlage
- Der Algorithmus gibt eine Ausgabe aus, die der logischen Anweisung folgt
- Komplexe Systeme benötigen viele Regeln

→ **Instandhaltung kann schnell untragbar werden**

Warum wird Maschinelles Lernen verwendet?

Traditionelles Programmieren vs. Maschinelles Lernen





Traditionelle Programmierung

- Alle Regeln werden explizit programmiert
- Jede Regel basiert auf einer logischen Grundlage
- Der Algorithmus gibt eine Ausgabe aus, die der logischen Anweisung folgt
- Komplexe Systeme benötigen viele Regeln

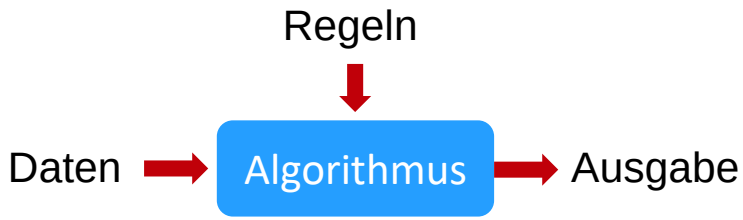
→ **Instandhaltung kann schnell untragbar werden**

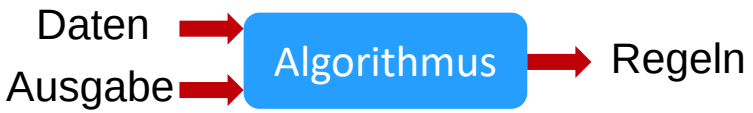
Maschinelles Lernen

- Soll dieses Problem überwinden

Warum wird Maschinelles Lernen verwendet?

Traditionelles Programmieren vs. Maschinelles Lernen





Traditionelle Programmierung

- Alle Regeln werden explizit programmiert
- Jede Regel basiert auf einer logischen Grundlage
- Der Algorithmus gibt eine Ausgabe aus, die der logischen Anweisung folgt
- Komplexe Systeme benötigen viele Regeln

→ **Instandhaltung kann schnell untragbar werden**

Maschinelles Lernen

- Soll dieses Problem überwinden
- Regeln werden basierend auf der Korrelation zwischen Daten und Ausgabe erlernt
- Regeln müssen nicht explizit geschrieben werden
- Wenn sich Daten ändern, können Regeln aktualisiert werden

Wie funktioniert Maschinelles Lernen?

Ziel des Maschinellen Lernens: **Trainieren** und **Schlussfolgern**



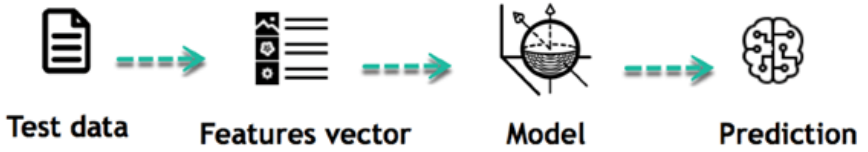
Trainingsphase

- Entdecken von Mustern/Korrelationen in Daten
  Daten sind von entscheidender Bedeutung
- Extrahieren von Merkmalen (**Feature-Vektor**)
- Überführen der Entdeckungen in ein Modell

Wie funktioniert Maschinelles Lernen?

Ziel des Maschinellen Lernens: **Trainieren** und **Schlussfolgern**





Trainingsphase

- Entdecken von Mustern/Korrelationen in Daten
  Daten sind von entscheidender Bedeutung
- Extrahieren von Merkmalen (**Feature-Vektor**)
- Überführen der Entdeckungen in ein Modell

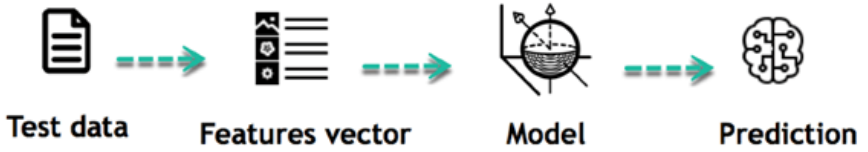
Schlussfolgerung

- Testen der Performance auf neue und ungesehene Daten
- Extrahieren der Merkmale
- Modell liefert eine Vorhersage

Wie funktioniert Maschinelles Lernen?

Einfaches Beispiel: Spamfilter





Lernphase

- Daten: E-Mails
- Features: Anzahl Rechtschreibfehler, Anzahl Begriffe wie Erbe, König, …, E-Mailadresse des Absenders, …
- Algorithmus findet Muster zwischen Daten und Label
- Überführen der Entdeckungen in ein Modell

Schlussfolgerung

- Testen der Performance auf neue und ungesehene Daten
- Extrahieren der Merkmale
- Modell liefert eine Vorhersage

Limitationen von Maschinelles Lernen

Welche Einschränkungen und Herausforderungen sehen Sie?

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Limitationen von Maschinelles Lernen

Welche Einschränkungen und Herausforderungen sehen Sie?

- Fehlerrate des Modells ist niemals kleiner als Fehlerrate der Daten-Labeler
  - Sind die Personen, die die E-Mails labeln, nicht in der Lage Spam-E-Mails zu erkennen, wird es das Modell auch nicht können
-
  -
  -
  -
-
  -
  -

Limitationen von Maschinelles Lernen

Welche Einschränkungen und Herausforderungen sehen Sie?

- Fehlerrate des Modells ist niemals kleiner als Fehlerrate der Daten-Labeler
  - Sind die Personen, die die E-Mails labeln, nicht in der Lage Spam-E-Mails zu erkennen, wird es das Modell auch nicht können
- Daten müssen repräsentativ sein
  - Bspw. verschiedene Sprachen, wenn Modell multilingual sein soll
  - Unterschiedliche Arten von Spam-E-Mails (Werbung, Phishing)
  - Spam-E-Mails verändern sich über die Jahre
-
  -
  -

Limitationen von Maschinelles Lernen

Welche Einschränkungen und Herausforderungen sehen Sie?

- Fehlerrate des Modells ist niemals kleiner als Fehlerrate der Daten-Labeler
  - Sind die Personen, die die E-Mails labeln, nicht in der Lage Spam-E-Mails zu erkennen, wird es das Modell auch nicht können
- Daten müssen repräsentativ sein
  - Bspw. verschiedene Sprachen, wenn Modell multilingual sein soll
  - Unterschiedliche Arten von Spam-E-Mails (Werbung, Phishing)
  - Spam-E-Mails verändern sich über die Jahre

- Wenn Machine Learning Modelle bei wirklich wichtigen Dingen eingesetzt werden (Medizin/Kriminalität/Job/…), müssen
  -
  -

Limitationen von Maschinelles Lernen

Welche Einschränkungen und Herausforderungen sehen Sie?

- Fehlerrate des Modells ist niemals kleiner als Fehlerrate der Daten-Labeler
  - Sind die Personen, die die E-Mails labeln, nicht in der Lage Spam-E-Mails zu erkennen, wird es das Modell auch nicht können
- Daten müssen repräsentativ sein
  - Bspw. verschiedene Sprachen, wenn Modell multilingual sein soll
  - Unterschiedliche Arten von Spam-E-Mails (Werbung, Phishing)
  - Spam-E-Mails verändern sich über die Jahre

- Wenn Machine Learning Modelle bei wirklich wichtigen Dingen eingesetzt werden (Medizin/Kriminalität/Job/…), müssen
  - die erlernten Regeln/Modelle für Menschen/Experten verständlich sein
  - und auch vor Gericht bestehen können

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Ein mensch-zentrierter Spam-Filter

Wie können wir den Spam-Filter mensch-zentrierter gestalten?

Ein mensch-zentrierter Spam-Filter

Wie können wir den Spam-Filter mensch-zentrierter gestalten?

- Kontrolle & Feedback-Mechanismen
  -
-
  -
  -

Ein mensch-zentrierter Spam-Filter

Wie können wir den Spam-Filter mensch-zentrierter gestalten?

- Kontrolle & Feedback-Mechanismen
  - Nutzer*innen müssen die Möglichkeit haben zu sagen: Das ist Spam. Das ist kein Spam.
-
  -
  -

Ein mensch-zentrierter Spam-Filter

Wie können wir den Spam-Filter mensch-zentrierter gestalten?

- Kontrolle & Feedback-Mechanismen
  - Nutzer*innen müssen die Möglichkeit haben zu sagen: Das ist Spam. Das ist kein Spam.
- Erklärbarkeit
  -
  -

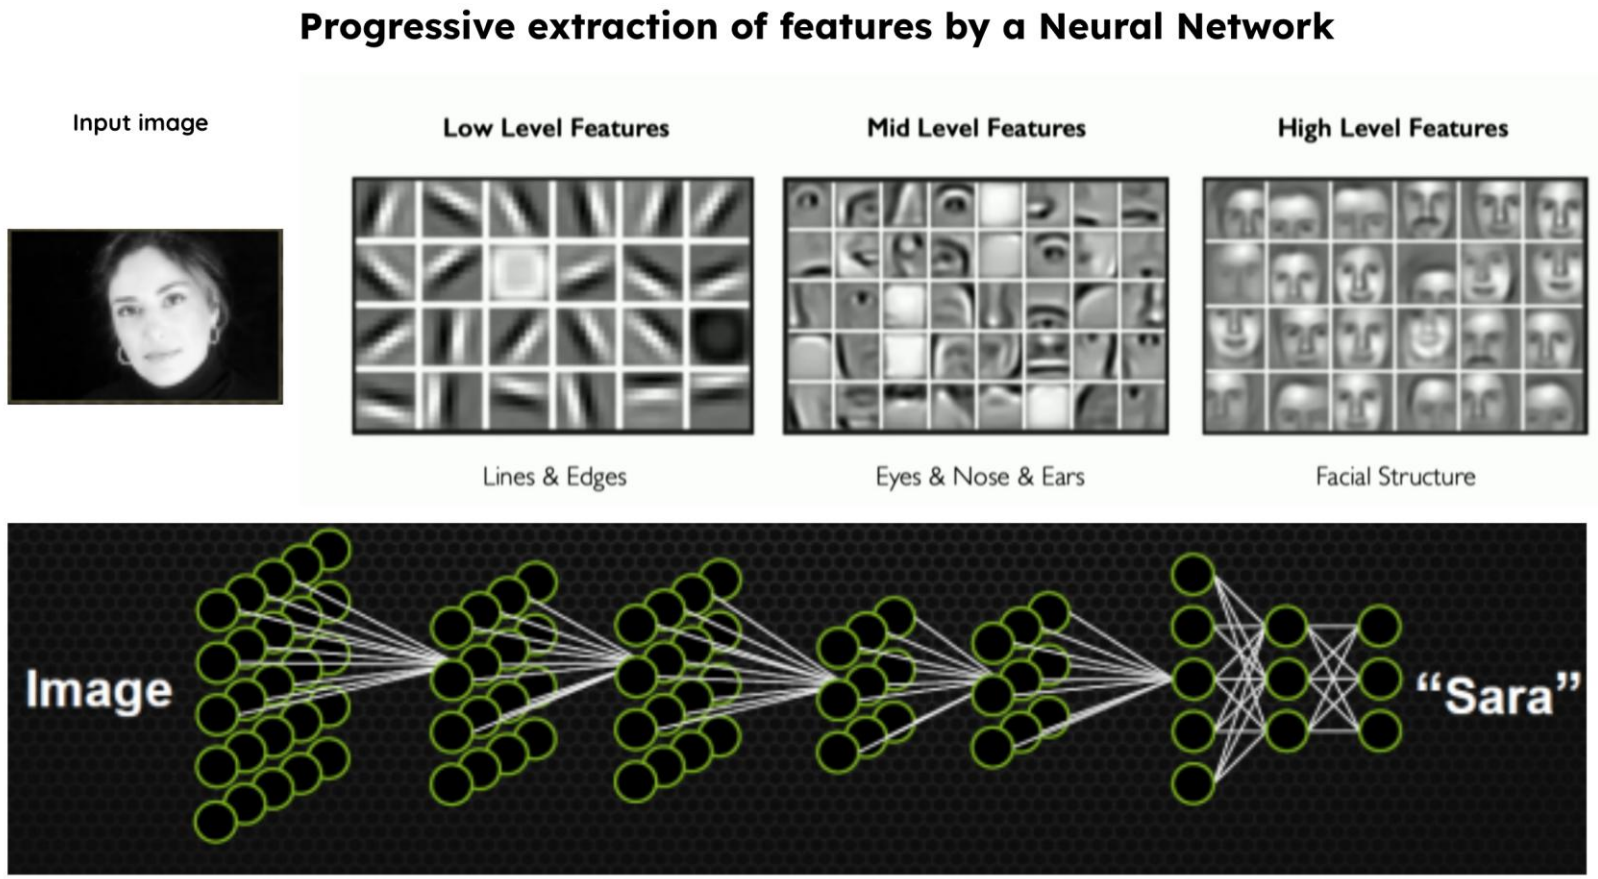
Ein mensch-zentrierter Spam-Filter

Wie können wir den Spam-Filter mensch-zentrierter gestalten?

- Kontrolle & Feedback-Mechanismen
  - Nutzer*innen müssen die Möglichkeit haben zu sagen: Das ist Spam. Das ist kein Spam.
- Erklärbarkeit
  - Warum ist diese E-Mail im Spamordner gelandet?
  - Wenn man selbst eine Mail an einen Freund sendet: Warnung des Spam-Filters, dass diese Mail evtl. in Spam-Ordner des Empfängers landen könnte, weil …

Unterschied zwischen Maschinelles Lernen und Deep Learning

- Deep Learning lernt Features



Bildquelle: https://aiml.com/what-is-deep-learning/

Warum wird Maschinelles Lernen verwendet?

Situationen, in denen Maschinelles Lernen (ML) besser geeignet ist als traditionelle Programme:

-
-
-

Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Warum wird Maschinelles Lernen verwendet?

Situationen, in denen Maschinelles Lernen (ML) besser geeignet ist als traditionelle Programme:

- Probleme, für die bestehende Lösungen lange Listen von Regeln erfordern.
- Komplexe Probleme, für die ein traditioneller Ansatz keine gute Lösung liefert.
-

Warum wird Maschinelles Lernen verwendet?

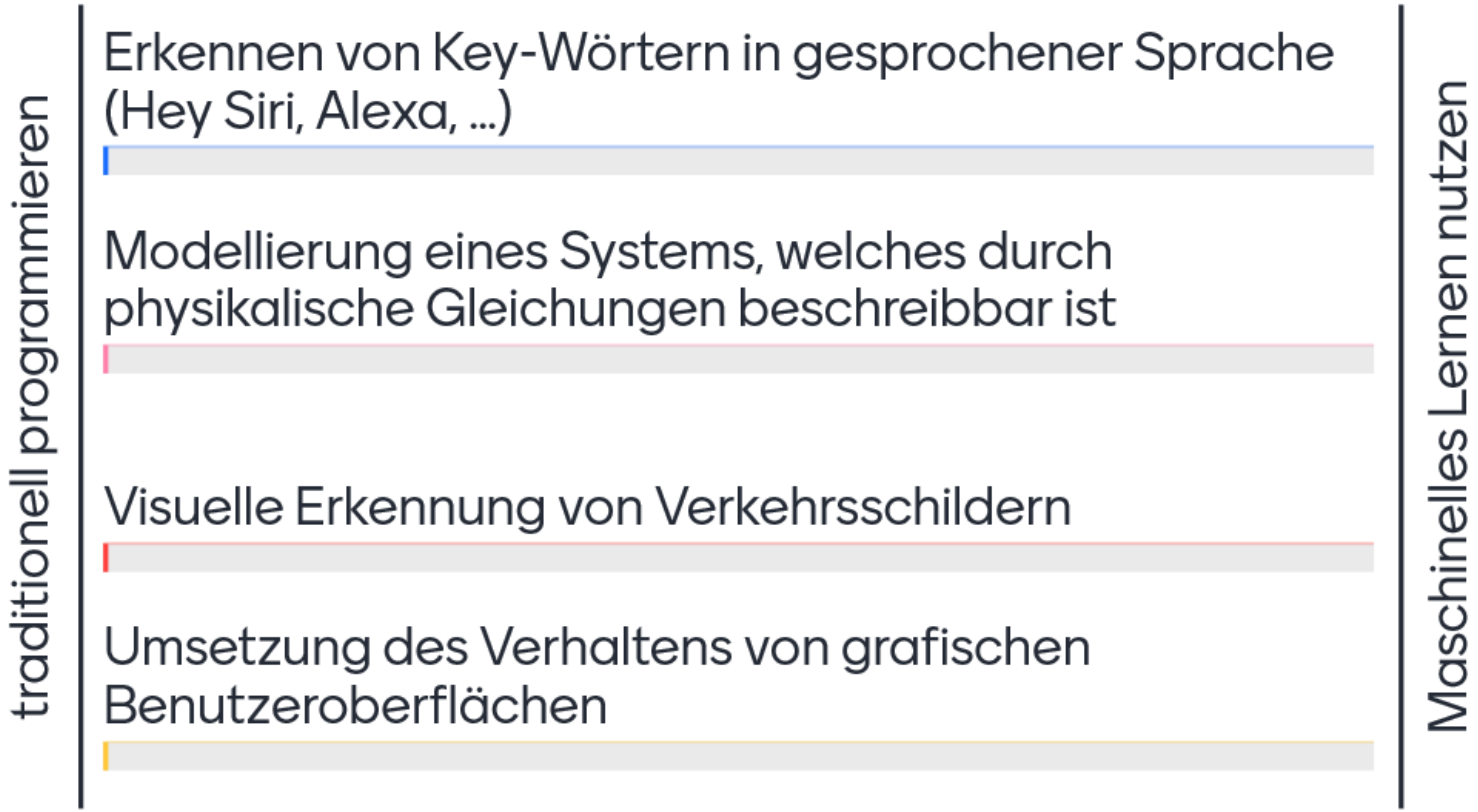
Situationen, in denen Maschinelles Lernen (ML) besser geeignet ist als traditionelle Programme:

- Probleme, für die bestehende Lösungen lange Listen von Regeln erfordern.
- Komplexe Probleme, für die ein traditioneller Ansatz keine gute Lösung liefert.
- Sich ändernde Umgebungen: ein ML-Modell kann sich an neue Daten anpassen.

Warum wird Maschinelles Lernen verwendet?

Quiz – traditionell programmieren oder ML?

Mentimeter Code: 1741 3121



Fragen?

- Machine Learning Modelle werden aus einem Trainingsdatensatz gelernt
- Machine Learning Algorithmen benötigen Merkmale/Features
  - Bei Machine Learning müssen Entwickler die Features selbst entwickeln
  - Deep Learning lernt die Features

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- **Anwendungsbeispiele für Machine Learning und Deep Learning**
- **Training von Machine Learning Modellen mit und ohne Überwachung**

- Grundlegende Visualisierungsmöglichkeiten von Daten

- Wie gut ist das trainierte Machine Learning Modell?

- Machine Learning und Deep Learning Algorithmen
  - Logistische Regression, Entscheidungsbäume, neuronale Netze

- Wie funktioniert ChatGPT & Co.?

Anwendungsbeispiele für Maschinelles Lernen/Deep Learning

- Vorhersage der Stromproduktion und -nachfrage
  - Berücksichtigung der Wettervorhersage (erneuerbare Energie)
  - Berücksichtigung des täglichen Profils der Stromnachfrage
-
  -
-
  -
-
  -
-
  -
-
  -



Quelle: W. Konen, WPF Machine Learning, Deep Learning und KI, WS2019

Anwendungsbeispiele für Maschinelles Lernen/Deep Learning

- Vorhersage der Stromproduktion und -nachfrage
  - Berücksichtigung der Wettervorhersage (erneuerbare Energie)
  - Berücksichtigung des täglichen Profils der Stromnachfrage
- Aufdeckung von Betrug
  - Beispiel: Ermittlung typischer Muster für Kreditkartenbetrug.
-
  -
-
  -
-
  -
-
  -



Quelle: W. Konen, WPF Machine Learning, Deep Learning und KI, WS2019

Anwendungsbeispiele für Maschinelles Lernen/Deep Learning

- Vorhersage der Stromproduktion und -nachfrage
  - Berücksichtigung der Wettervorhersage (erneuerbare Energie)
  - Berücksichtigung des täglichen Profils der Stromnachfrage
- Aufdeckung von Betrug
  - Beispiel: Ermittlung typischer Muster für Kreditkartenbetrug.
- Kreditwürdigkeitsprüfung
  - Ermittlung von Kriterien für die Kreditwürdigkeit von Kunden
-
  -
-
  -
-
  -



Quelle: W. Konen, WPF Machine Learning, Deep Learning und KI, WS2019

Anwendungsbeispiele für Maschinelles Lernen/Deep Learning

- Vorhersage der Stromproduktion und -nachfrage
  - Berücksichtigung der Wettervorhersage (erneuerbare Energie)
  - Berücksichtigung des täglichen Profils der Stromnachfrage
- Aufdeckung von Betrug
  - Beispiel: Ermittlung typischer Muster für Kreditkartenbetrug.
- Kreditwürdigkeitsprüfung
  - Ermittlung von Kriterien für die Kreditwürdigkeit von Kunden
- Vorhersage der Nachfrage
  - Wie viele Einheiten von Produkt X werden wir in Woche 42 verkaufen?
-
  -
-
  -



Quelle: W. Konen, WPF Machine Learning, Deep Learning und KI, WS2019

Anwendungsbeispiele für Maschinelles Lernen/Deep Learning

- Vorhersage der Stromproduktion und -nachfrage
  - Berücksichtigung der Wettervorhersage (erneuerbare Energie)
  - Berücksichtigung des täglichen Profils der Stromnachfrage
- Aufdeckung von Betrug
  - Beispiel: Ermittlung typischer Muster für Kreditkartenbetrug.
- Kreditwürdigkeitsprüfung
  - Ermittlung von Kriterien für die Kreditwürdigkeit von Kunden
- Vorhersage der Nachfrage
  - Wie viele Einheiten von Produkt X werden wir in Woche 42 verkaufen?
- Empfehlungssysteme
  - Spotify, Netflix, …
-
  -

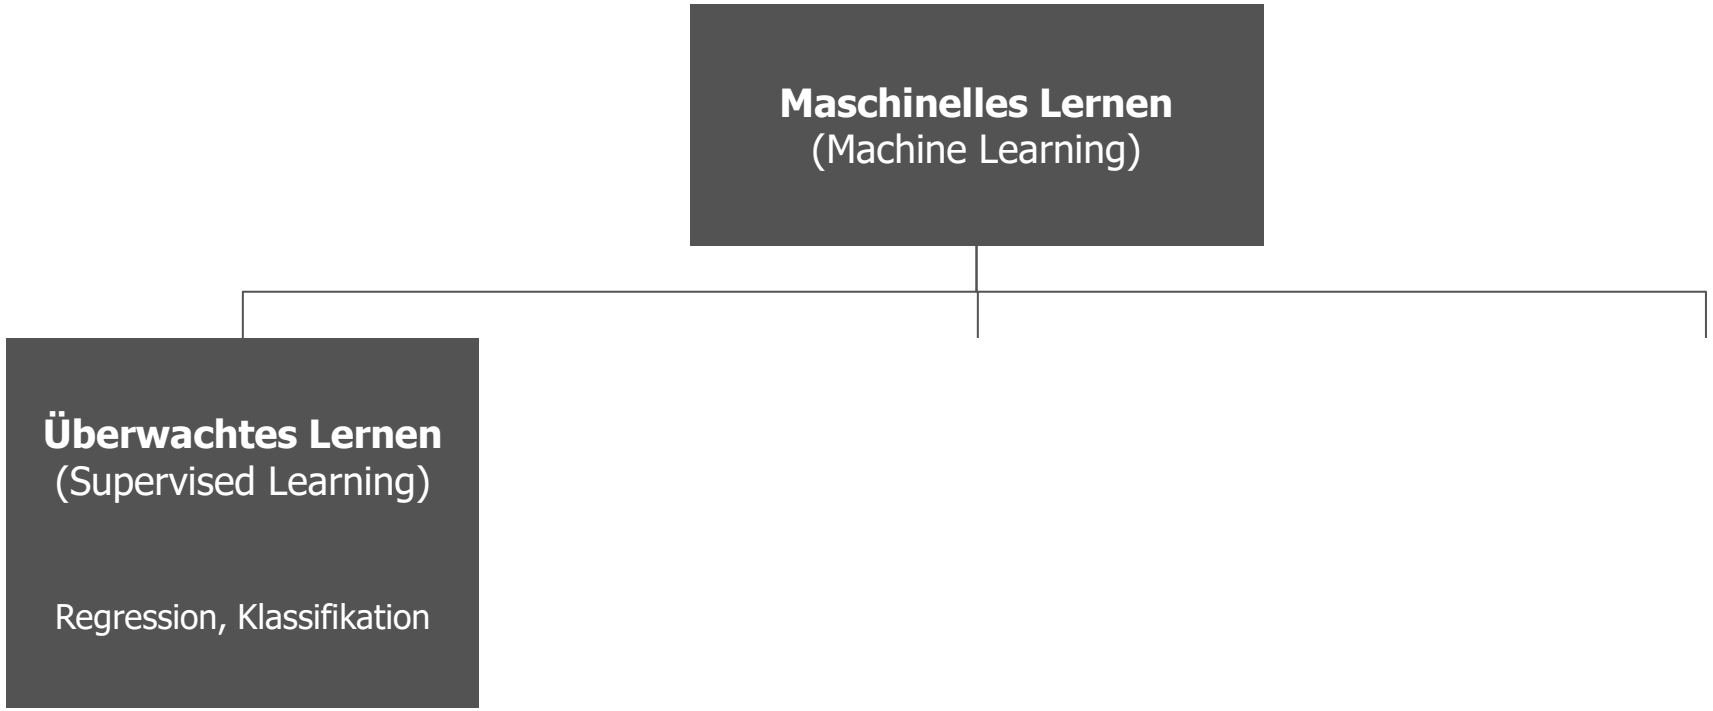


Anwendungsbeispiele für Maschinelles Lernen/Deep Learning

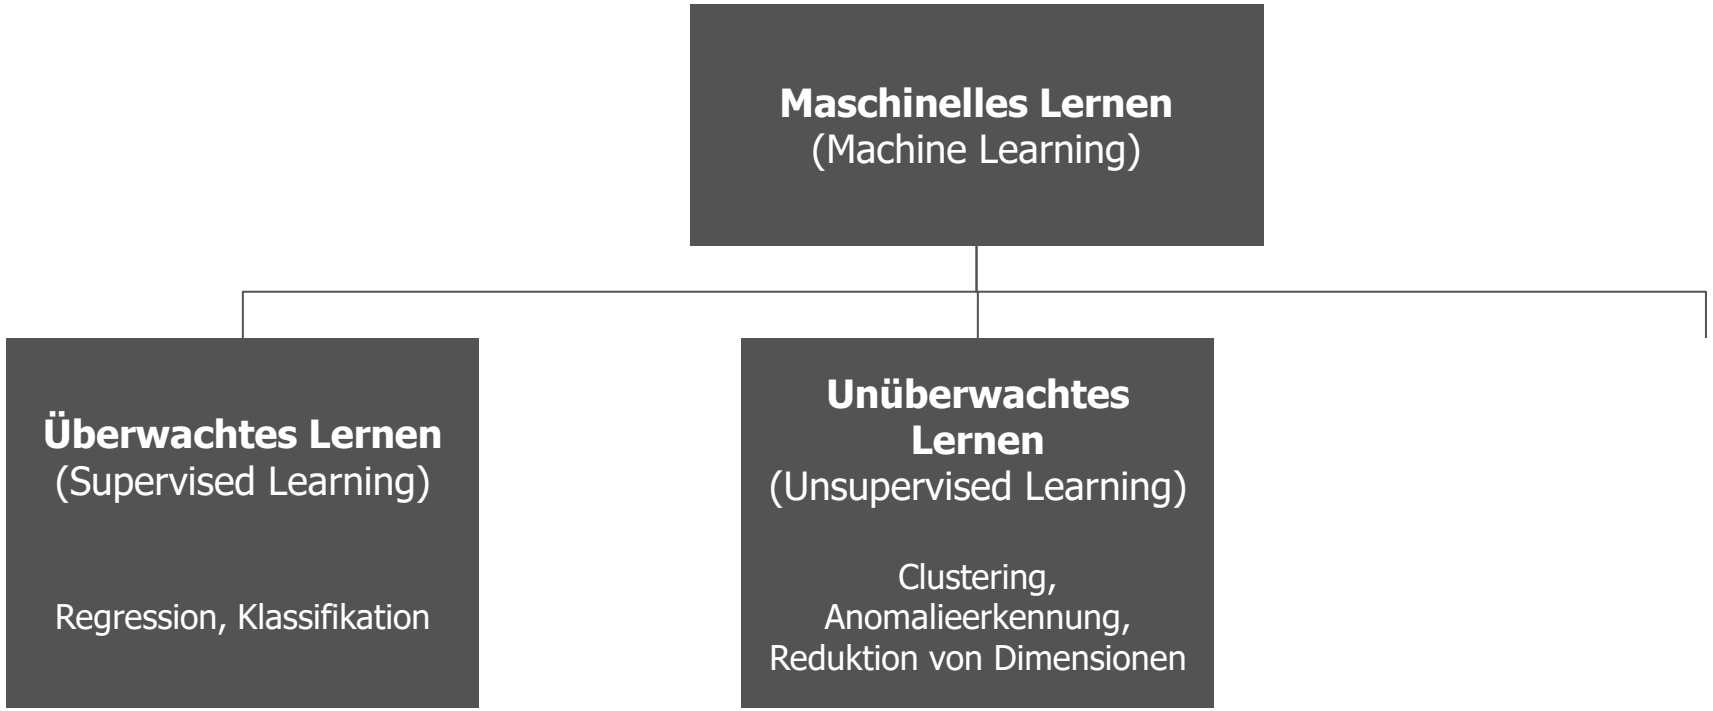
- Vorhersage der Stromproduktion und -nachfrage
  - Berücksichtigung der Wettervorhersage (erneuerbare Energie)
  - Berücksichtigung des täglichen Profils der Stromnachfrage
- Aufdeckung von Betrug
  - Beispiel: Ermittlung typischer Muster für Kreditkartenbetrug.
- Kreditwürdigkeitsprüfung
  - Ermittlung von Kriterien für die Kreditwürdigkeit von Kunden
- Vorhersage der Nachfrage
  - Wie viele Einheiten von Produkt X werden wir in Woche 42 verkaufen?
- Empfehlungssysteme
  - Spotify, Netflix, …
- Verkehrsprognose und Routenoptimierung
  - Google Maps



Training von Machine Learning Modellen mit und ohne Überwachung

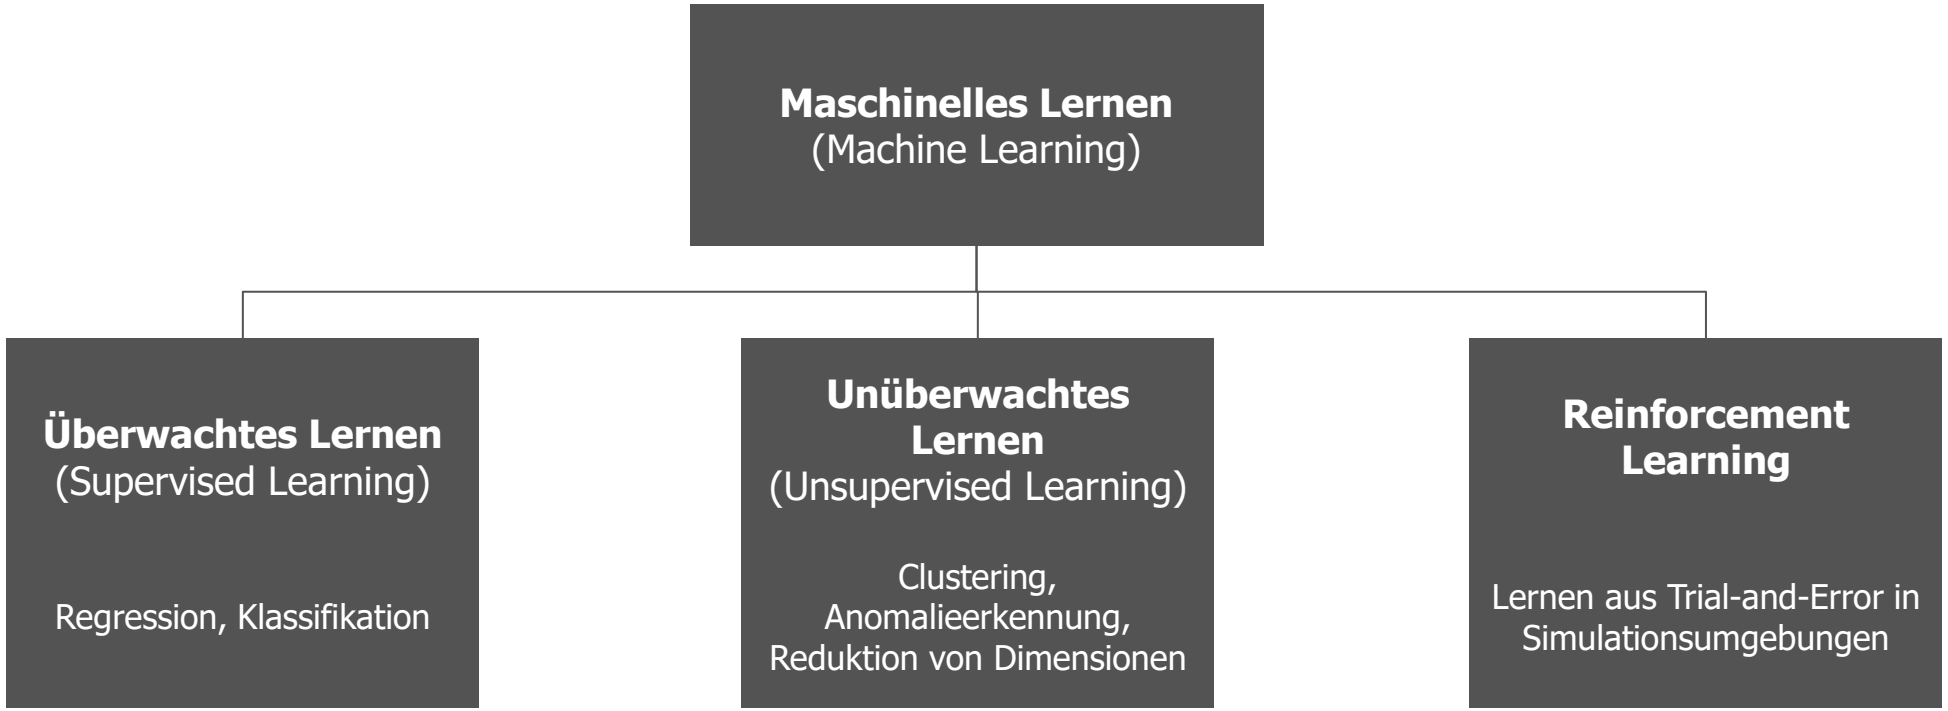


Training von Machine Learning Modellen mit und ohne Überwachung



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Quelle der Folie: Hahn-Schickard

Training von Machine Learning Modellen mit und ohne Überwachung



Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen: Regression vs. Klassifikation

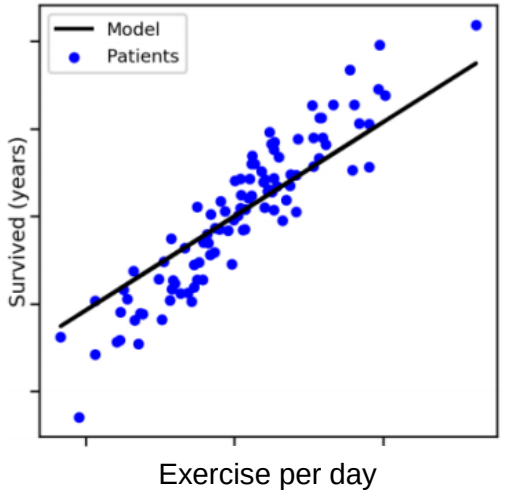
- Trainingsdaten sind gelabelt

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen: Regression vs. Klassifikation

- Trainingsdaten sind gelabelt

	Regression	Klassifikation
Vorhersage	Numerische Werte (geordnet)	Klassen (ungeordnet)
Beispiel	Alters- oder Preisvorhersage	Gesund/krank, Spam/kein Spam

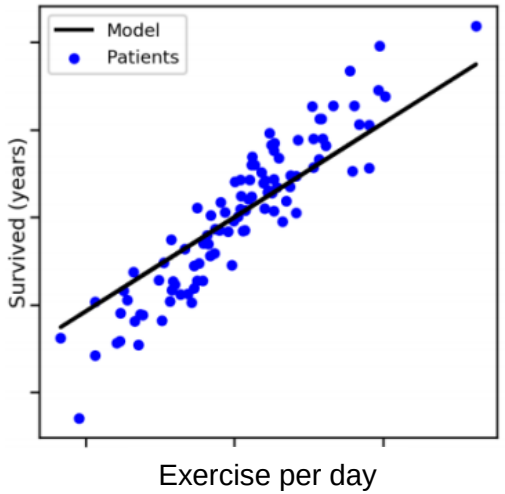


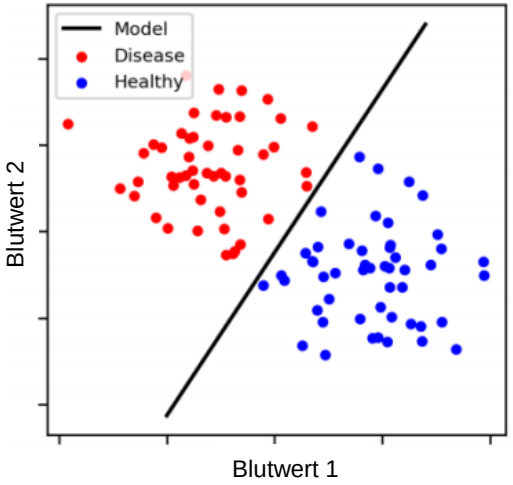
Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen: Regression vs. Klassifikation

- Trainingsdaten sind gelabelt

	Regression	Klassifikation
Vorhersage	Numerische Werte (geordnet)	Klassen (ungeordnet)
Beispiel	Alters- oder Preisvorhersage	Gesund/krank, Spam/kein Spam





Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Quelle der Folie: Hahn-Schickard

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen

- Klassifikation: Beispiel Spamerkennung
-

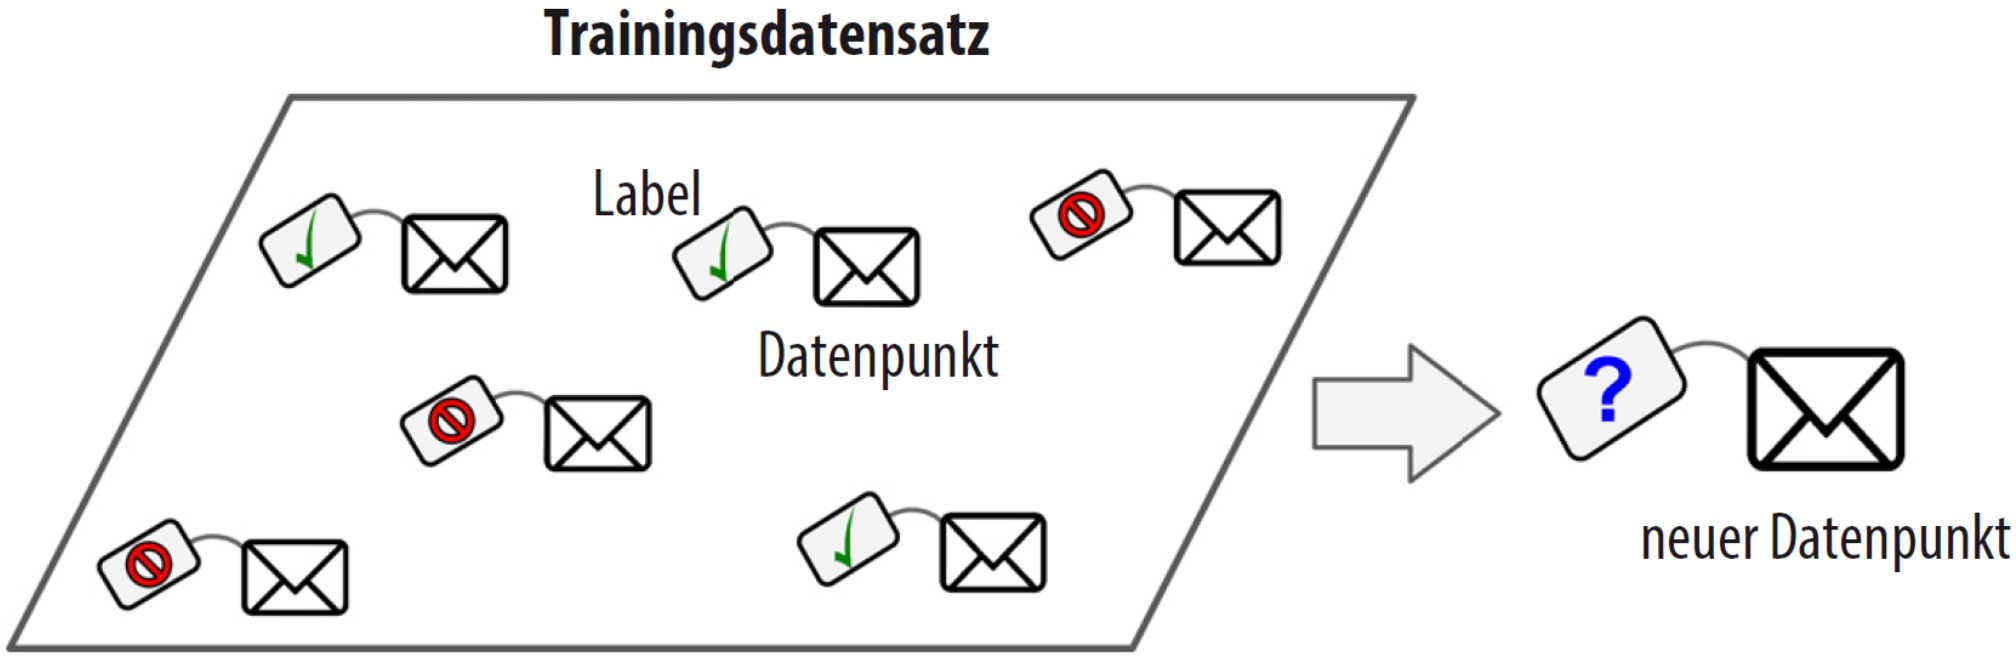


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen

- Klassifikation: Beispiel Spamerkennung
- Weitere Beispiele für Klassifikationsprobleme?

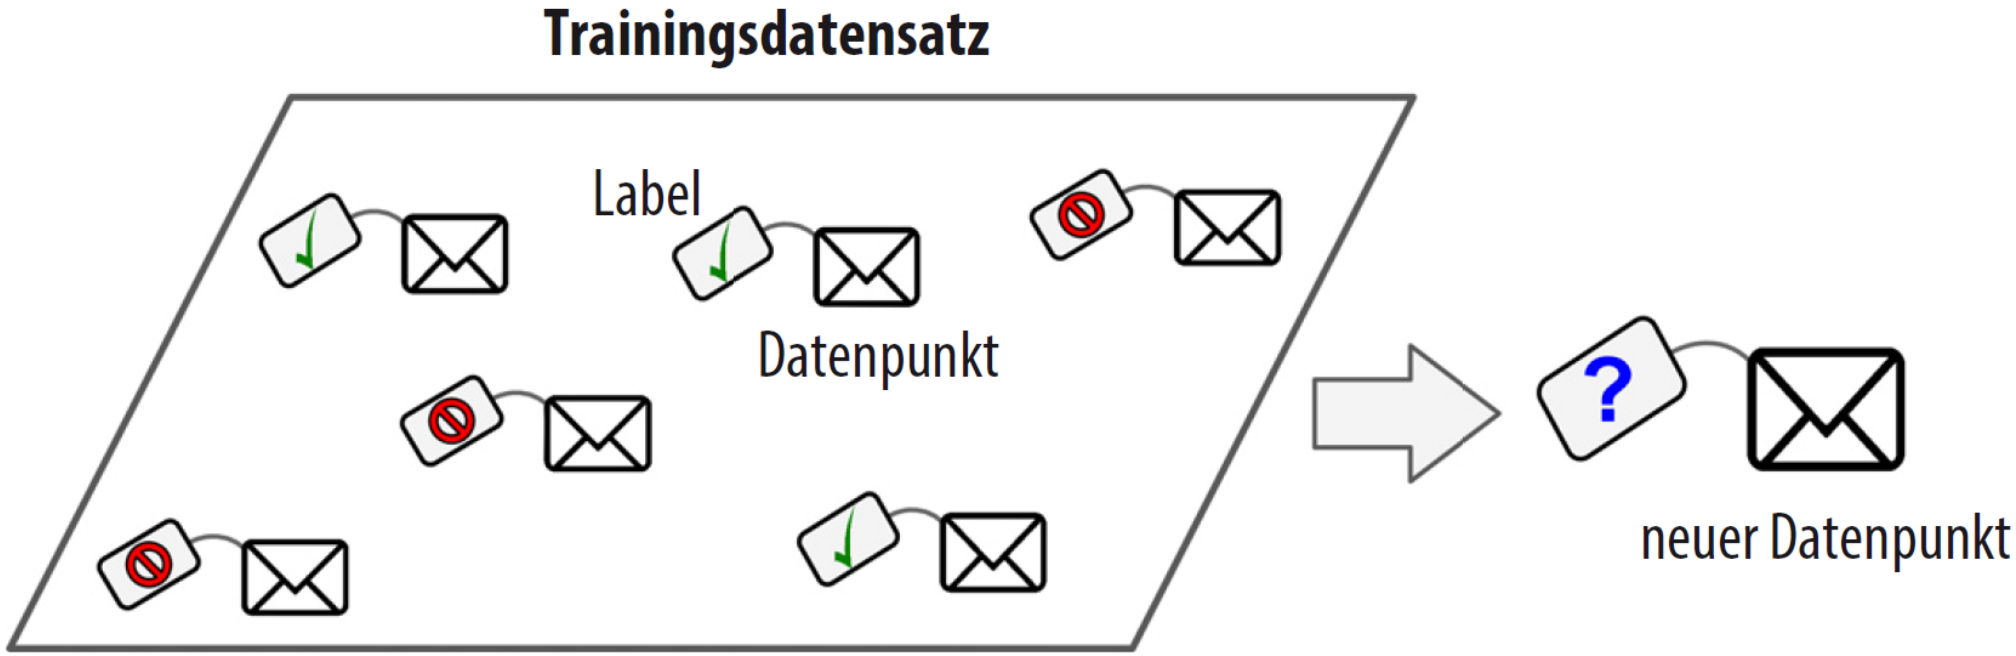


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen

- Regression
  - Vorhersage einer numerischen Zielgröße aus **Merkmalen**
  -
  -
-
  -

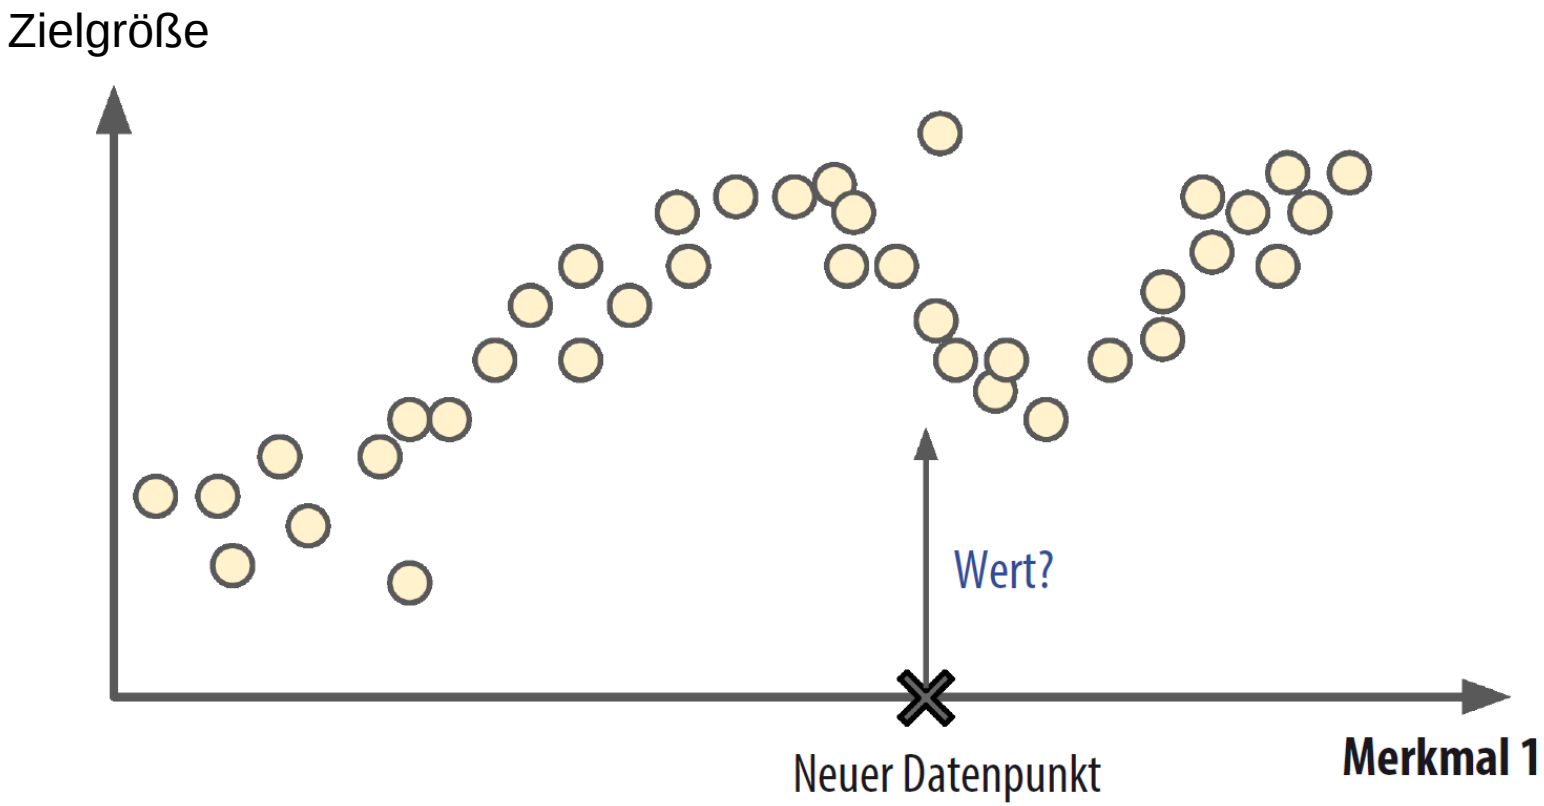


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen

- Regression
  - Vorhersage einer numerischen Zielgröße aus **Merkmalen**
  - Bspw. Preis eines Gebrauchtwagens auf Basis von gefahrene Kilometer, Alter, Marke, …
  -
-
  -

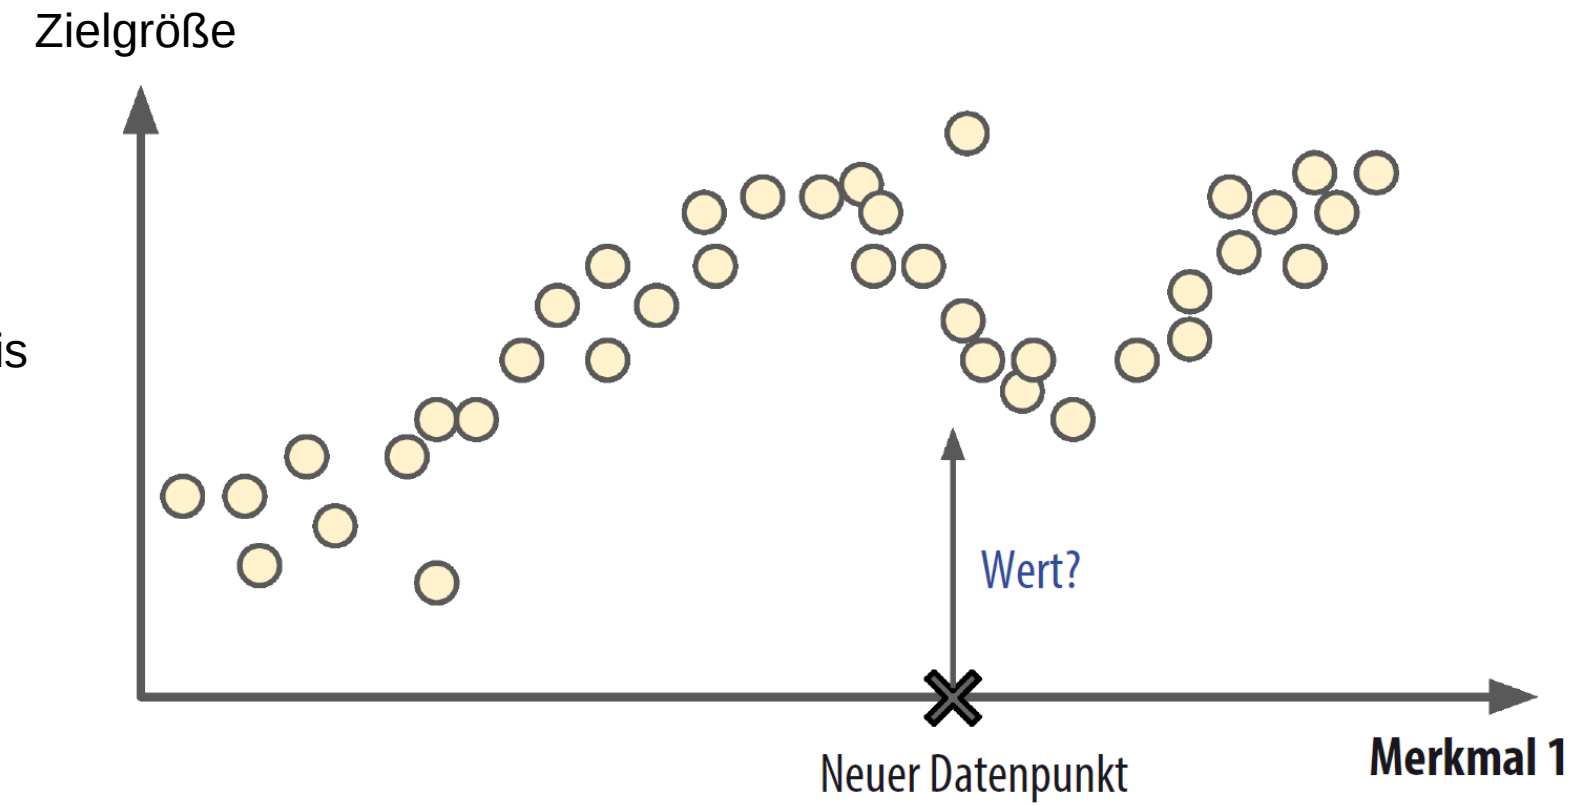


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen

- Regression
  - Vorhersage einer numerischen Zielgröße aus **Merkmalen**
  - Bspw. Preis eines Gebrauchtwagens auf Basis von gefahrene Kilometer, Alter, Marke, …
  - Gefahrene Kilometer, Alter, Marke, … sind **Merkmale (Features)**
-
  -

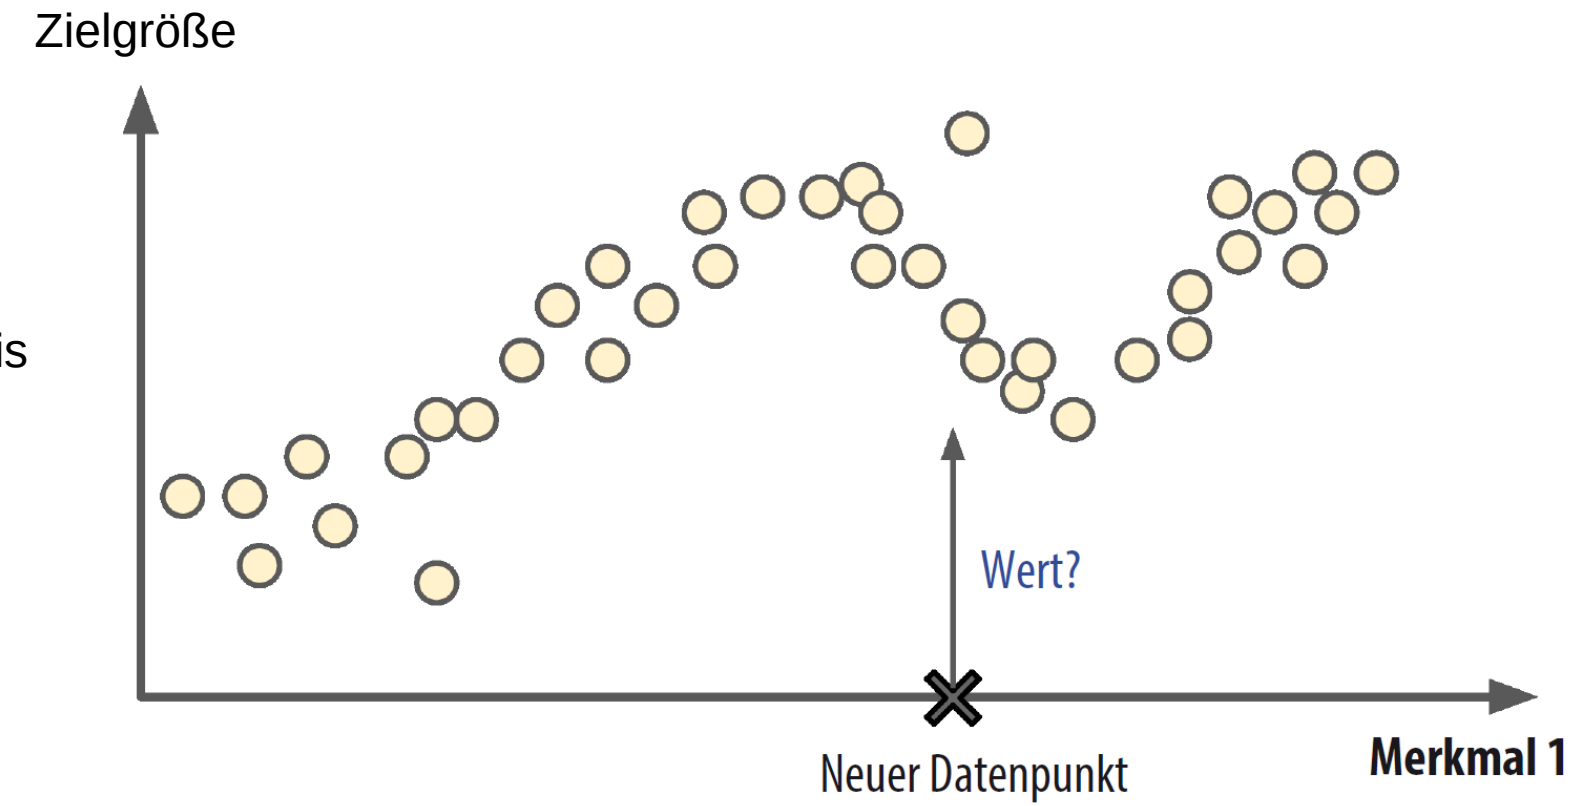


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen

- Regression
  - Vorhersage einer numerischen Zielgröße aus **Merkmalen**
  - Bspw. Preis eines Gebrauchtwagens auf Basis von gefahrene Kilometer, Alter, Marke, …
  - Gefahrene Kilometer, Alter, Marke, … sind **Merkmale (Features)**
- Beispiel:
  - Lineare Regression

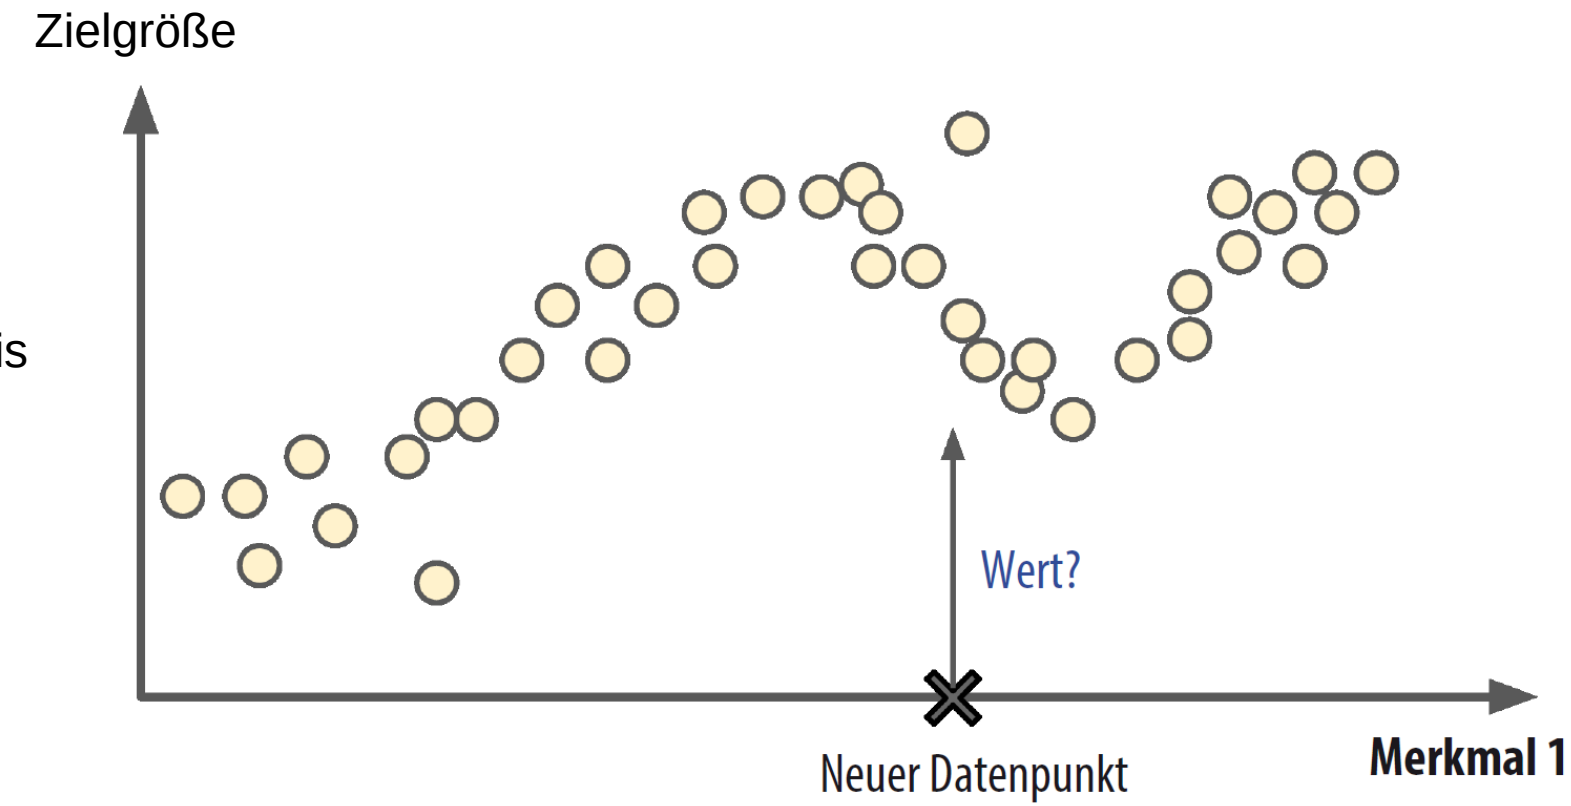


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Überwachtes Lernen

- Regression
  - Vorhersage einer numerischen Zielgröße aus **Merkmalen**
  - Bspw. Preis eines Gebrauchtwagens auf Basis von gefahrene Kilometer, Alter, Marke, …
  - Gefahrene Kilometer, Alter, Marke, … sind **Merkmale (Features)**
- Beispiel:
  - Lineare Regression

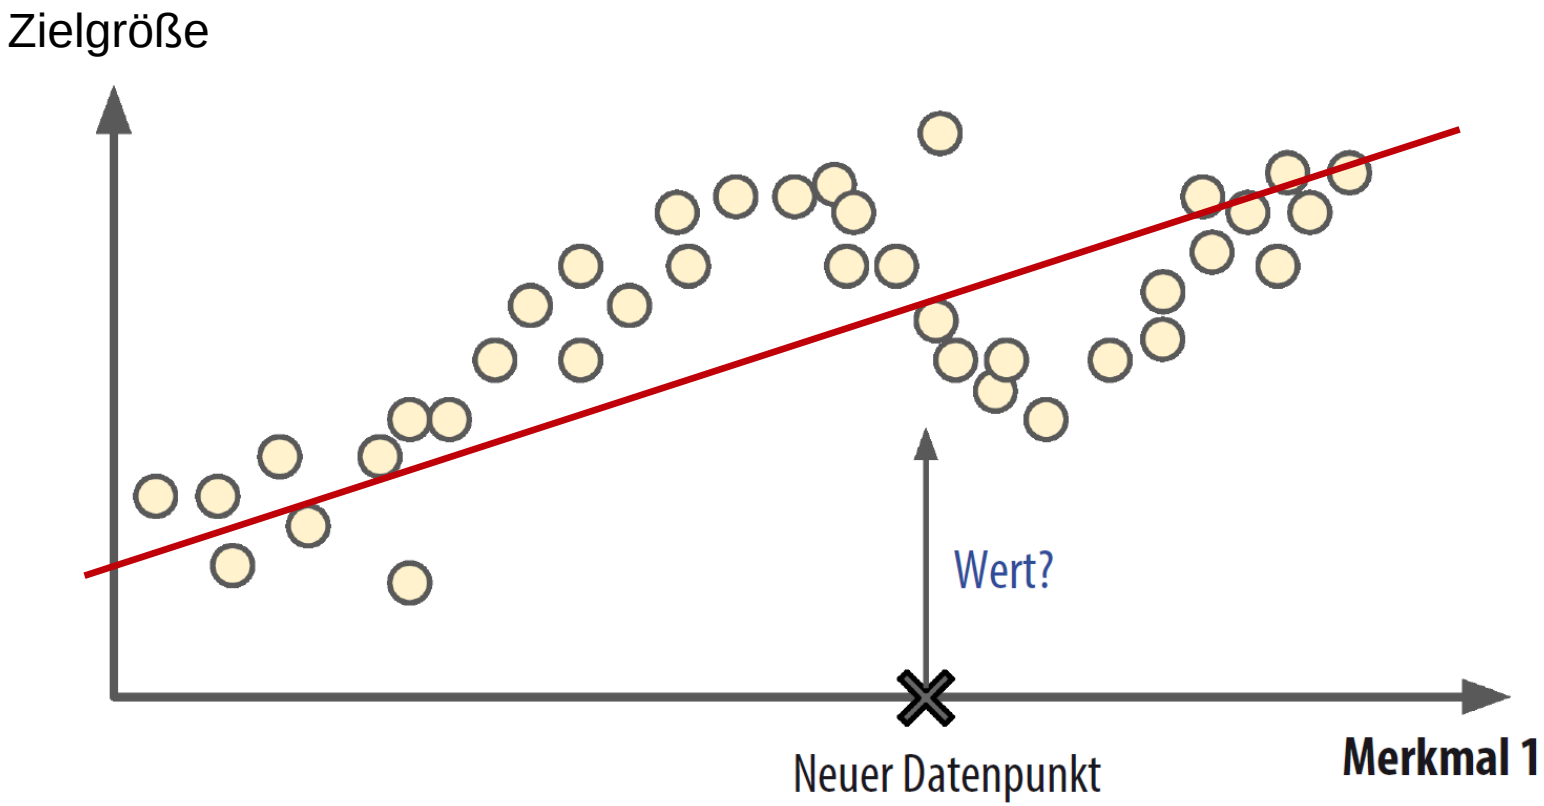
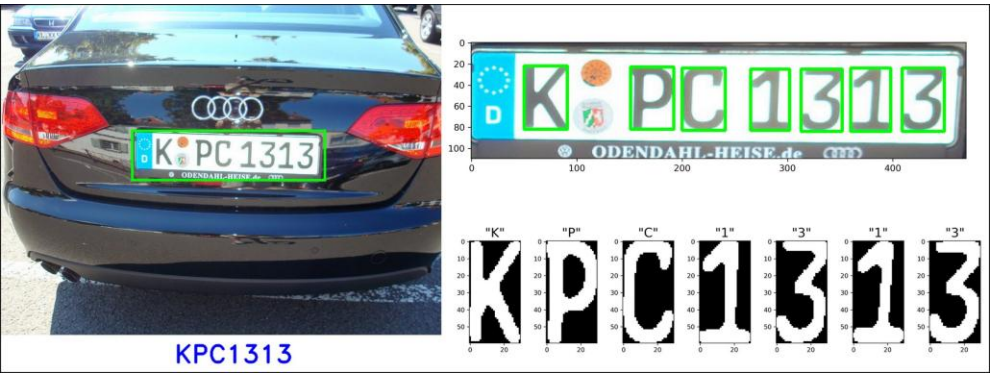


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Quiz – Regression oder Klassifikation

Mentimeter Code: 1741 3121



Quelle: https://www.analyticsvidhya.com/blog/2021/03/license-plate-character-recognition-using-knn-and-cnn/

	Klassifikation	Regression
Preisvorhersage an der Tankstelle auf Basis des Ölpreises, weltweite Krisen, Monat, Ort		✓
Erkennung von Nummernschildern mit einer Kamera	✓	
Detektion von gesprochenen Key-Wörtern wie Alexa, Hey Siri, ...	✓	
Schätzung der Oberflächentemperatur eines Sees auf Basis der Sonnenscheindauer und Außentemperatur		✓

Training von ML Modellen mit und ohne Überwachung

Unüberwachtes Lernen

- Beispiel:
  - Empfehlungssysteme
- Was wären Beispiele für Merkmale?
- Bsp. Videofilm
  -
  -
-
-

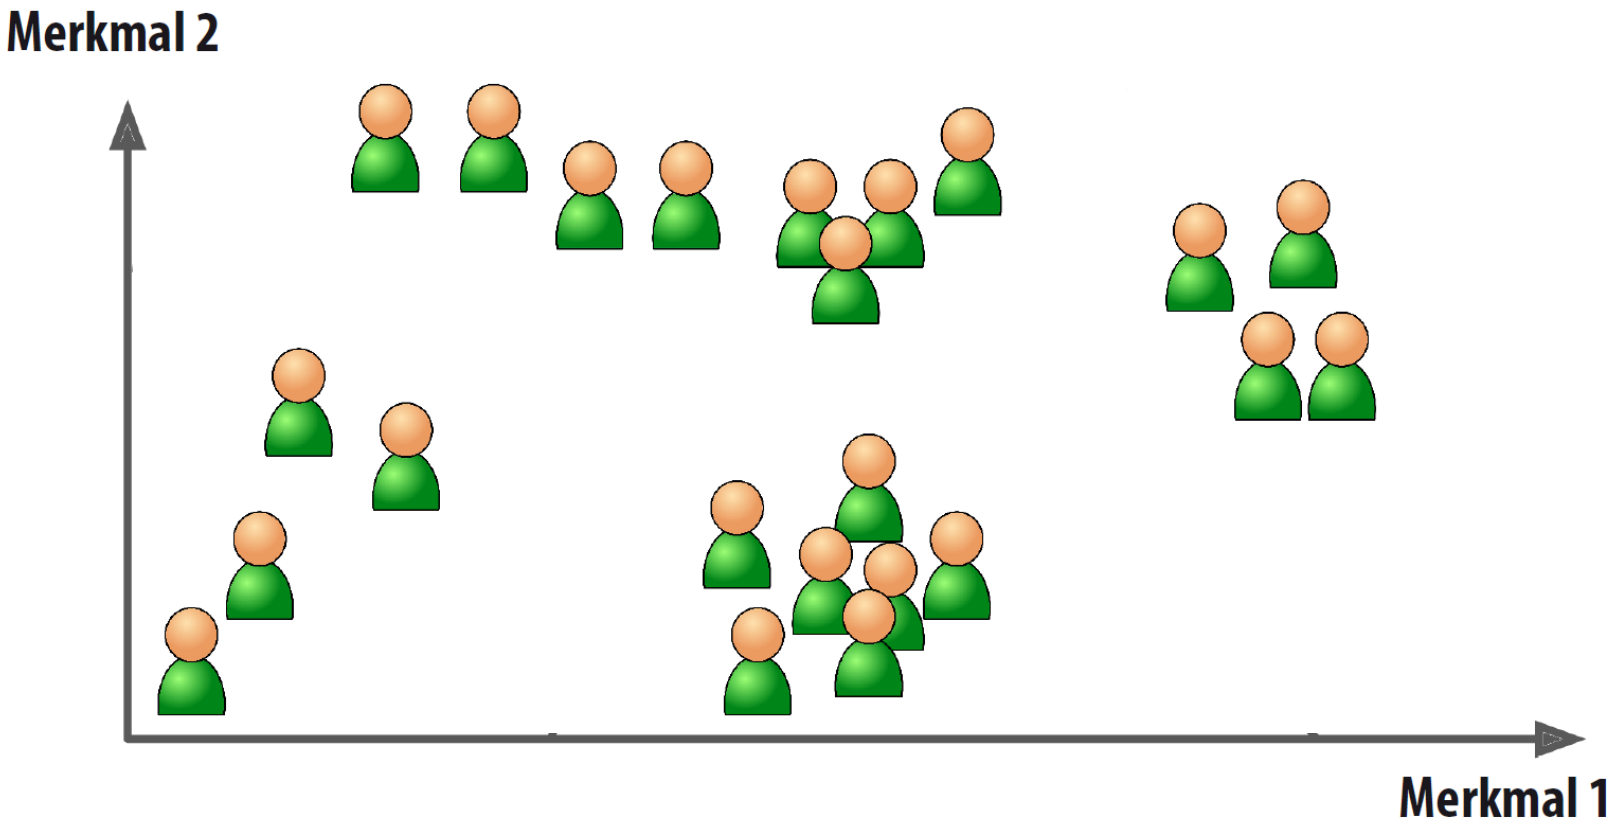


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Unüberwachtes Lernen

- Beispiel:
  - Empfehlungssysteme
- Was wären Beispiele für Merkmale?
- Bsp. Videofilm
  - Merkmal 1: Spannung
  - Merkmal 2: Action
- Clustering
- Wie viele Cluster sehen Sie?

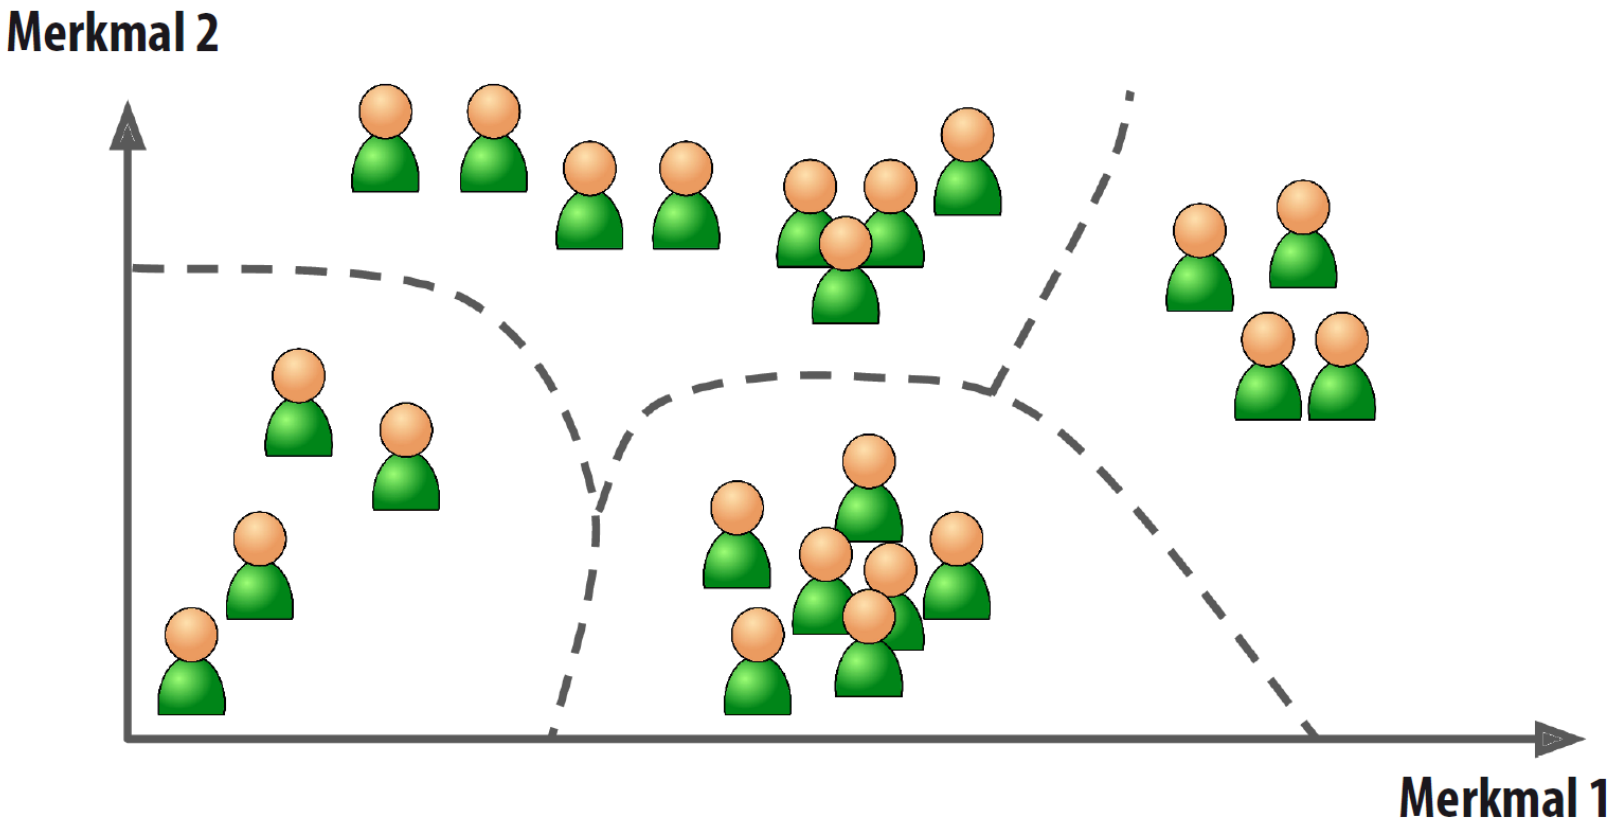


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Unüberwachtes Lernen

- Beispiel:
  - Empfehlungssysteme
- Was wären Beispiele für Merkmale?
- Bsp. Videofilm
  - Merkmal 1: Spannung
  - Merkmal 2: Action
- Clustering
- Wie viele Cluster sehen Sie?

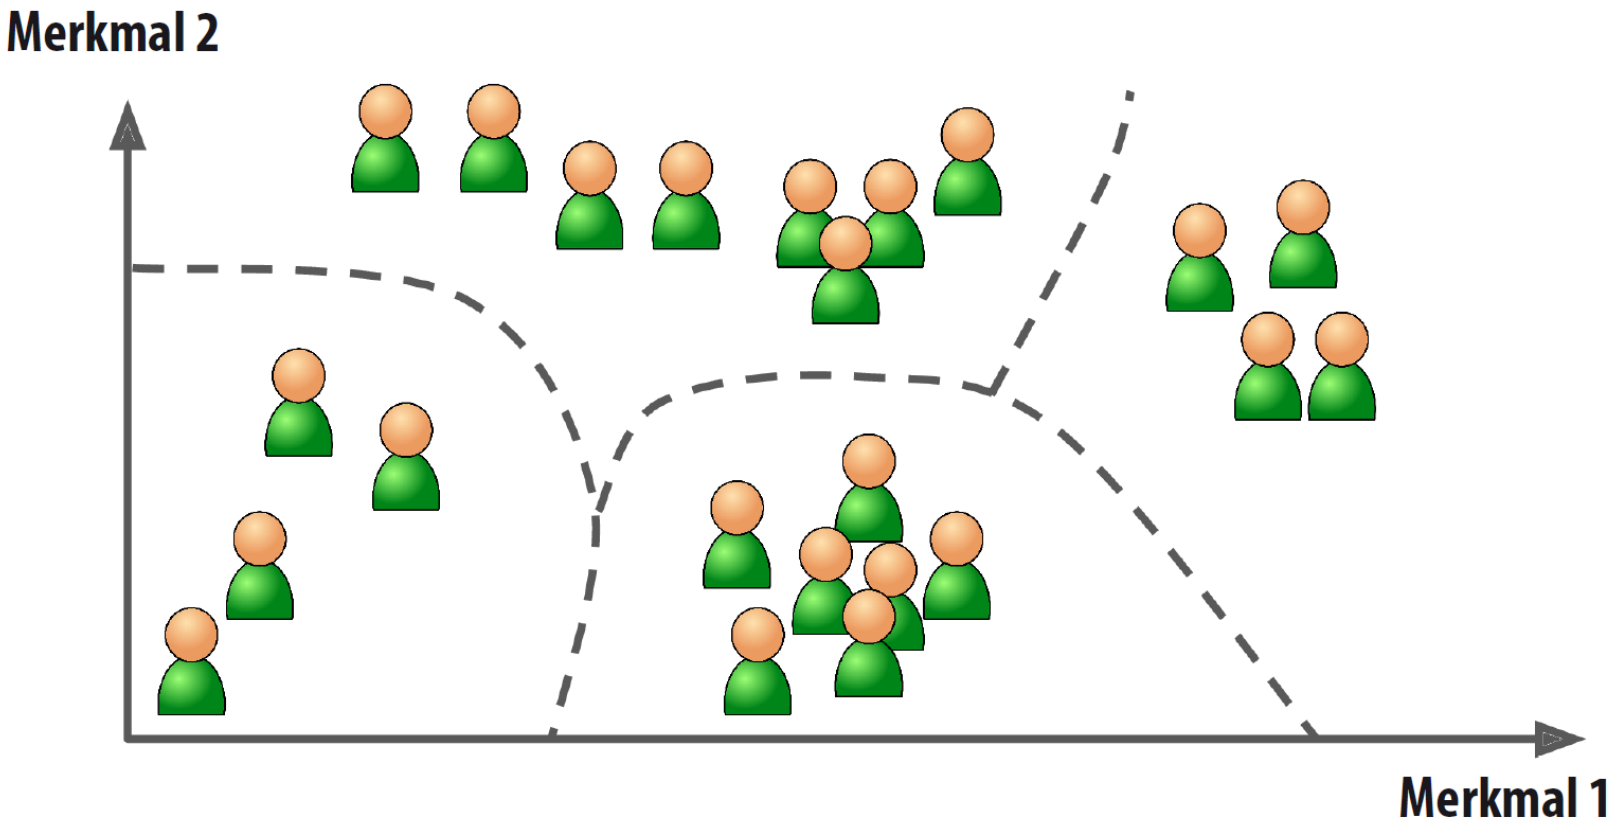


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Unüberwachtes Lernen

- Anomalieerkennung
- Beispiel:
  - Ungewöhnliche Transaktionen auf Kreditkarten
  - Produktionsfehler
  - Messfehler
  - Sensordefekt
- Merkmale?
  -
  -

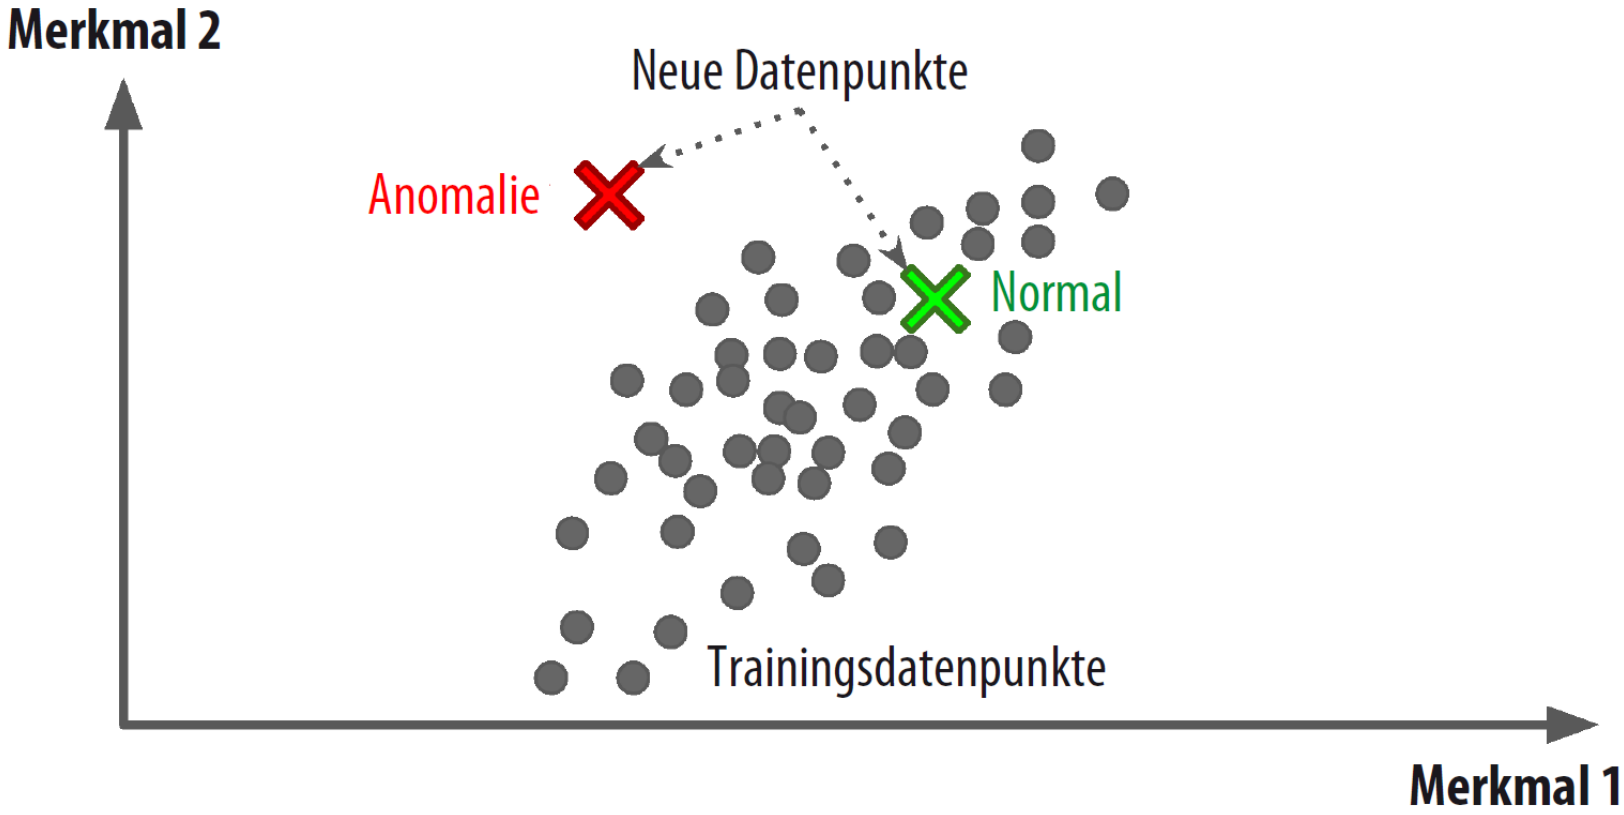


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Unüberwachtes Lernen

- Anomalieerkennung
- Beispiel:
  - Ungewöhnliche Transaktionen auf Kreditkarten
  - Produktionsfehler
  - Messfehler
  - Sensordefekt
- Merkmale?
  - Merkmal 1: Temperatur
  - Merkmal 2: Durchfluss

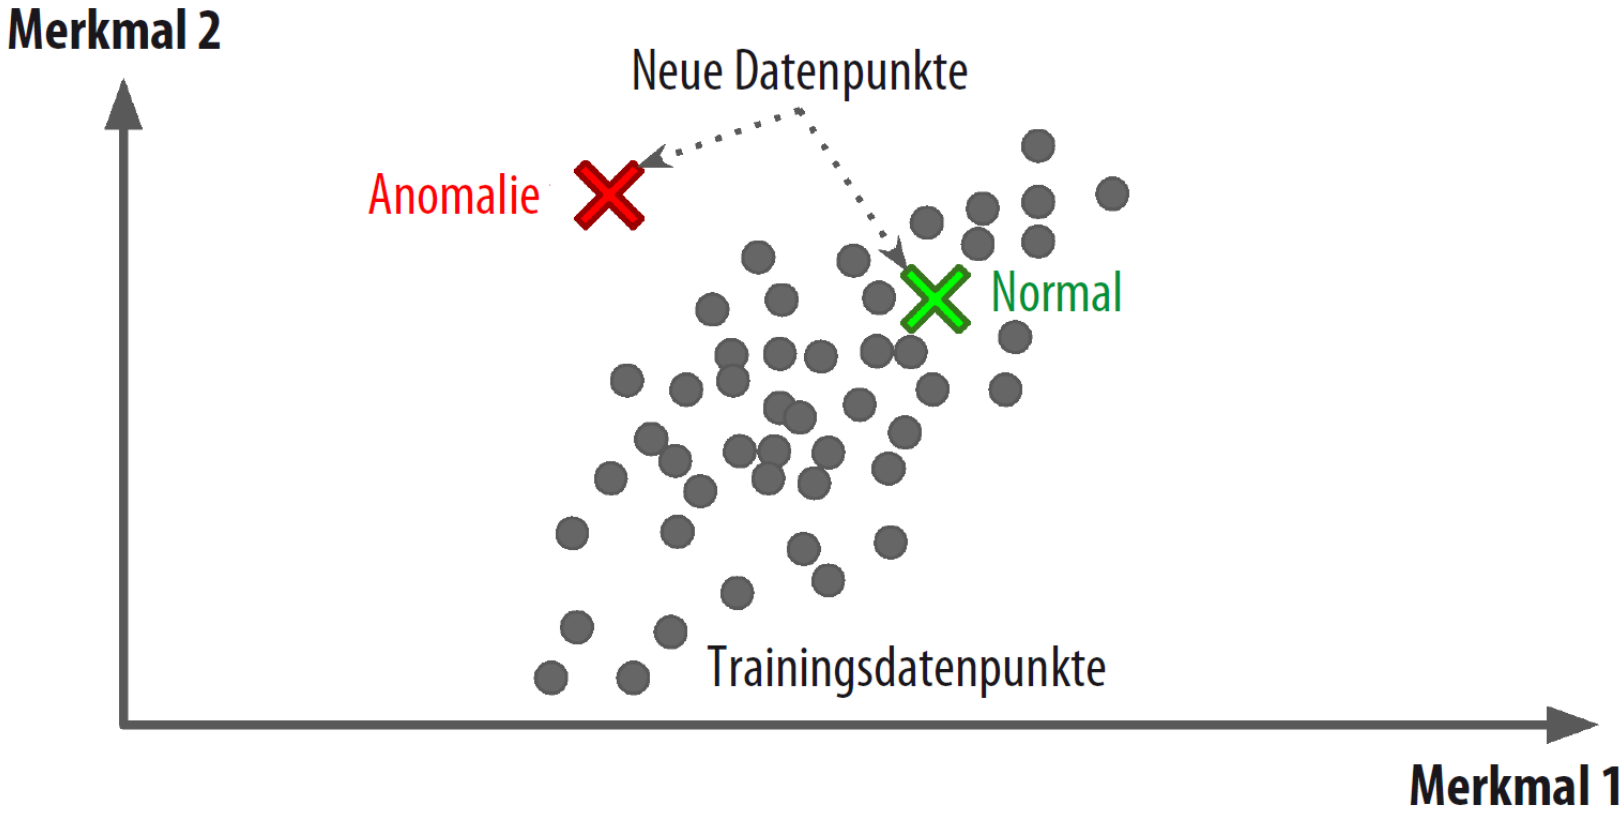
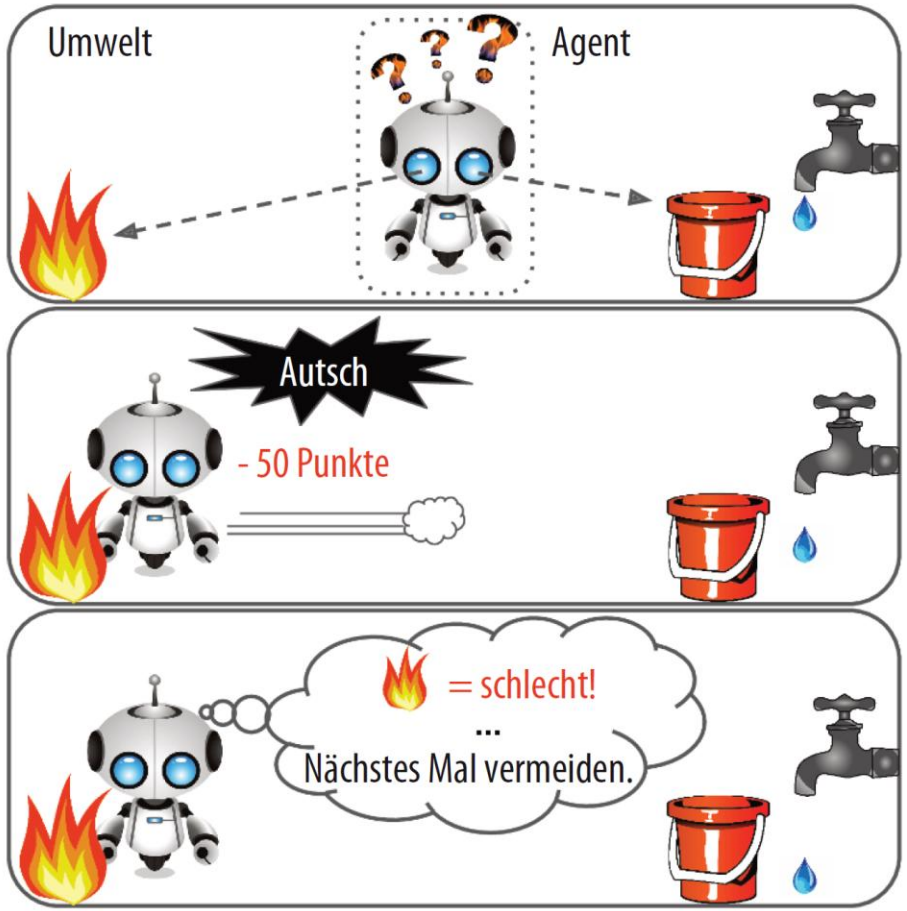


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Reinforcement Learning

- Agent lernt durch Interaktion mit Umgebung (führt Aktionen aus)
-
-
-
-
  -
  -



1 Beobachten

2 Aktion nach einer Policy auswählen

3 Aktion durchführen!

4 Belohnung oder Strafe erhalten

5 Policy aktualisieren (Lernschritt)

6 Wiederholen bis zum Finden einer optimalen Policy

Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Reinforcement Learning

- Agent lernt durch Interaktion mit Umgebung (führt Aktionen aus)
- Erhält Belohnungen
- Maximierung der Summe der Belohnungen über die Zeit
-
-
  -
  -

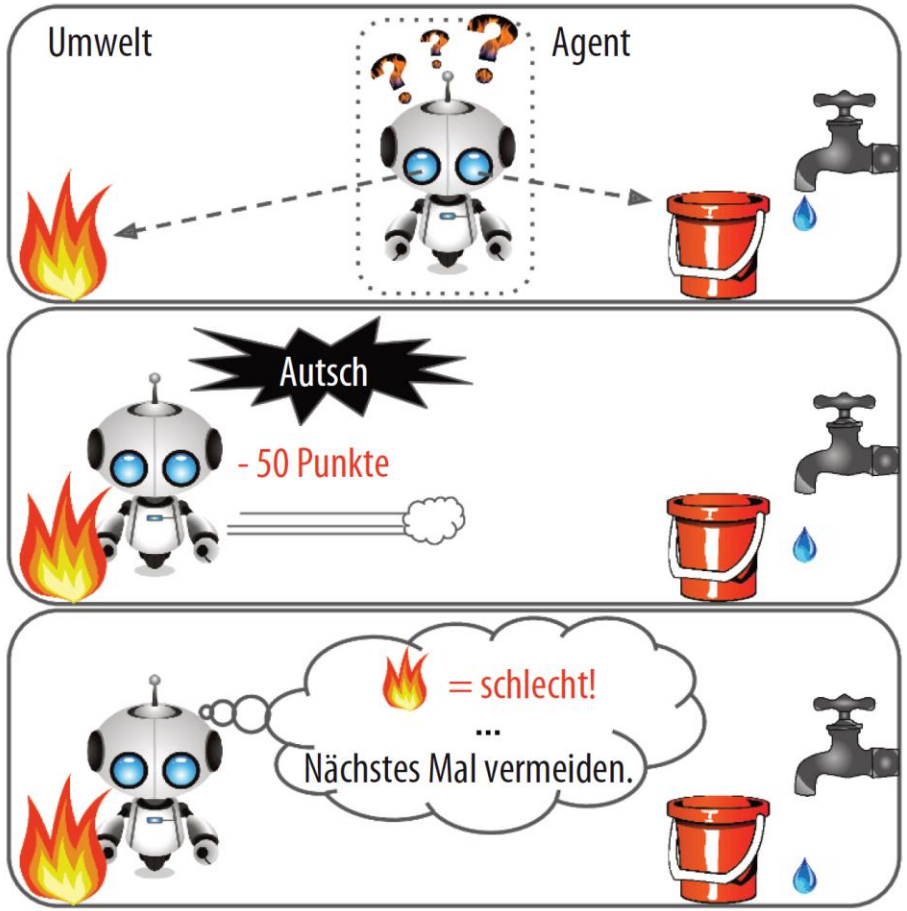


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Reinforcement Learning

- Agent lernt durch Interaktion mit Umgebung (führt Aktionen aus)
- Erhält Belohnungen
- Maximierung der Summe der Belohnungen über die Zeit
- Policy definiert, welche Aktion Agent in welcher Situation auswählt
-
  -
  -

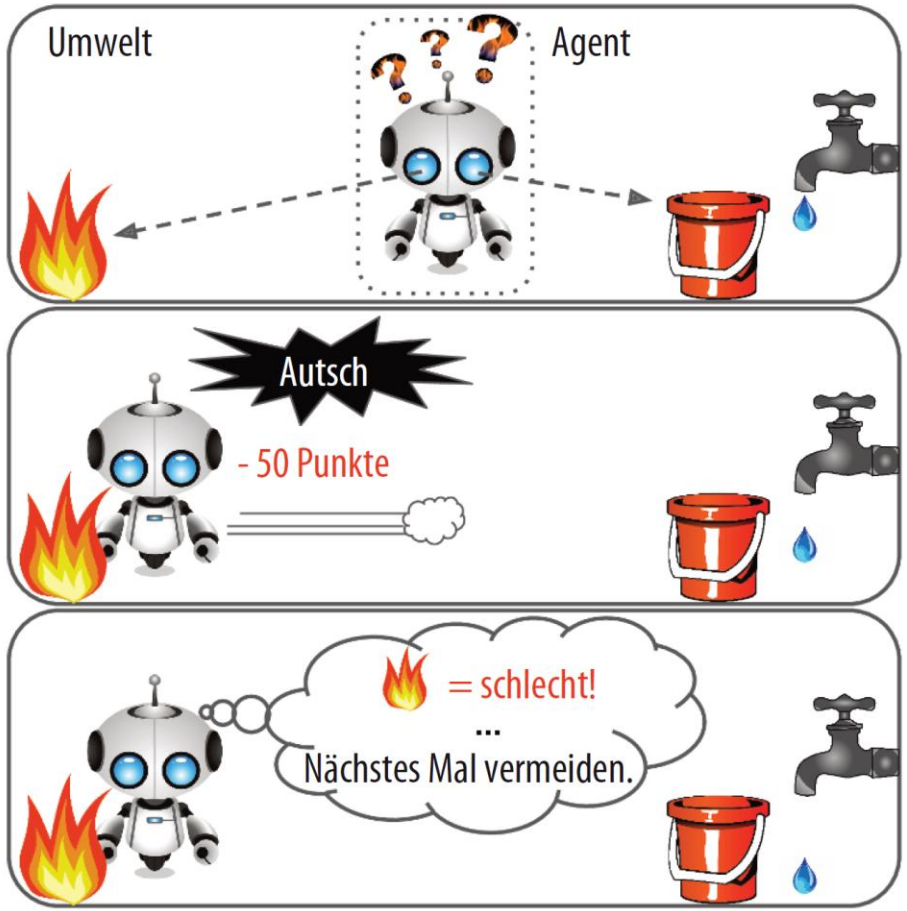


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training von ML Modellen mit und ohne Überwachung

Reinforcement Learning

- Agent lernt durch Interaktion mit Umgebung (führt Aktionen aus)
- Erhält Belohnungen
- Maximierung der Summe der Belohnungen über die Zeit
- Policy definiert, welche Aktion Agent in welcher Situation auswählt

- Beispiele:
  - Roboter
  - Spiele (AlphaGo)

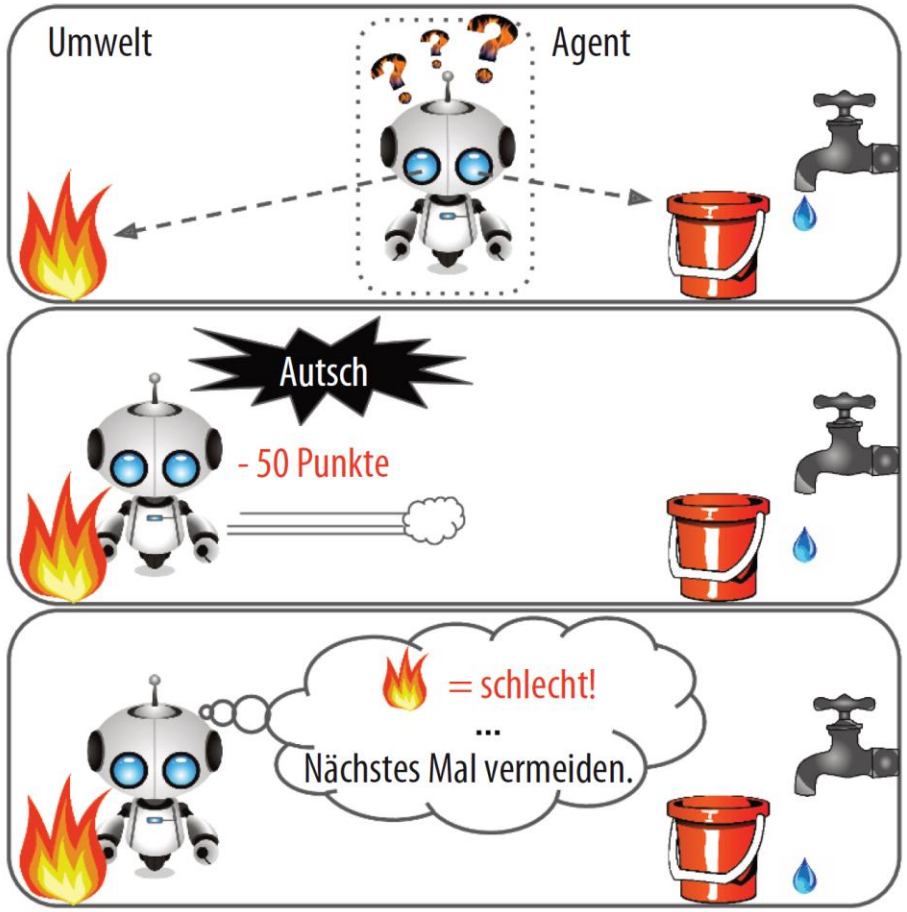


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Umfrage zu Training von Machine Learning Modellen mit und ohne Überwachung

- Vorhersage eines Aktienkurses
- Emotionserkennung aus gesprochener Sprache eines Menschen
- Training eines Agenten für einen Ego-Shooter
- Empfehlung eines Films bei Netflix
-
-
-
- Antwortmöglichkeiten:
  - Überwachtes Lernen (Regression, Klassifikation)
  - Unüberwachtes Lernen (Clustering, Anomalieerkennung)
  - Reinforcement Learning

Umfrage zu Training von Machine Learning Modellen mit und ohne Überwachung

- Vorhersage eines Aktienkurses
- Emotionserkennung aus gesprochener Sprache eines Menschen
- Training eines Agenten für einen Ego-Shooter
- Empfehlung eines Films bei Netflix
- Erkennung ob ein Text ein Thema aus der Wirtschaft, dem Sport oder Kultur beschreibt
- Ein Pflegeroboter lernt durch Ausprobieren, wie er ältere Menschen beim Aufstehen am besten unterstützen kann, ohne sie zu gefährden.
- Ein Wearable analysiert Bewegungs- und Schlafmuster, um verschiedene Verhaltenscluster zu entdecken (z. B. „aktive Frühaufsteher“, „gestresste Nachteulen“).

- Antwortmöglichkeiten:
  - Überwachtes Lernen (Regression, Klassifikation)
  - Unüberwachtes Lernen (Clustering, Anomalieerkennung)
  - Reinforcement Learning

Umfrage zu Training von Machine Learning Modellen mit und ohne Überwachung

- Vorhersage eines Aktienkurses
- Emotionserkennung aus gesprochener Sprache eines Menschen
- Training eines Agenten für einen Ego-Shooter
- Empfehlung eines Films bei Netflix
- Erkennung ob ein Text ein Thema aus der Wirtschaft, dem Sport oder Kultur beschreibt
- Ein Pflegeroboter lernt durch Ausprobieren, wie er ältere Menschen beim Aufstehen am besten unterstützen kann, ohne sie zu gefährden.
- Ein Wearable analysiert Bewegungs- und Schlafmuster, um verschiedene Verhaltenscluster zu entdecken (z. B. „aktive Frühaufsteher“, „gestresste Nachteulen“).

- Antwortmöglichkeiten:
  - Überwachtes Lernen (Regression, Klassifikation)
  - Unüberwachtes Lernen (Clustering, Anomalieerkennung)
  - Reinforcement Learning

Übungsblatt 2, Aufgabe 1

Überwachtes Lernen - Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. Bruttoinlandsprodukt (BIP)

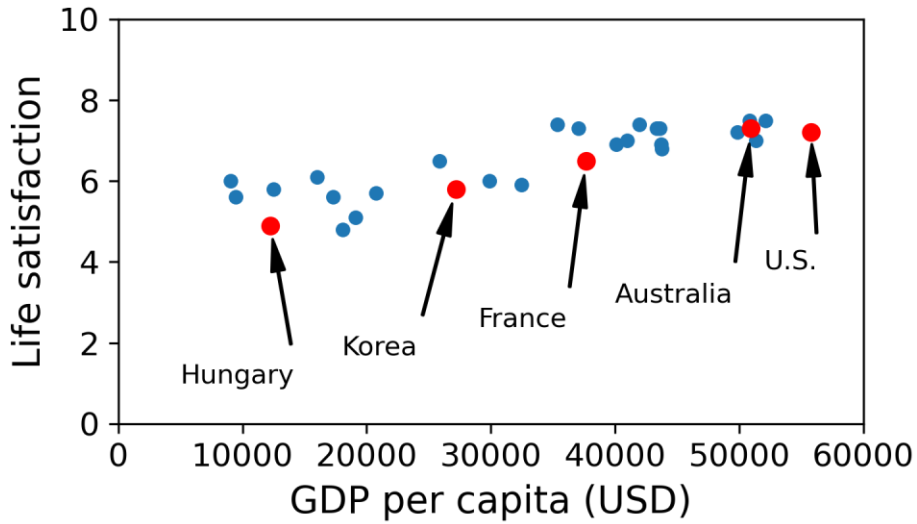


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Überwachtes Lernen - Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. Bruttoinlandsprodukt (BIP)
- Was ist das für ein Problem?
  - Regression oder Klassifikation?
-
-
-

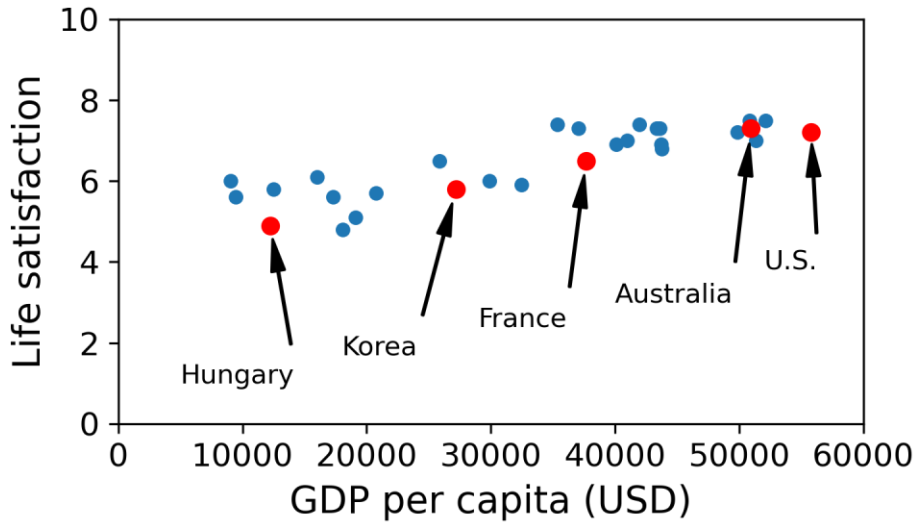


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Überwachtes Lernen - Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. Bruttoinlandsprodukt (BIP)
- Was ist das für ein Problem?
  - Regression oder Klassifikation?
- Sehen Sie hier einen Trend?
- Ist dieser linear, quadratisch, logarithmisch?
-

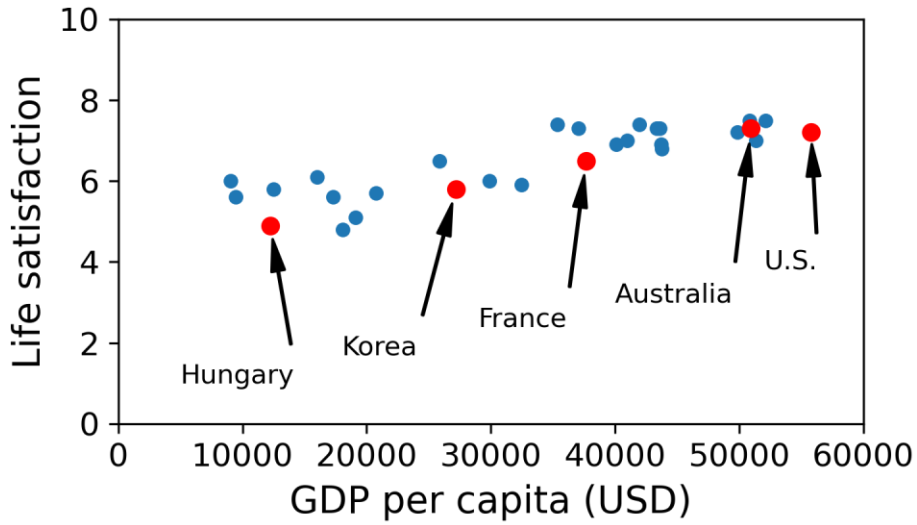


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Überwachtes Lernen - Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. Bruttoinlandsprodukt (BIP)
- Was ist das für ein Problem?
  - Regression oder Klassifikation?
- Sehen Sie hier einen Trend?
- Ist dieser linear, quadratisch, logarithmisch?

- Modellannahme:

Formel 1-1: Ein einfaches lineares Modell

$$\text{Zufriedenheit} = \theta_0 + \theta_1 \times \text{BIP_pro_Kopf}$$

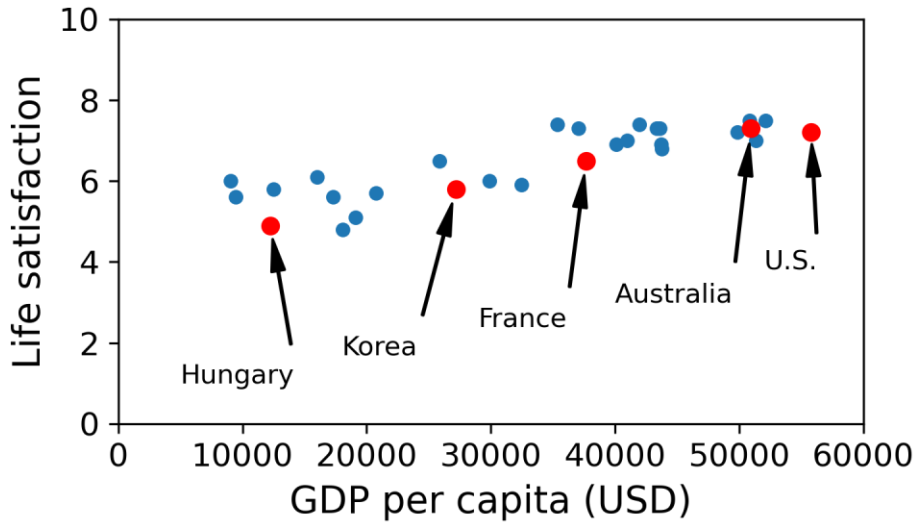


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. BIP

Formel 1-1: Ein einfaches lineares Modell

$$\text{Zufriedenheit} = \theta_0 + \theta_1 \times \text{BIP_pro_Kopf}$$

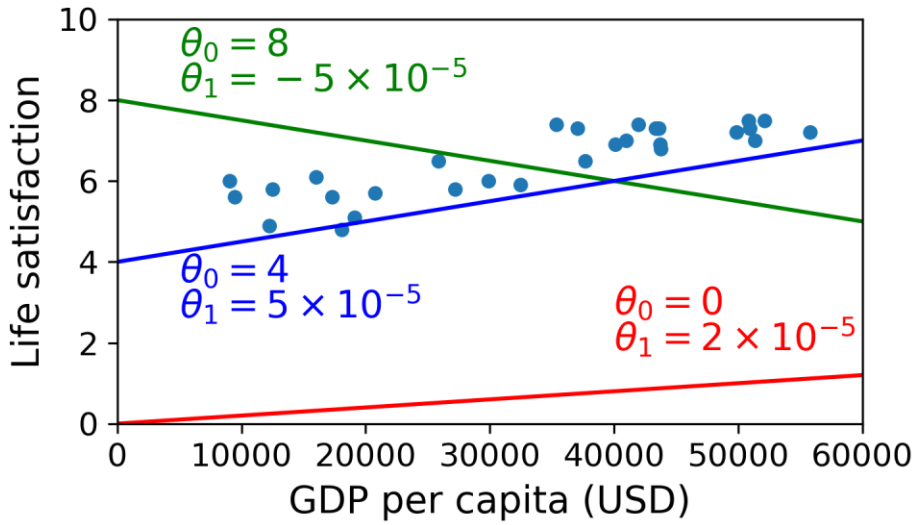


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. BIP

Formel 1-1: Ein einfaches lineares Modell

$$\text{Zufriedenheit} = \theta_0 + \theta_1 \times \text{BIP_pro_Kopf}$$

- Gesucht sind die Werte für die Modellparameter, die zu einer Vorhersage führen, die einen möglichst kleinen Prädiktionsfehler hat

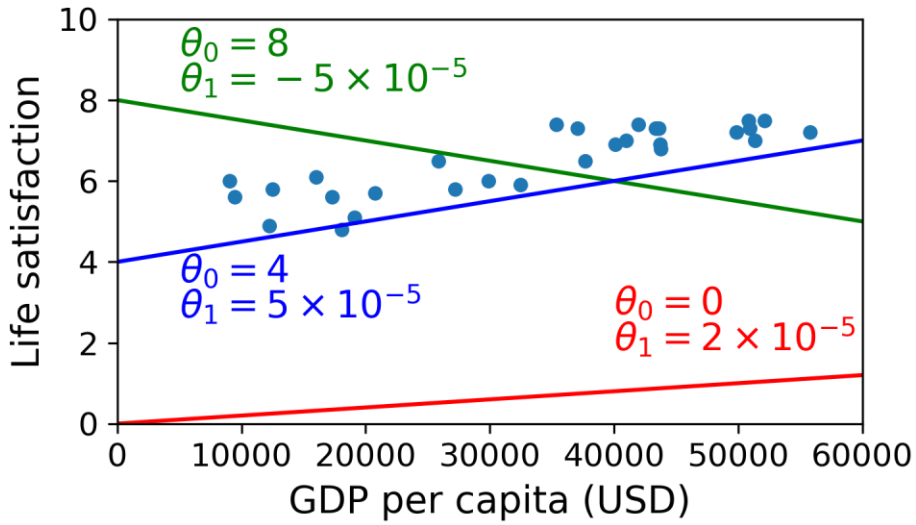


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. BIP

Formel 1-1: Ein einfaches lineares Modell

$$\text{Zufriedenheit} = \theta_0 + \theta_1 \times \text{BIP_pro_Kopf}$$

- Gesucht sind die Werte für die Modellparameter, die zu einer Vorhersage führen, die einen möglichst kleinen Prädiktionsfehler hat

- Wie messen wir den Prädiktionsfehler?
  -

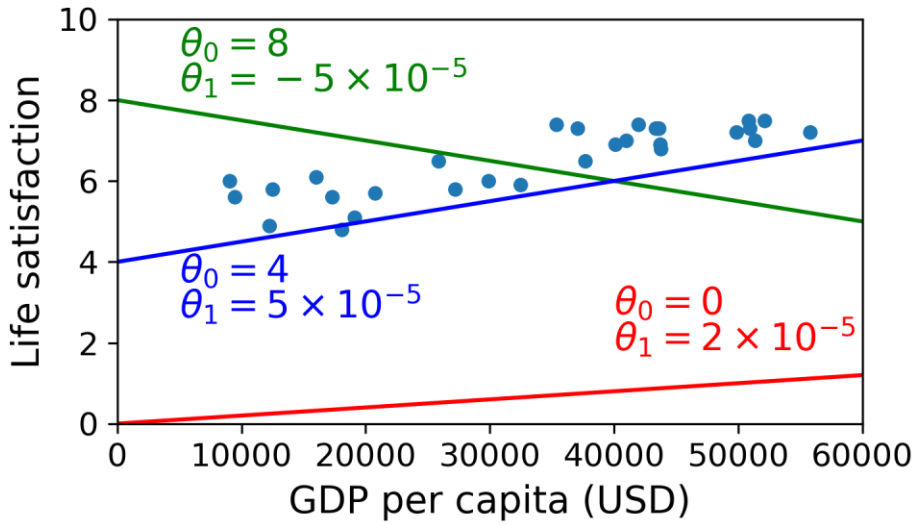


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Lebenszufriedenheit vs. BIP

Formel 1-1: Ein einfaches lineares Modell

$$\text{Zufriedenheit} = \theta_0 + \theta_1 \times \text{BIP_pro_Kopf}$$

- Gesucht sind die Werte für die Modellparameter, die zu einer Vorhersage führen, die einen möglichst kleinen Prädiktionsfehler hat

- Wie messen wir den Prädiktionsfehler?
  - Mittlere Quadratische Fehler,
    Mittlere Absolute Fehler (MAE),
    Root mean squared error (RMSE), …

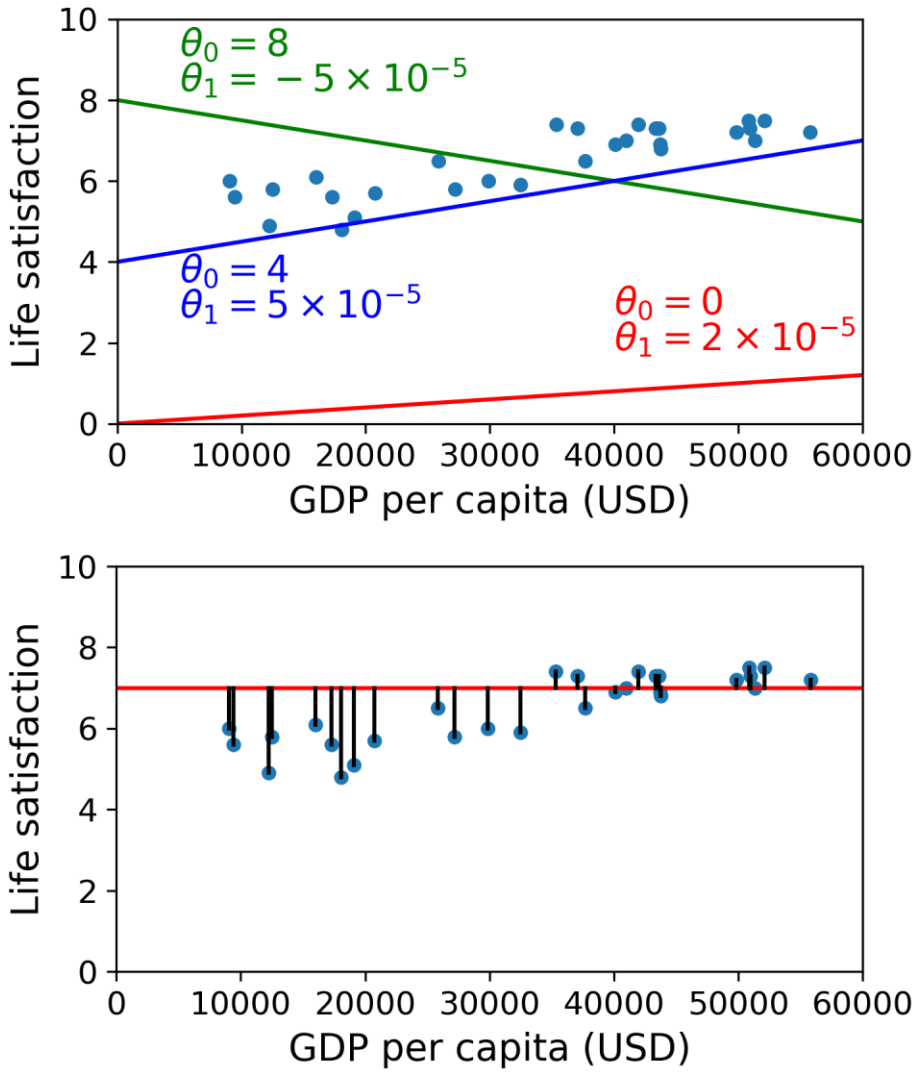


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Algorithmus Lineare Regression:
- Training des Modells:
  - Minimierung des Prädiktionsfehlers auf den Trainingsdaten durch Variation der Modellparameter

Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Algorithmus Lineare Regression:
- Training des Modells:
  - Minimierung des Prädiktionsfehlers auf den Trainingsdaten durch Variation der Modellparameter

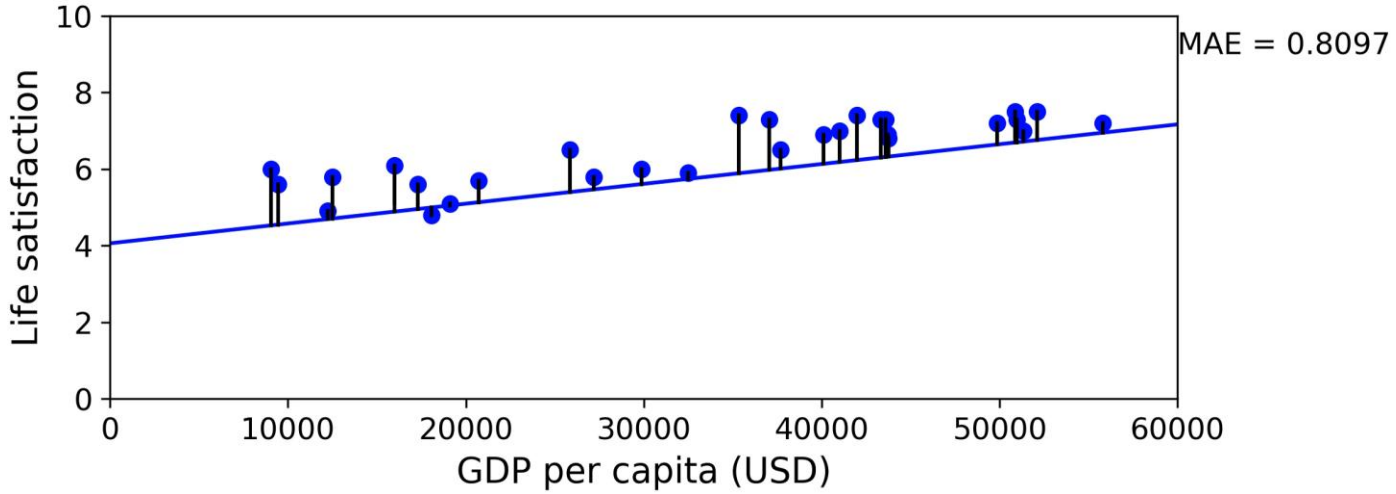
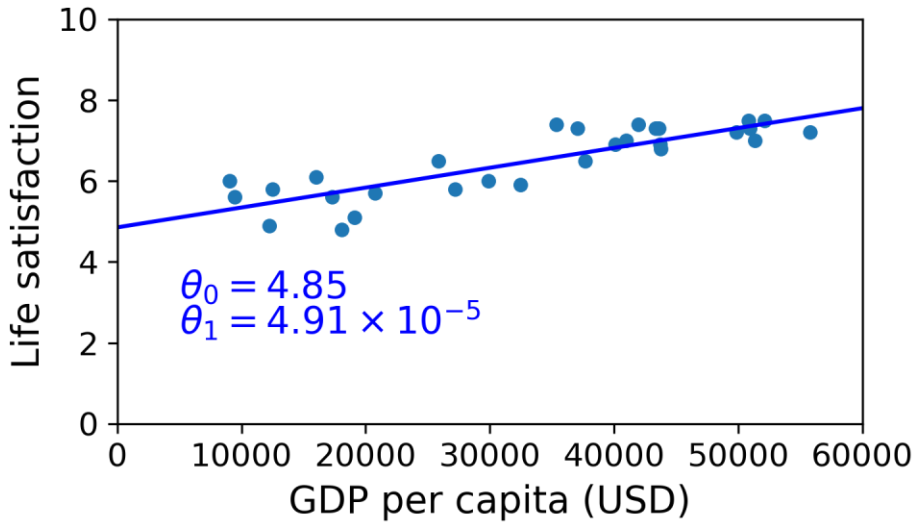


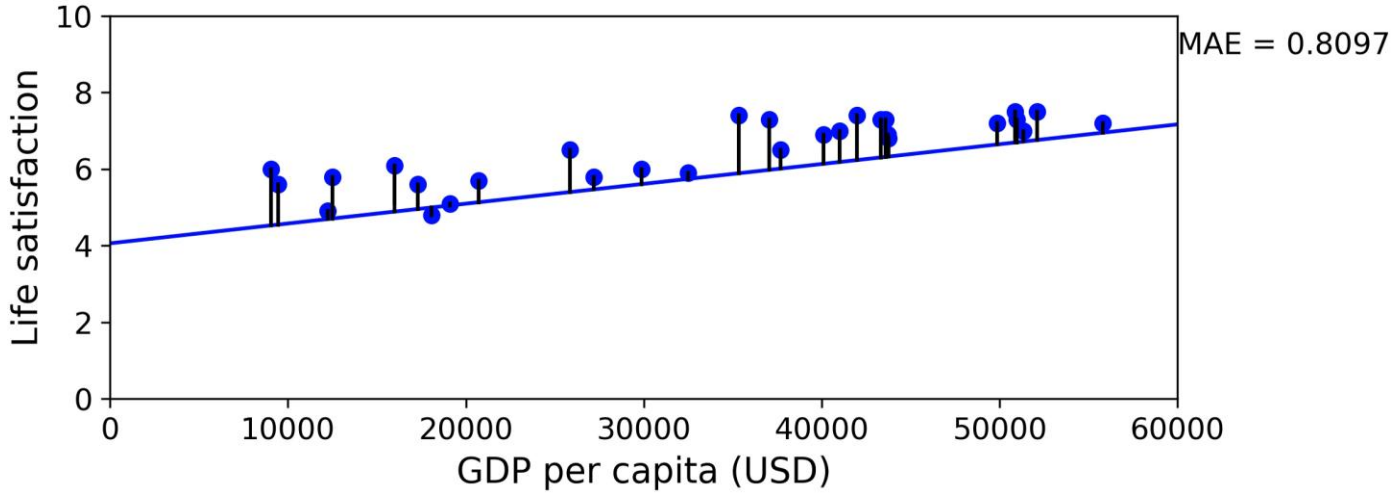
Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Algorithmus Lineare Regression:
- Training des Modells:
  - Minimierung des Prädiktionsfehlers auf den Trainingsdaten durch Variation der Modellparameter





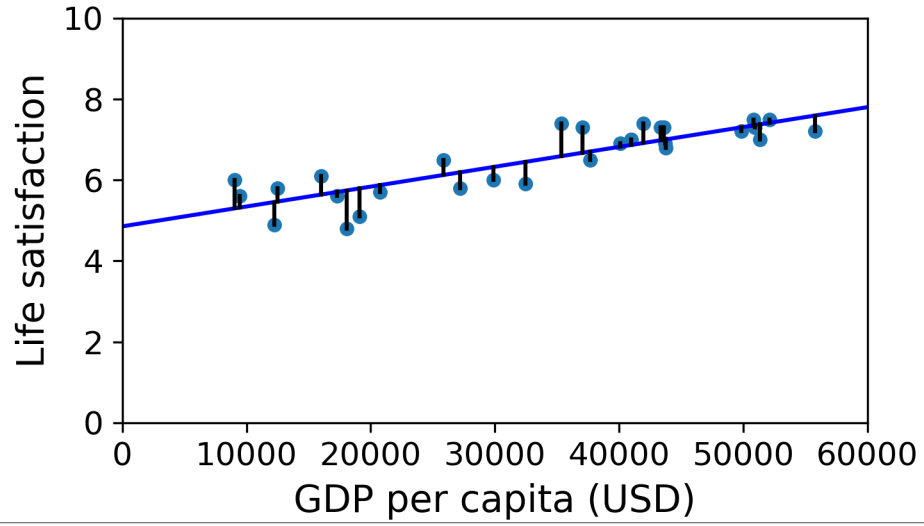
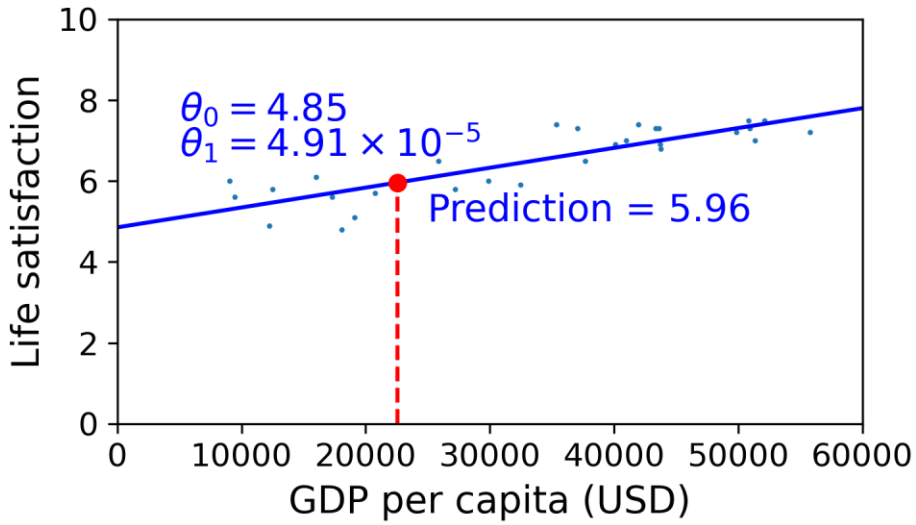


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Einfaches Beispiel

Macht Geld glücklich?

- Test des Modells:
  - Für ein neues Land (hier: Zypern) BIP nehmen und Lebenszufriedenheit mit trainiertem Modell vorhersagen
- Durch Test des Modells auf neuen Daten (Testdaten), prüft man die Qualität des Modells



Formel 1-1: Ein einfaches lineares Modell

$$\text{Zufriedenheit} = \theta_0 + \theta_1 \times \text{BIP_pro_Kopf}$$

Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Training und Test von Machine Learning Methoden

- Modellannahme:
  - Jedes Modell hat Modellparameter
-
  -
-
  -
  -

Training und Test von Machine Learning Methoden

- Modellannahme:
  - Jedes Modell hat Modellparameter
- Training:
  - Minimierung des Prädiktionsfehlers auf den Trainingsdaten durch Variation der Modellparameter
-
  -
  -

Training und Test von Machine Learning Methoden

- Modellannahme:
  - Jedes Modell hat Modellparameter
- Training:
  - Minimierung des Prädiktionsfehlers auf den Trainingsdaten durch Variation der Modellparameter
- Test:
  - Durch Test des trainierten Modells auf neuen Daten (Testdaten), prüft man die Qualität des Modells
  -

Training und Test von Machine Learning Methoden

- Modellannahme:
  - Jedes Modell hat Modellparameter
- Training:
  - Minimierung des Prädiktionsfehlers auf den Trainingsdaten durch Variation der Modellparameter
- Test:
  - Durch Test des trainierten Modells auf neuen Daten (Testdaten), prüft man die Qualität des Modells
  - Wichtig, da man Prädiktionsfehler auf Trainingsdaten auf null reduzieren kann, wenn das Modell genügend Modellparameter hat. Das bedeutet aber nicht, dass das Modell wirklich etwas gelernt hat.

Instanzbasiertes vs. Modellbasiertes Lernen

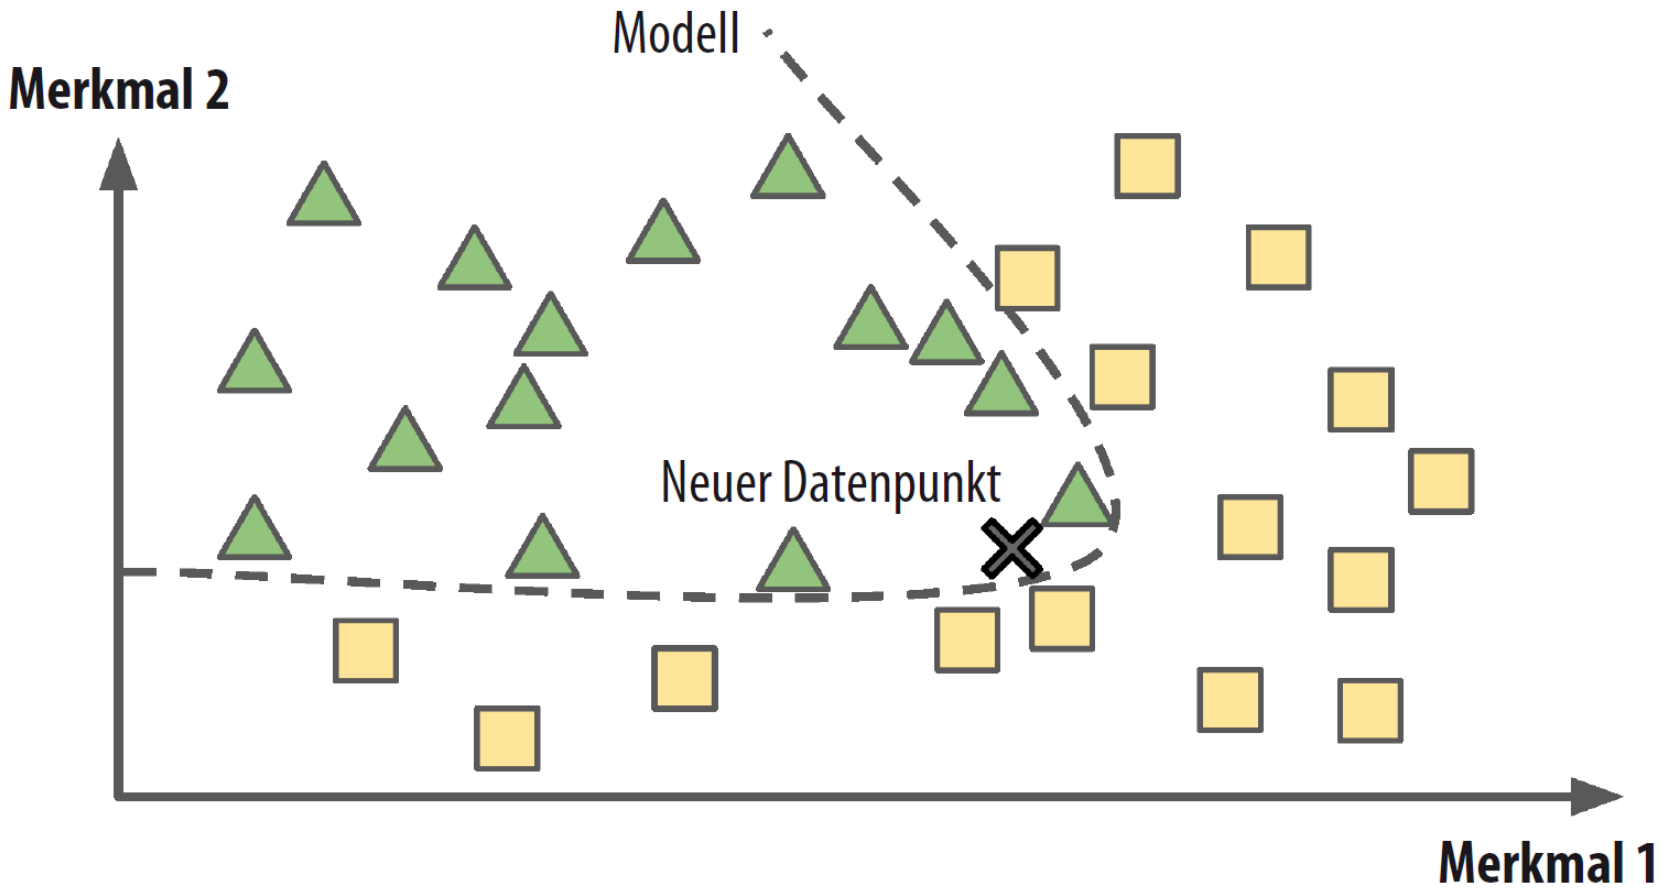


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Instanzbasiertes vs. Modellbasiertes Lernen

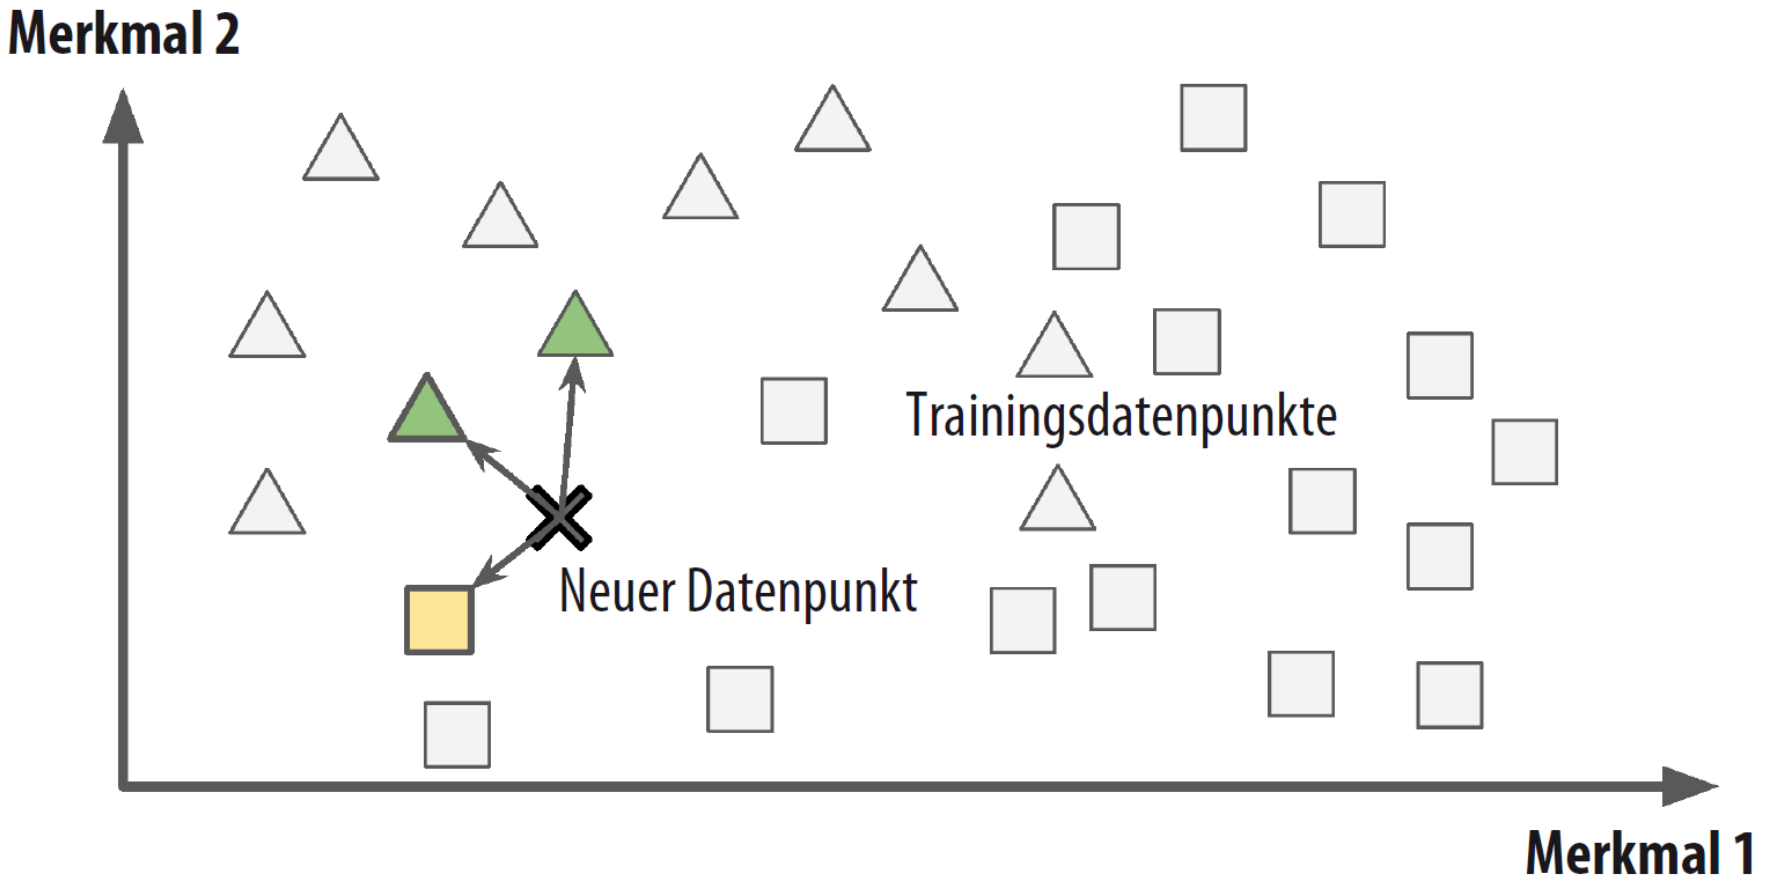


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Instanzbasiertes vs. Modellbasiertes Lernen

k Nächster Nachbar Algorithmus

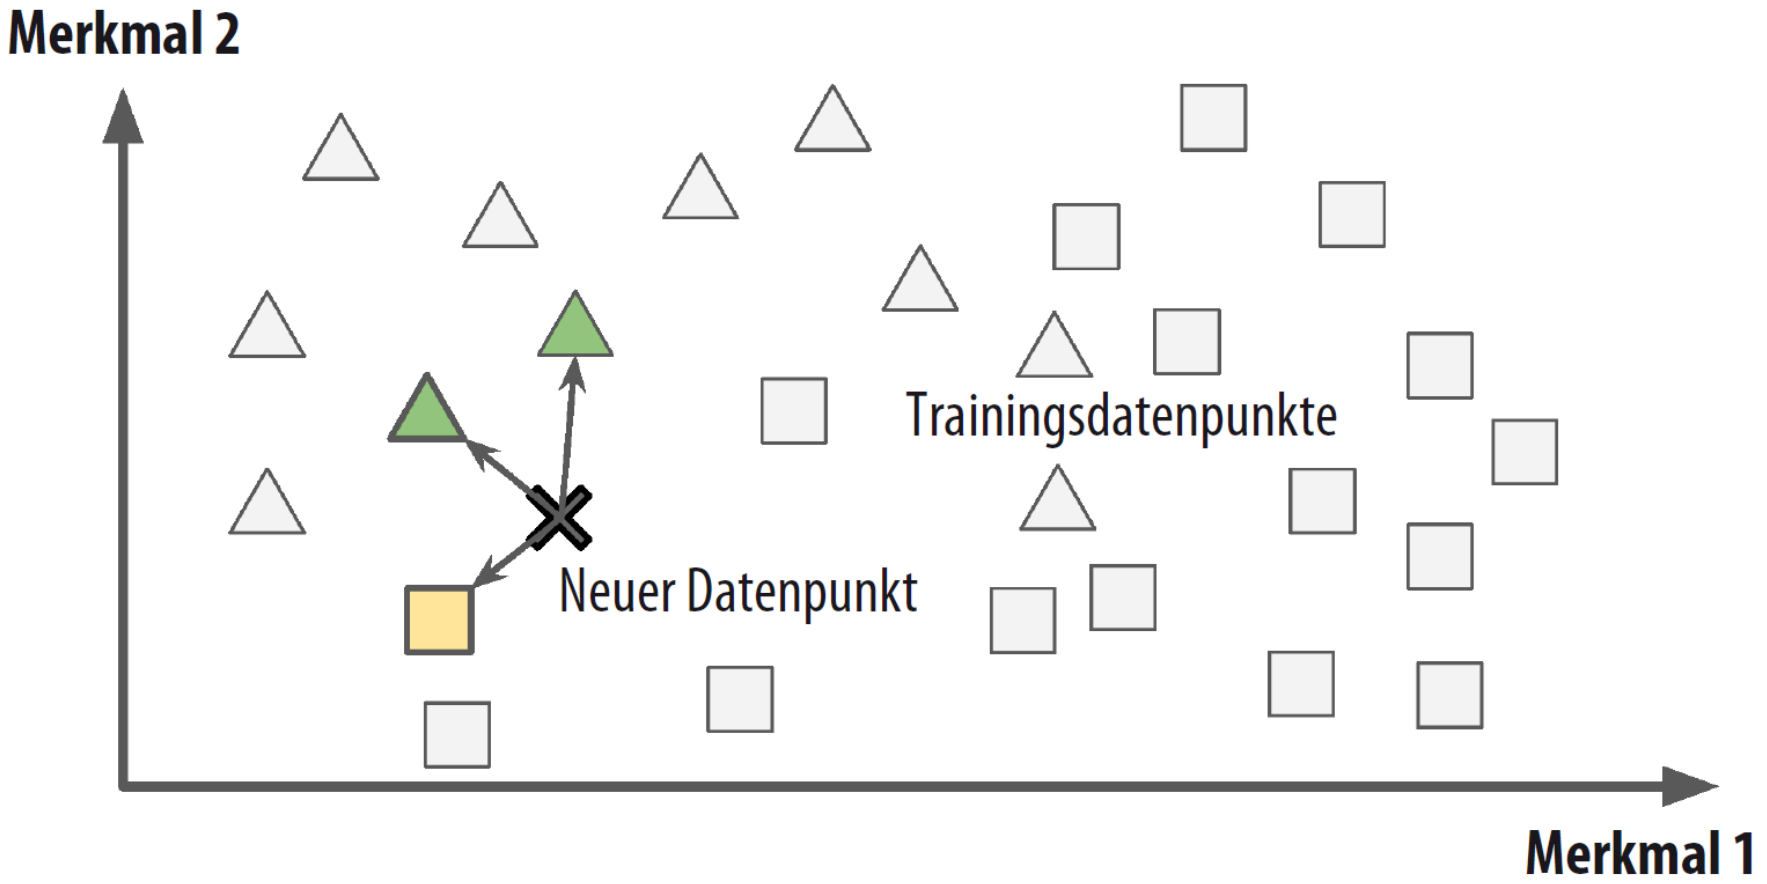


Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Fragen?

- Training mit und ohne menschliche Überwachung
- Lineare Regression

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
- Training von Machine Learning Modellen mit und ohne Überwachung

- **Grundlegende Visualisierungsmöglichkeiten von Daten**

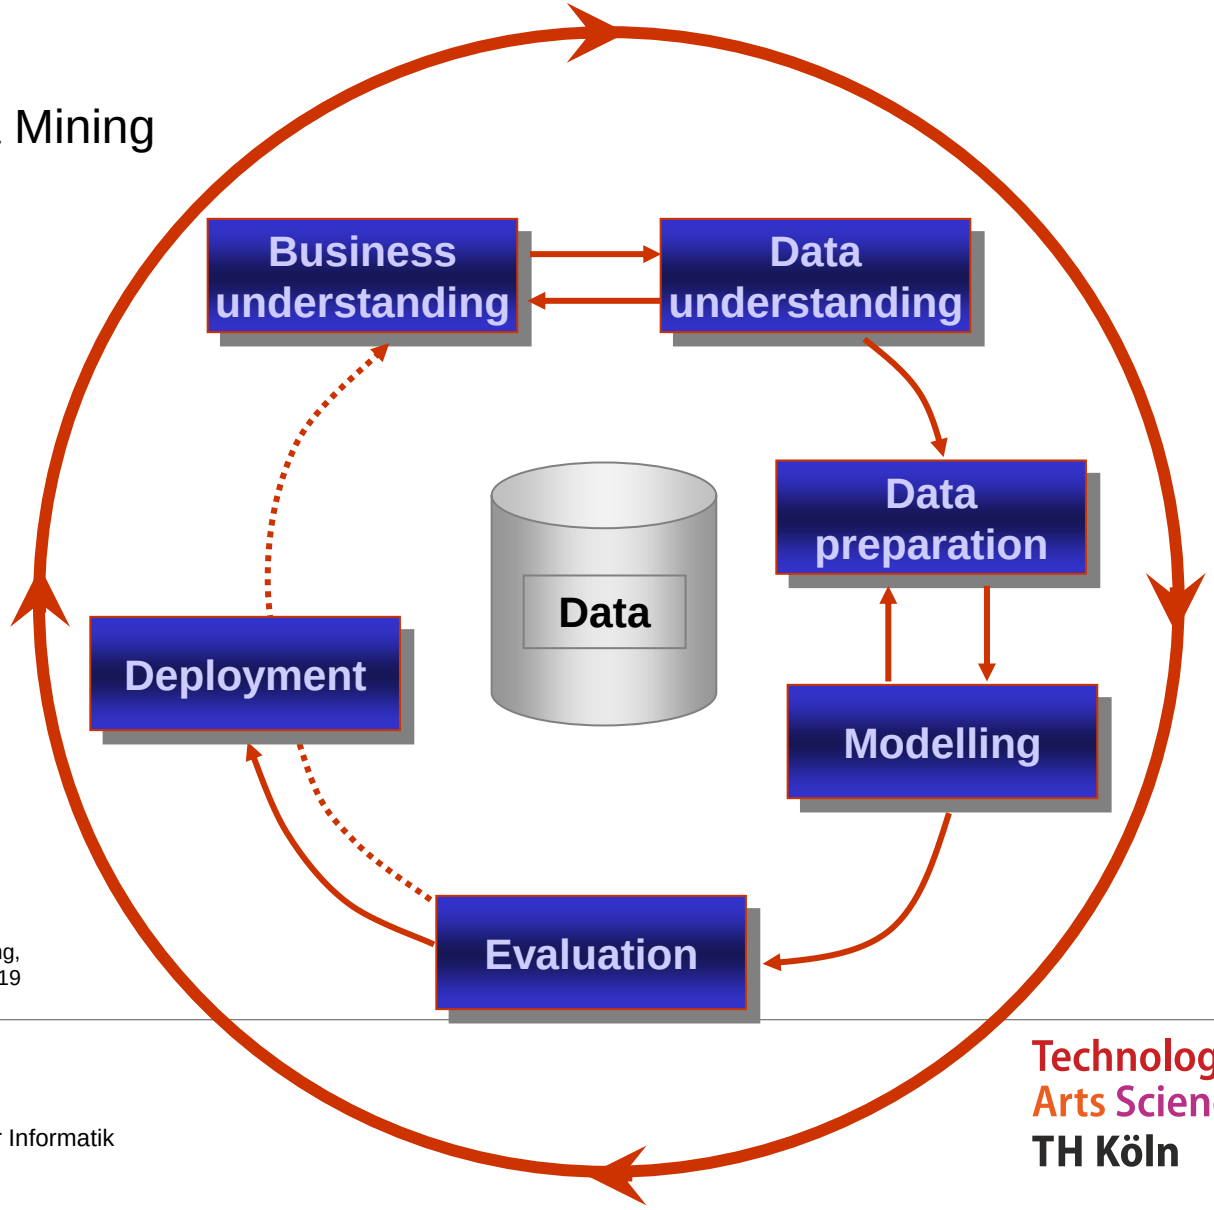
- Wie gut ist das trainierte Machine Learning Modell?

- Machine Learning und Deep Learning Algorithmen
  - Logistische Regression, Entscheidungsbäume, neuronale Netze

- Wie funktioniert ChatGPT & Co.?

CRISP-DM

- Cross-Industry Standard Process for Data Mining



Quelle: W. Konen, WPF Machine Learning, Deep Learning und KI, WS2019

Einen kurzen Blick auf die Daten werfen

- Was ist pandas (Python and Data Analysis)?
  - Pandas ist ein leistungsstarkes Python Datenanalyse Toolkit
  - Im Mittelpunkt von Pandas stehen DataFrame-Objekte. Als Excel-Tabelle vorstellbar.

- Nützliche Methoden eines DataFrame Objekts
  - head() → Gibt die ersten n Zeilen des DataFrames aus
  - info() → Gibt Anzahl Zeilen, Datentyp des Attributs und Anzahl Werte ungleich null aus
  -
  -

Einen kurzen Blick auf die Daten werfen

- Was ist pandas (Python and Data Analysis)?
  - Pandas ist ein leistungsstarkes Python Datenanalyse Toolkit
  - Im Mittelpunkt von Pandas stehen DataFrame-Objekte. Als Excel-Tabelle vorstellbar.

- Nützliche Methoden eines DataFrame Objekts
  - head() → Gibt die ersten n Zeilen des DataFrames aus
  - info() → Gibt Anzahl Zeilen, Datentyp des Attributs und Anzahl Werte ungleich null aus
  - value_counts() → Gibt Anzahl unterschiedlicher Kategorien eines kategorischen Merkmals aus
  - describe() → Gibt numerische Zusammenfassung über alle numerischen Merkmale (mean, std, min, max, …) aus

Übung: Notebook HCAI_02_Übung_Notebook.ipynb

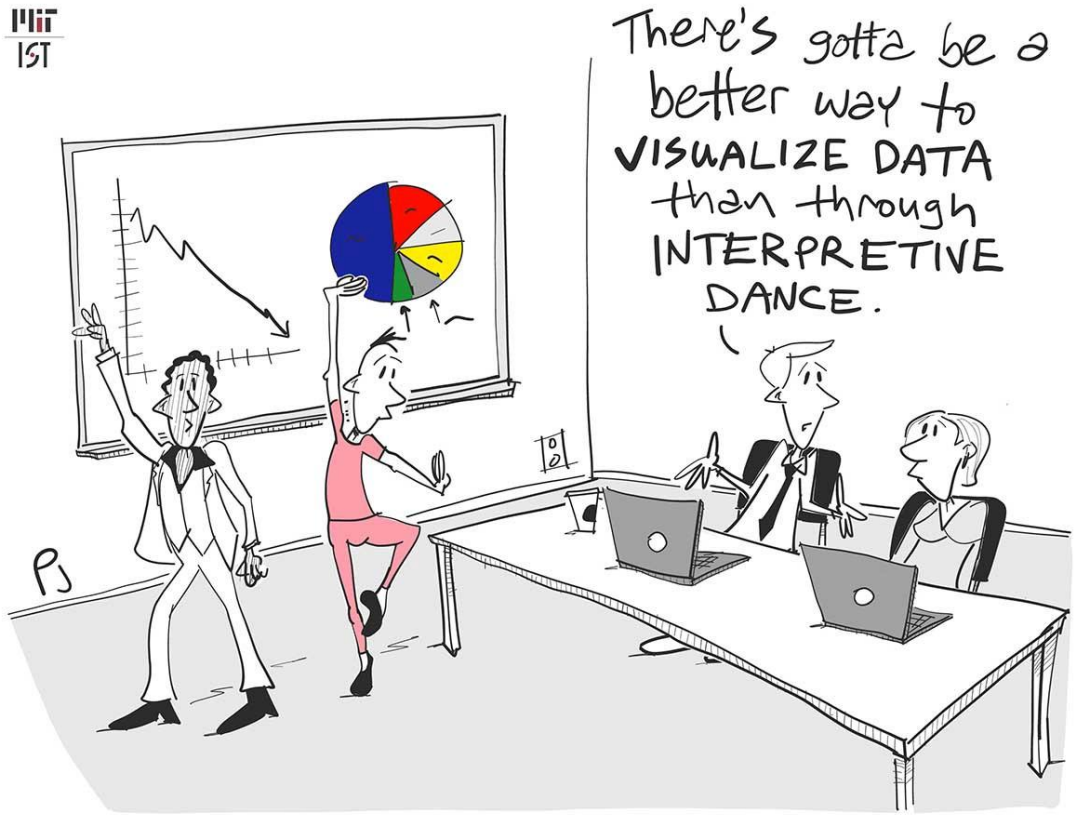
- Übungsblatt 2, Aufgabe 2 (a) – (c).

- Gehen Sie zu: https://colab.research.google.com/
- Laden Sie das Notebook HCAI_02_Übung_Notebook.ipynb hoch
- Klicken Sie auf „Alle ausführen“
- Schauen Sie sich das Notebook an

Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Die Datenvisualisierung:

- verschafft einen Überblick
- dient zur Datenanalyse
  - Bspw. Suche nach Korrelationen
  - Suche nach Besonderheiten
- hilft bei der Dokumentation
- sowie der Kommunikation



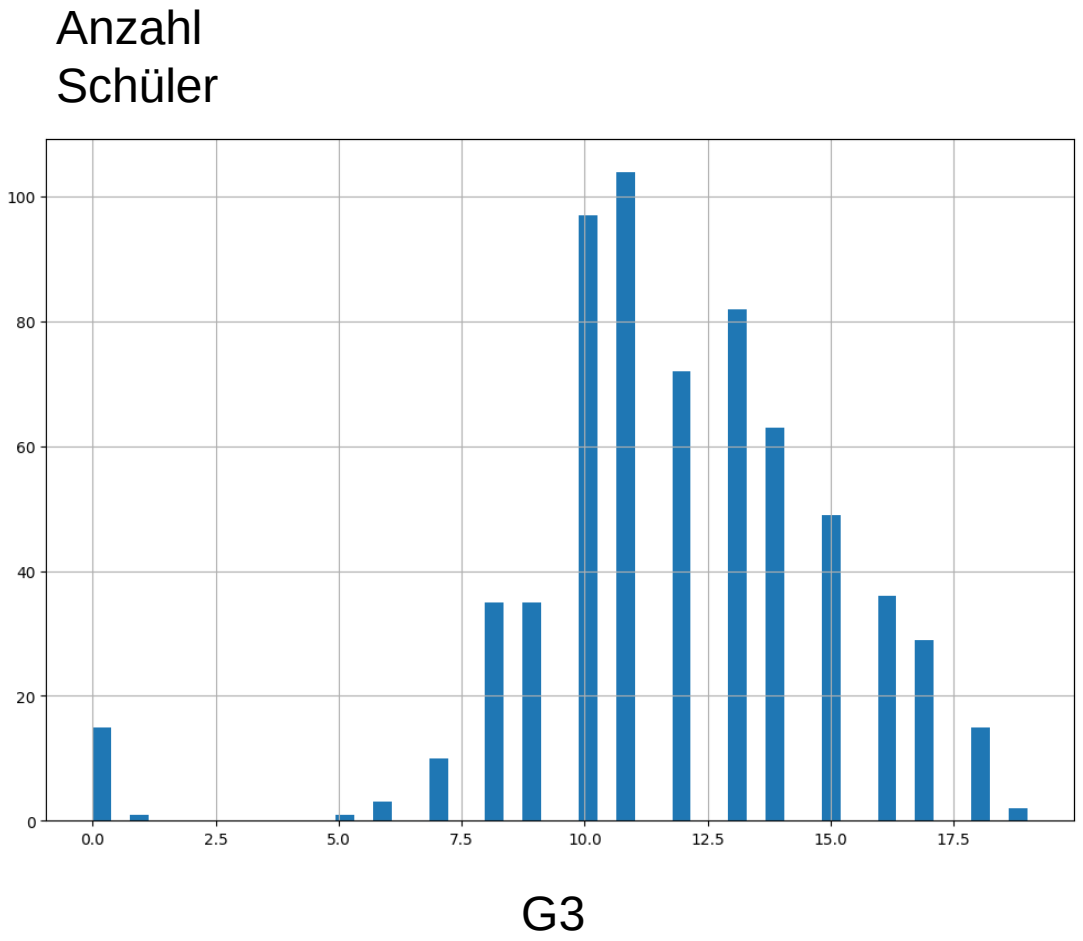
Quelle der Folie: Hahn-Schickard

Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

- Histogramme (hist())
  - Stellt die Häufigkeiten eines Merkmals grafisch dar
  - Gibt Aufschluss über die tatsächliche Verteilung (gleichverteilt, gaußverteilt, …)

- Gehen Sie zurück zum Notebook und beantworten Sie Frage 2 (d).



Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

- Berechnung des Korrelationskoeffizienten zwischen allen Merkmalen, insbesondere zur Zielgröße
  - Der Pearson-Korrelationskoeffizient liegt zwischen -1 und 1.
  -

$$r_{x,z} := \frac{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})(z_i - \bar{\boldsymbol{z}})}{\sqrt{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})^2 \sum_{i=1}^{m} (z_i - \bar{\boldsymbol{z}})^2}}$$

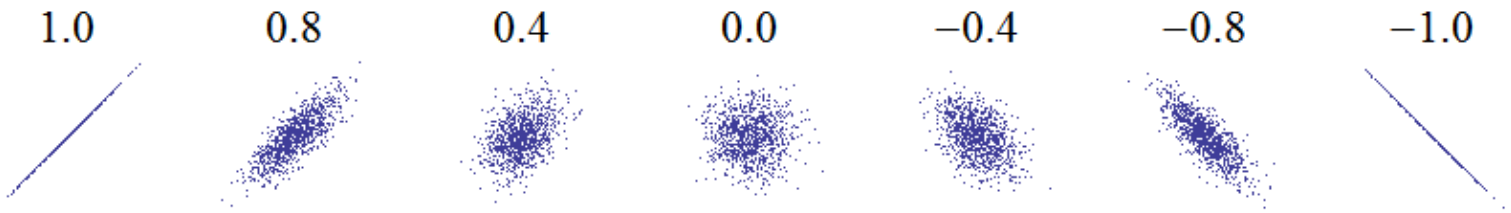
x_i und z_i sind einzelne Werte der Merkmale $\boldsymbol{x}$ und $\boldsymbol{z}$. $\bar{\boldsymbol{x}}$ und $\bar{\boldsymbol{z}}$ sind die Mittelwerte der beiden Merkmale.

Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

- Berechnung des Korrelationskoeffizienten zwischen allen Merkmalen, insbesondere zur Zielgröße
  - Der Pearson-Korrelationskoeffizient liegt zwischen -1 und 1.
  -

$$r_{x,z} := \frac{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})(z_i - \bar{\boldsymbol{z}})}{\sqrt{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})^2 \sum_{i=1}^{m} (z_i - \bar{\boldsymbol{z}})^2}}$$



x_i und z_i sind einzelne Werte der Merkmale $\boldsymbol{x}$ und $\boldsymbol{z}$. $\bar{\boldsymbol{x}}$ und $\bar{\boldsymbol{z}}$ sind die Mittelwerte der beiden Merkmale.

Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

- Berechnung des Korrelationskoeffizienten zwischen allen Merkmalen, insbesondere zur Zielgröße
  - Der Pearson-Korrelationskoeffizient liegt zwischen -1 und 1.
  -

$$r_{x,z} := \frac{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})(z_i - \bar{\boldsymbol{z}})}{\sqrt{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})^2 \sum_{i=1}^{m} (z_i - \bar{\boldsymbol{z}})^2}}$$



x_i und z_i sind einzelne Werte der Merkmale $\boldsymbol{x}$ und $\boldsymbol{z}$. $\bar{\boldsymbol{x}}$ und $\bar{\boldsymbol{z}}$ sind die Mittelwerte der beiden Merkmale.

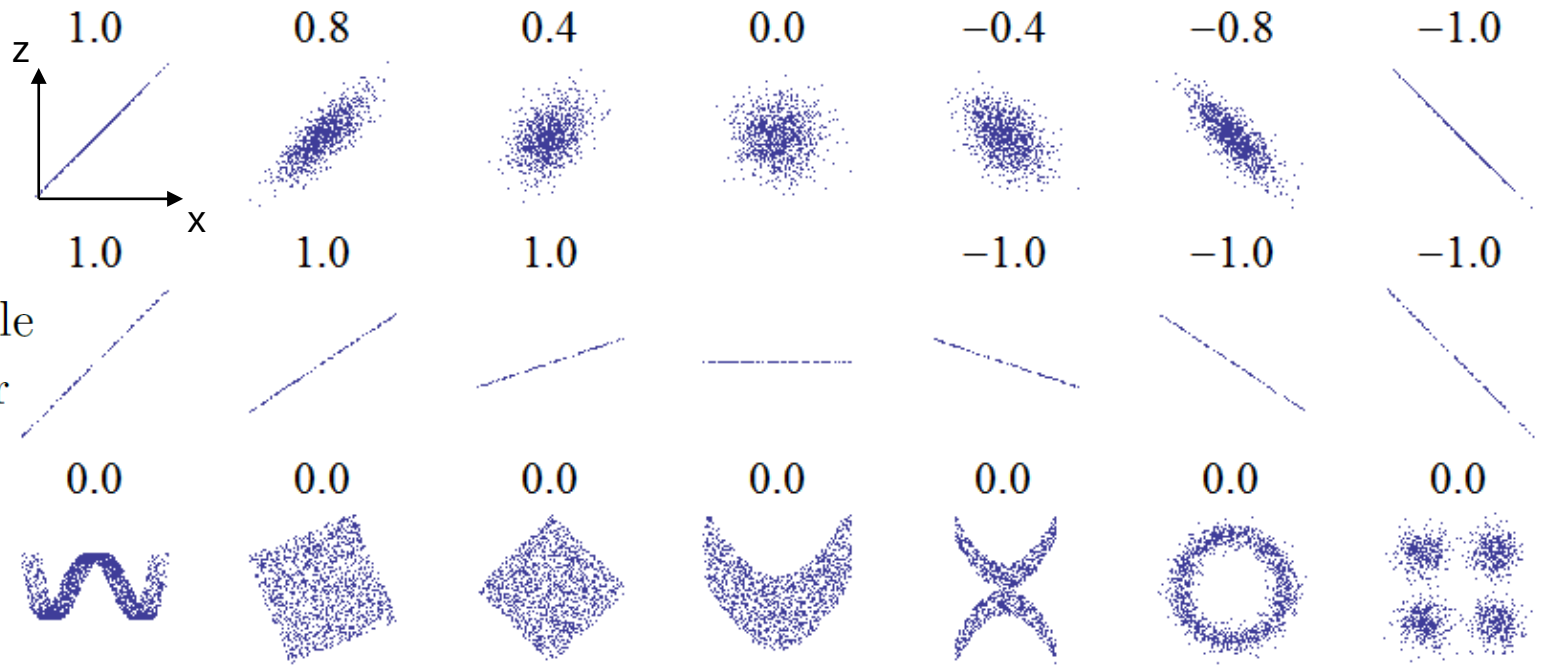
Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

- Berechnung des Korrelationskoeffizienten zwischen allen Merkmalen, insbesondere zur Zielgröße
  - Der Pearson-Korrelationskoeffizient liegt zwischen -1 und 1.
  - Der Korrelationskoeffizient erfasst ausschließlich lineare Korrelationen

$$r_{x,z} := \frac{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})(z_i - \bar{\boldsymbol{z}})}{\sqrt{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})^2 \sum_{i=1}^{m} (z_i - \bar{\boldsymbol{z}})^2}}$$

x_i und z_i sind einzelne Werte der Merkmale $\boldsymbol{x}$ und $\boldsymbol{z}$. $\bar{\boldsymbol{x}}$ und $\bar{\boldsymbol{z}}$ sind die Mittelwerte der beiden Merkmale.



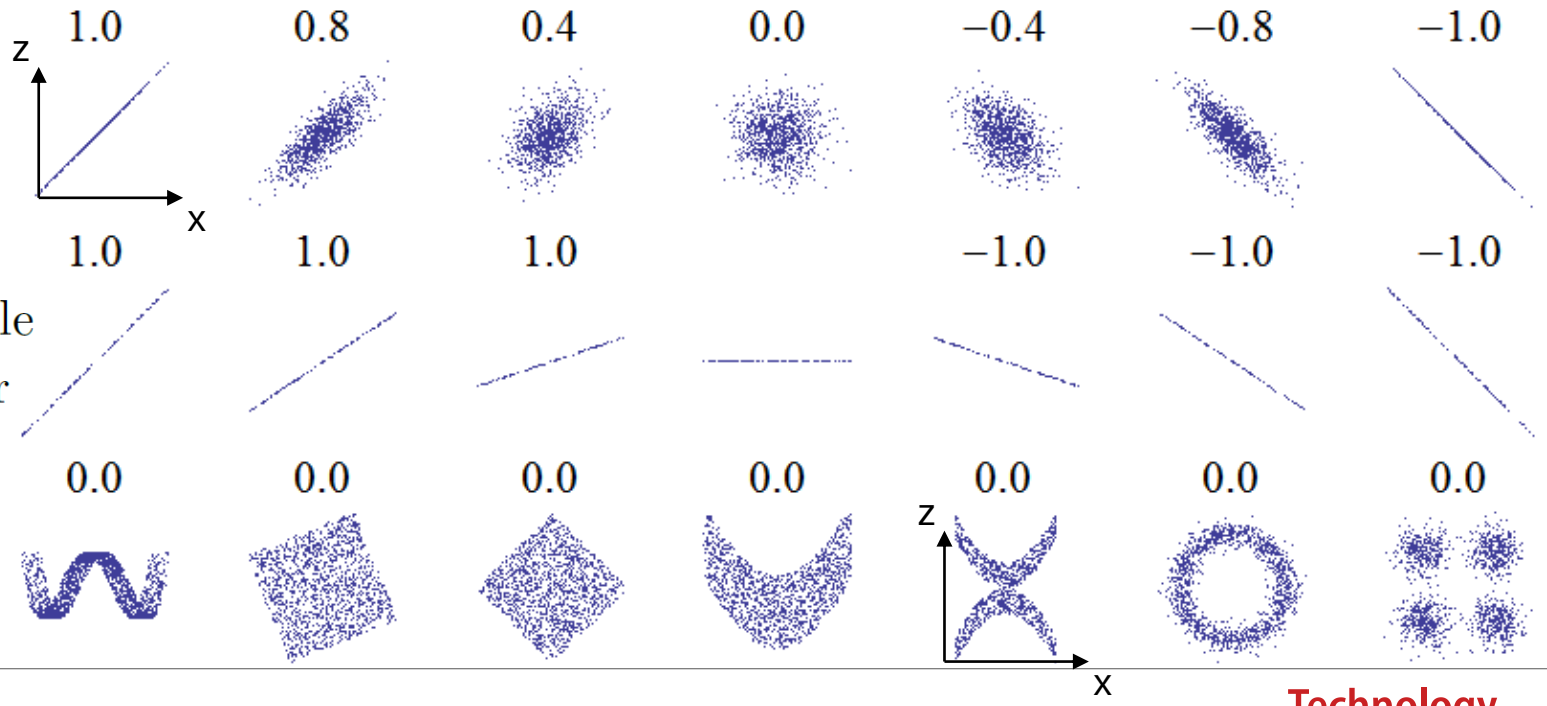
Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen

Suche nach Korrelationen

- Berechnung des Korrelationskoeffizienten zwischen allen Merkmalen, insbesondere zur Zielgröße
  - Der Pearson-Korrelationskoeffizient liegt zwischen -1 und 1.
  - Der Korrelationskoeffizient erfasst ausschließlich lineare Korrelationen

$$r_{x,z} := \frac{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})(z_i - \bar{\boldsymbol{z}})}{\sqrt{\sum_{i=1}^{m} (x_i - \bar{\boldsymbol{x}})^2 \sum_{i=1}^{m} (z_i - \bar{\boldsymbol{z}})^2}}$$

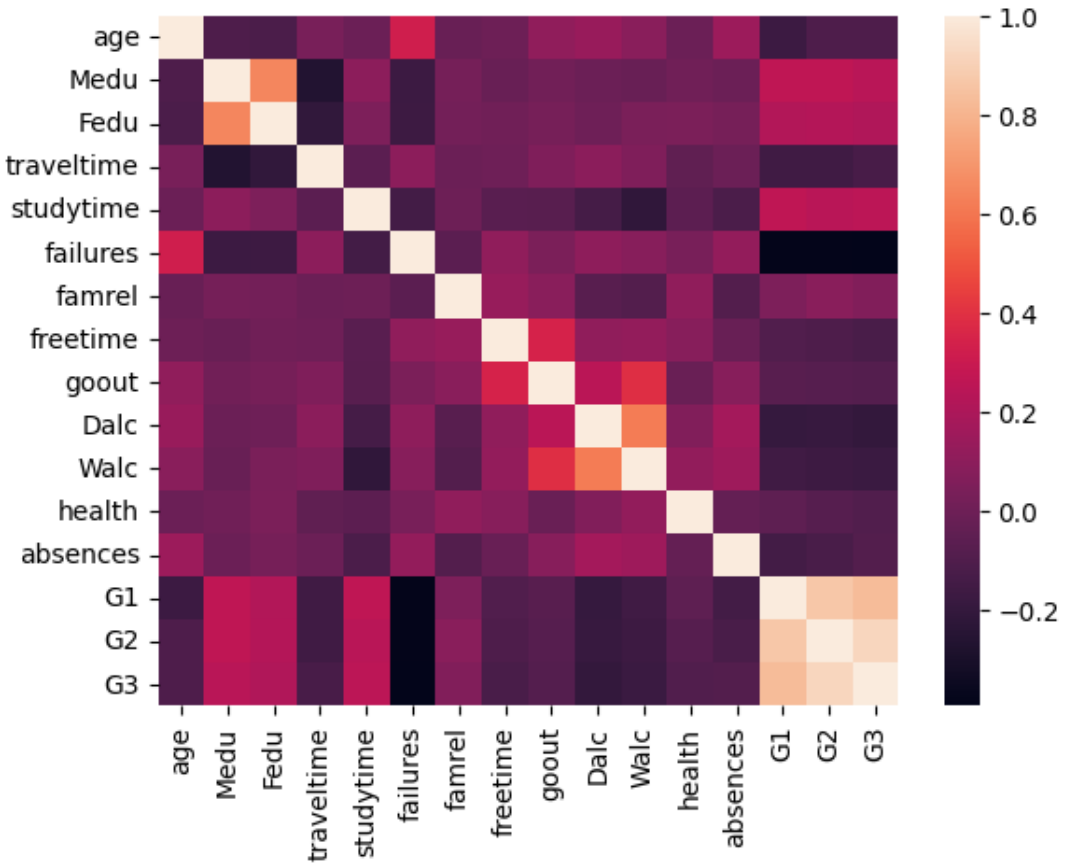
x_i und z_i sind einzelne Werte der Merkmale $\boldsymbol{x}$ und $\boldsymbol{z}$. $\bar{\boldsymbol{x}}$ und $\bar{\boldsymbol{z}}$ sind die Mittelwerte der beiden Merkmale.



Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen
Suche nach Korrelationen

Pandas Methode: corr()

corr_matrix = dataframe.corr()



Erkunde und visualisiere die Daten, um Erkenntnisse zu gewinnen
Suche nach Korrelationen

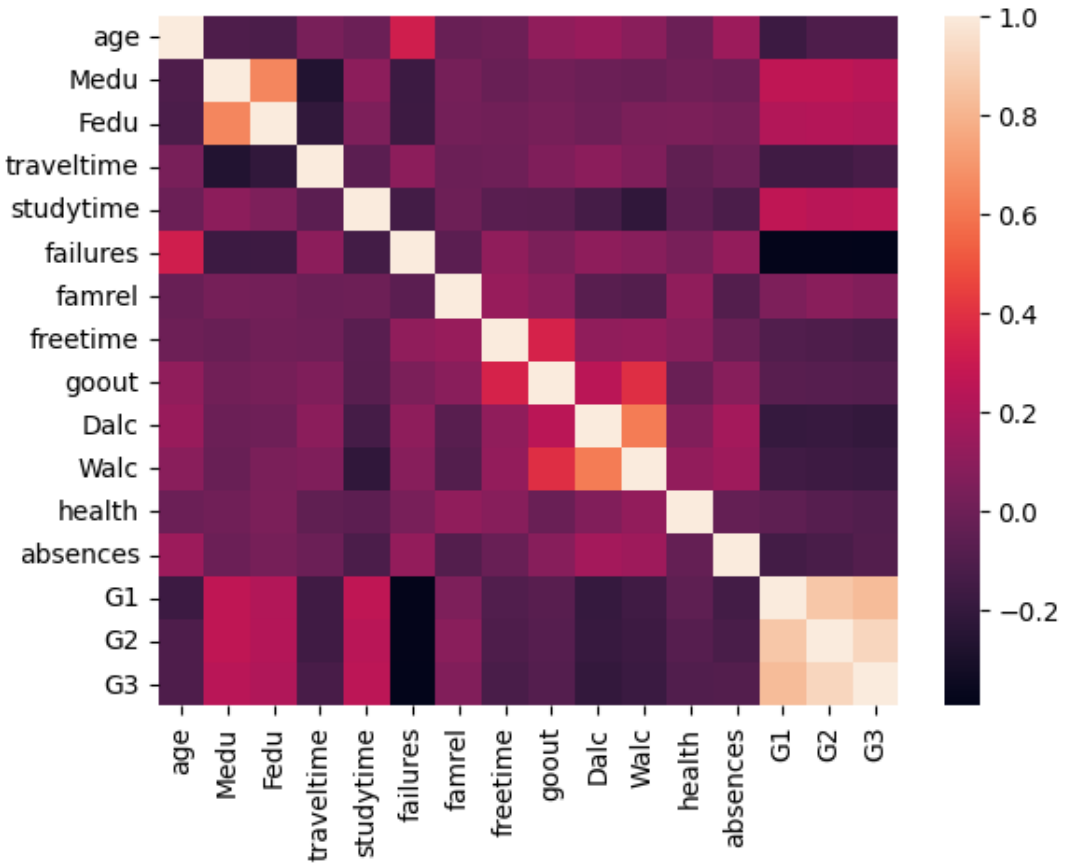
Pandas Methode: corr()

corr_matrix = dataframe.corr()

Seaborn:

- https://seaborn.pydata.org/
- Basiert auf matplotlib

seaborn.heatmap(corr_matrix)



Erstellen Sie einen Testdatensatz

Wichtig!

- Bevor Sie sich den Datensatz im Detail anschauen, trennen Sie diesen in zwei disjunkte Teile:
  - Trainingsdatensatz (ca. 70 % der Daten) trainiert das Machine Learning Modell
  - Testdatensatz (ca. 30 % der Daten) testet das Machine Learning Modell

- Bei sehr großen Datensätzen (> 1 Mio. gelabelte Daten), darf der Testdatensatz auch kleiner ausfallen (5 %)

Erstellen Sie einen Testdatensatz

Wichtig!

- Bevor Sie sich den Datensatz im Detail anschauen, trennen Sie diesen in zwei disjunkte Teile:
  - Trainingsdatensatz (ca. 70 % der Daten) trainiert das Machine Learning Modell
  - Testdatensatz (ca. 30 % der Daten) testet das Machine Learning Modell

- Bei sehr großen Datensätzen (> 1 Mio. gelabelte Daten), darf der Testdatensatz auch kleiner ausfallen (5 %)

Wichtig!

- Testdatensatz nicht weiter anschauen, sondern wegschließen und vergessen… ;-)

- Test auf Testdaten darf nur **einmal** erfolgen, da man sonst auf dem Testdatensatz optimiert

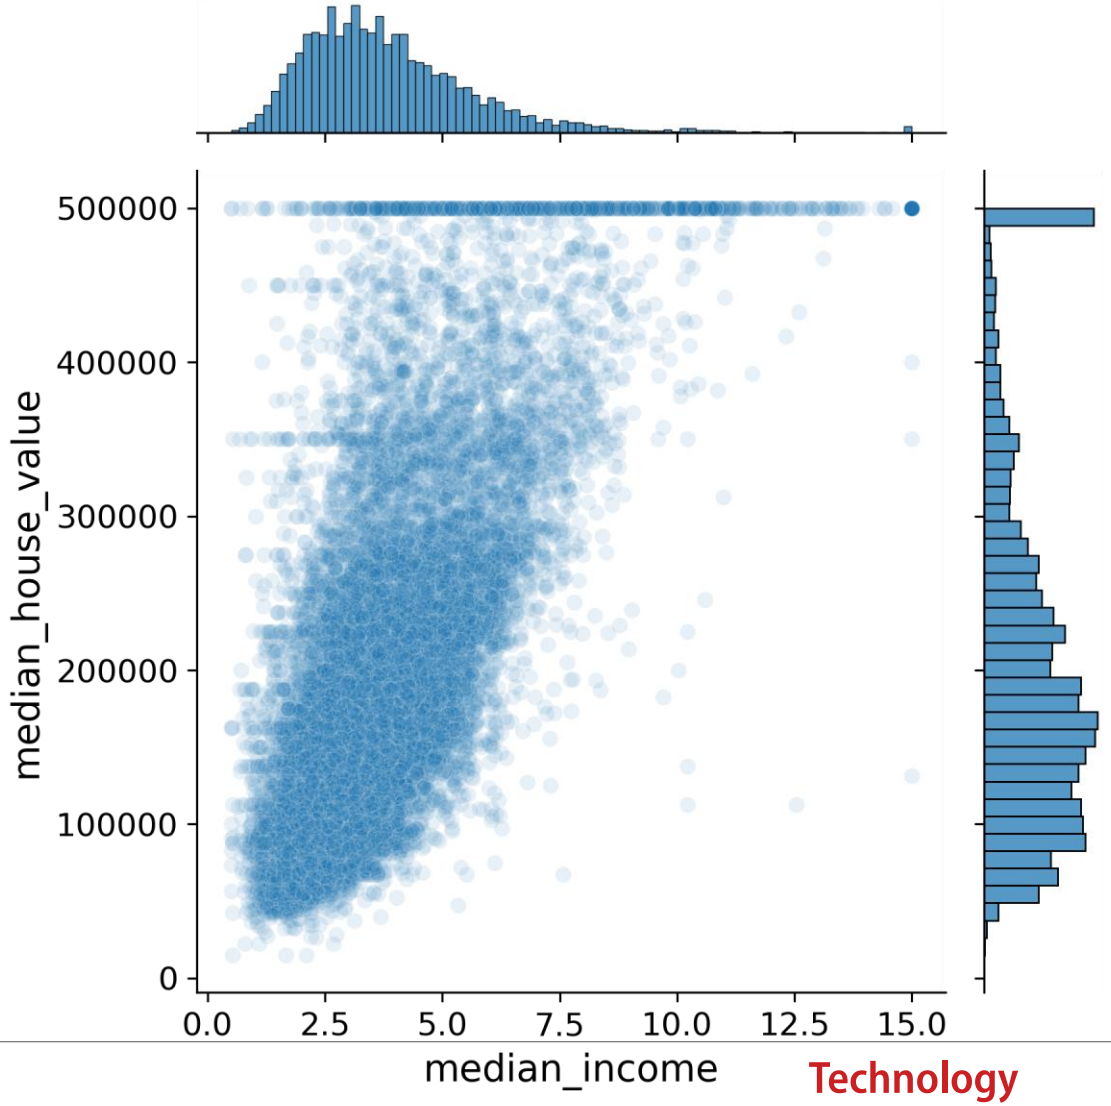
Erkunde und visualisiere die Trainingsdaten

Streudiagramme

- **Streudiagramme** vergleichen zwei Merkmale miteinander
- Zusätzliche **Randdiagramme** veranschaulichen Beziehungen zwischen den zwei Merkmalen

Bild

- Bildmitte zeigt ein Streudiagramm
- Randdiagramme zeigen Projektionen der zwei Merkmale in Form von Histogrammen



Erkunde und visualisiere die Trainingsdaten

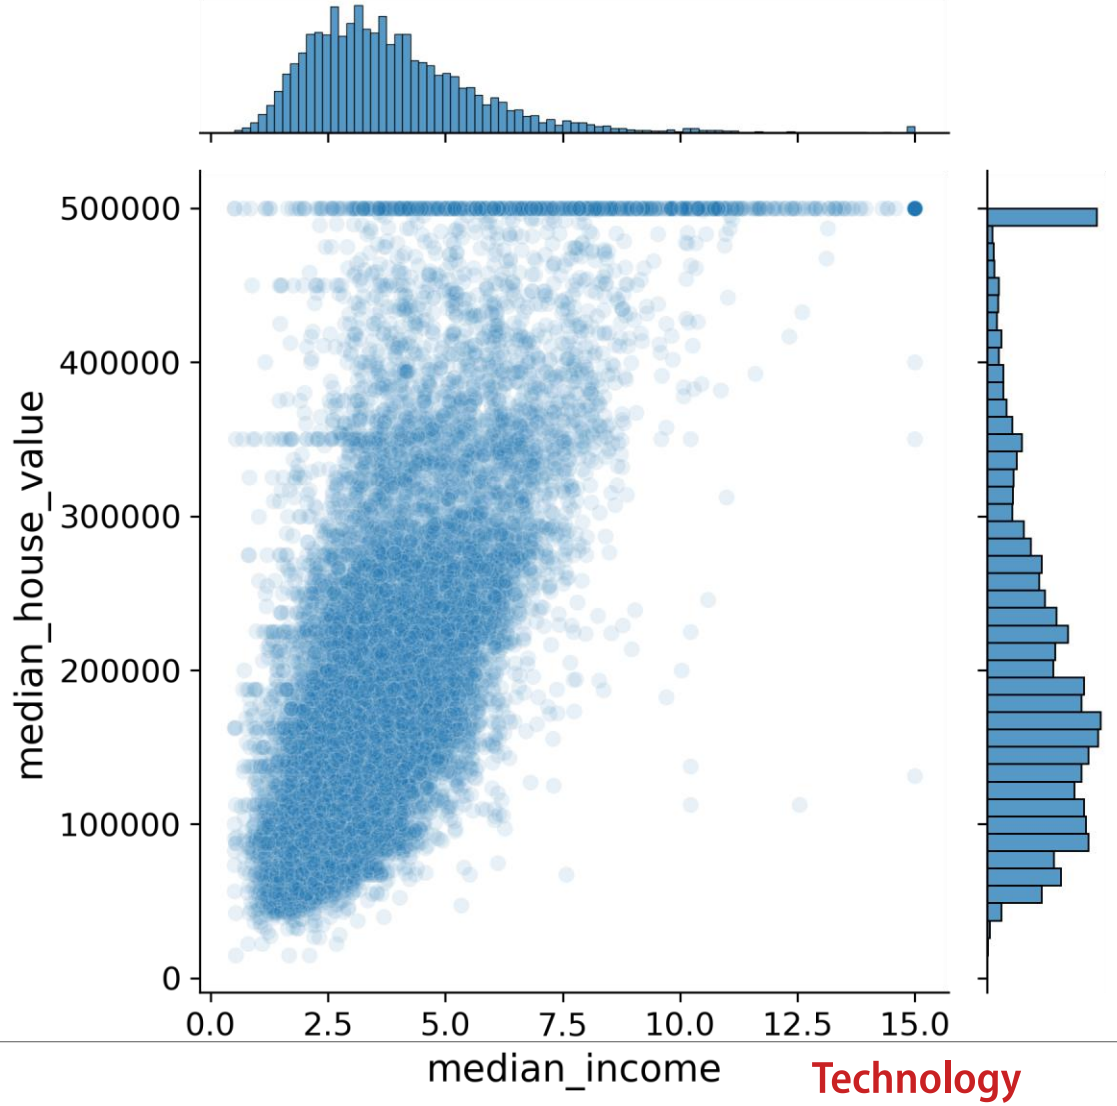
Streudiagramme

- **Streudiagramme** vergleichen zwei Merkmale miteinander
- Zusätzliche **Randdiagramme** veranschaulichen Beziehungen zwischen den zwei Merkmalen

Bild

- Bildmitte zeigt ein Streudiagramm
- Randdiagramme zeigen Projektionen der zwei Merkmale in Form von Histogrammen

- seaborn.jointplot()

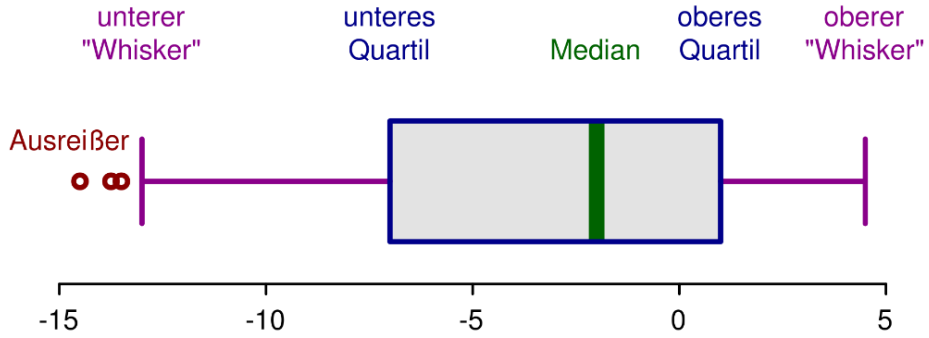


Erkunde und visualisiere die Trainingsdaten

Boxplot

Eigenschaften:

- Verrät Lage und Streuungsmaß einer Verteilung
- Ausreißererkennung
  (z.B. 1.5 x Interquartilsabstand IQA)



https://de.wikipedia.org/wiki/Box-Plot

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle der Folie: Hahn-Schickard

Erkunde und visualisiere die Trainingsdaten

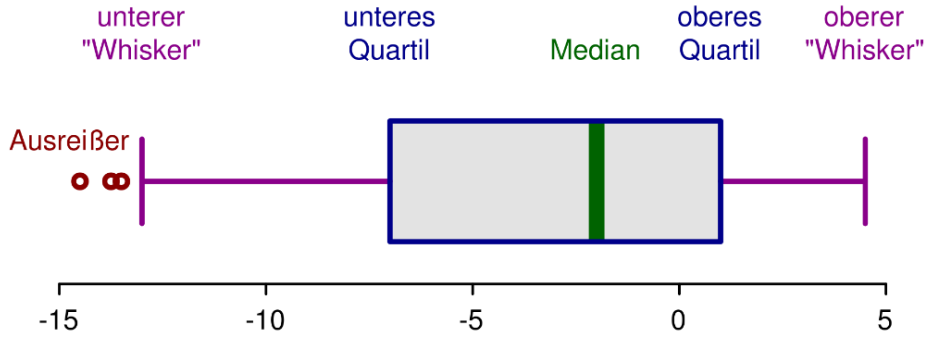
Boxplot

Eigenschaften:

- Verrät Lage und Streuungsmaß einer Verteilung
- Ausreißererkennung
  (z.B. 1.5 x Interquartilsabstand IQA)

Die Grundelemente eines Boxdiagramms:

- einem Kasten – unteren & oberen Quartil
- einem Strich darin – Median
- zwei Antennen (Whiskers) – Minimum & Maximum
-



https://de.wikipedia.org/wiki/Box-Plot

Erkunde und visualisiere die Trainingsdaten

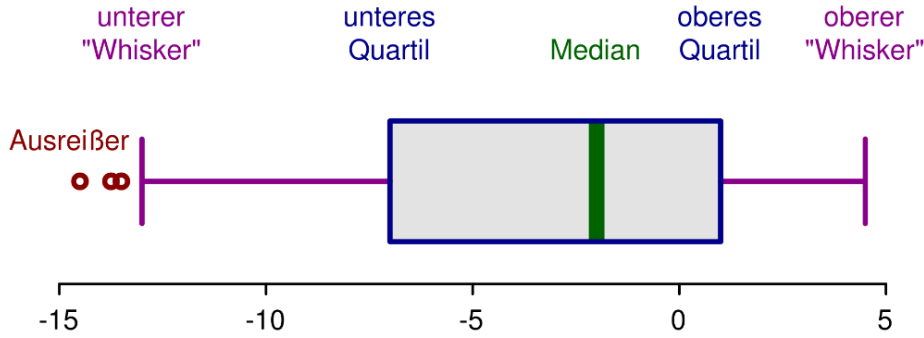
Boxplot

Eigenschaften:

- Verrät Lage und Streuungsmaß einer Verteilung
- Ausreißererkennung
  (z.B. 1.5 x Interquartilsabstand IQA)

Die Grundelemente eines Boxdiagramms:

- einem Kasten – unteren & oberen Quartil
- einem Strich darin – Median
- zwei Antennen (Whiskers) – Minimum & Maximum
- die 5 Quantile:
  - Median: Wert genau in der Mitte aller Daten
  - Unteres & oberes Quartil: 25% der Verteilung unter/über dem Median
  - Min & Max: Min & Max, ohne Ausreißer; oder 2,5 %- und 97,5 %-Quantil der Daten

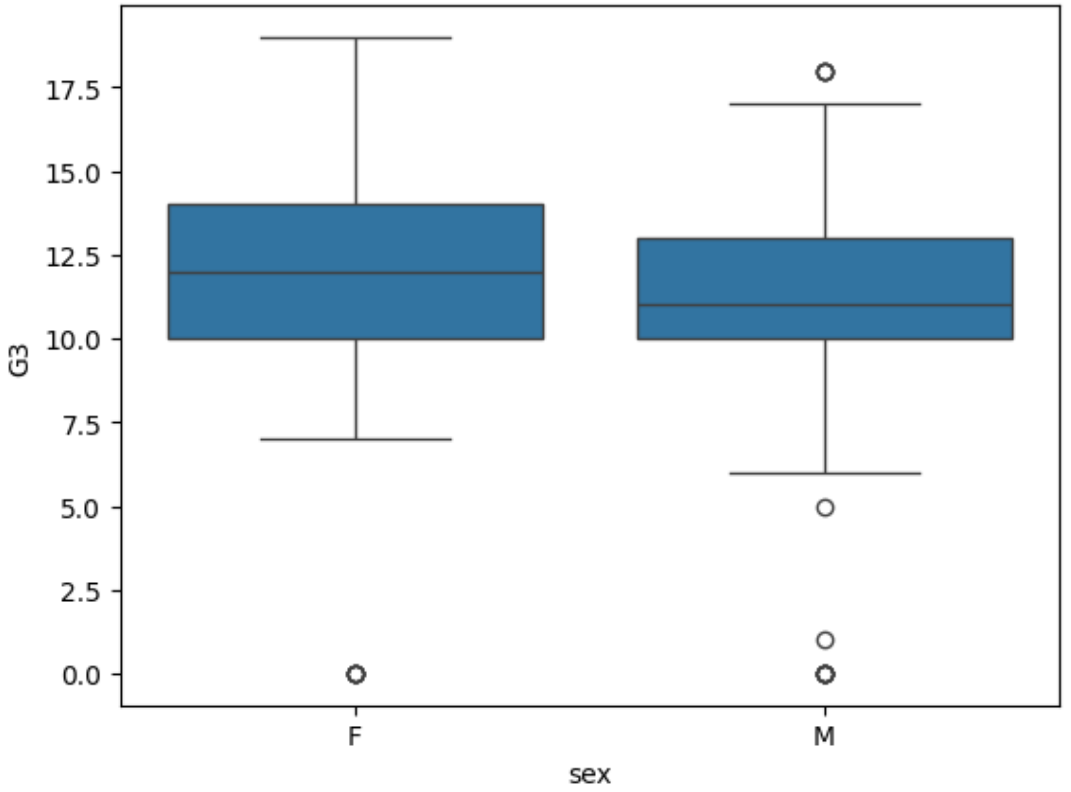


https://de.wikipedia.org/wiki/Box-Plot

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Quelle der Folie: Hahn-Schickard

Übung: Notebook HCAI_02_Übung_Notebook.ipynb

Gehen Sie zurück zum Notebook und beantworten Sie die Frage 2 (e) und (f).



Fragen?

- Histogramm
- Korrelationen
- Streudiagramme
- Boxplot

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
- Training von Machine Learning Modellen mit und ohne Überwachung

- Grundlegende Visualisierungsmöglichkeiten von Daten

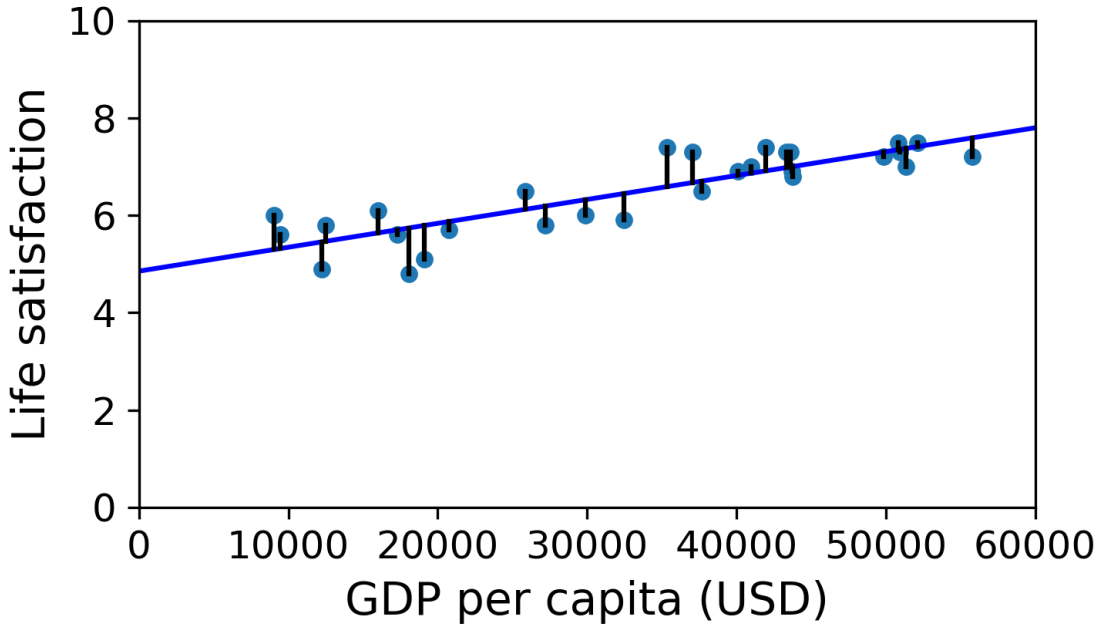
- **Wie gut ist das trainierte Machine Learning Modell?**

- Machine Learning und Deep Learning Algorithmen
  - Logistische Regression, Entscheidungsbäume, neuronale Netze

- Wie funktioniert ChatGPT & Co.?

Wie gut ist mein Modell?

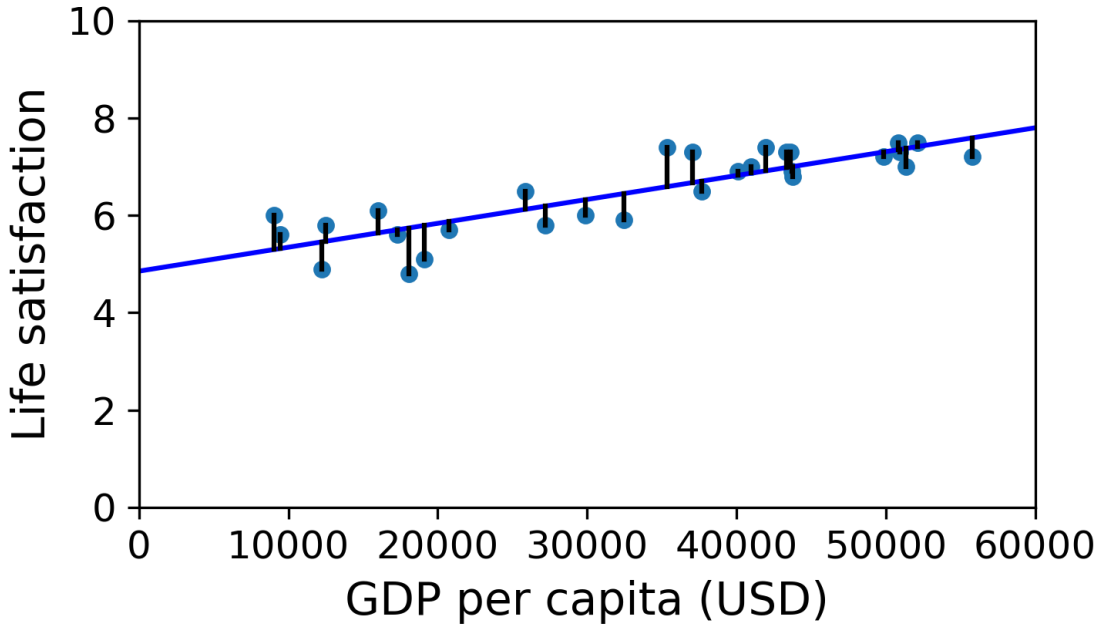
- Metriken für …
  - Regressionsmodelle:
    - Mittlere Quadratische Fehler
    - Mittlere Absolute Fehler
    - Root mean squared Error (RMSE)
  -
    -
    -
-



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

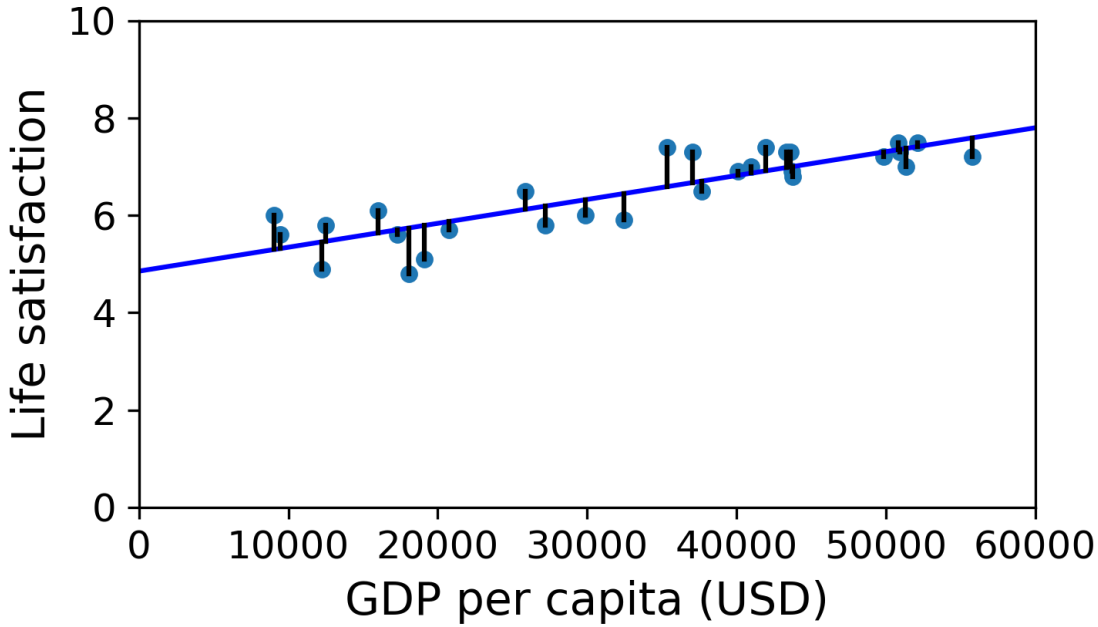
Wie gut ist mein Modell?

- Metriken für …
  - Regressionsmodelle:
    - Mittlere Quadratische Fehler
    - Mittlere Absolute Fehler
    - Root mean squared Error (RMSE)
  - Klassifikationsmodelle:
    - Konfusionsmatrix
    - Genauigkeit



Wie gut ist mein Modell?

- Metriken für …
  - Regressionsmodelle:
    - Mittlere Quadratische Fehler
    - Mittlere Absolute Fehler
    - Root mean squared Error (RMSE)
  - Klassifikationsmodelle:
    - Konfusionsmatrix
    - Genauigkeit



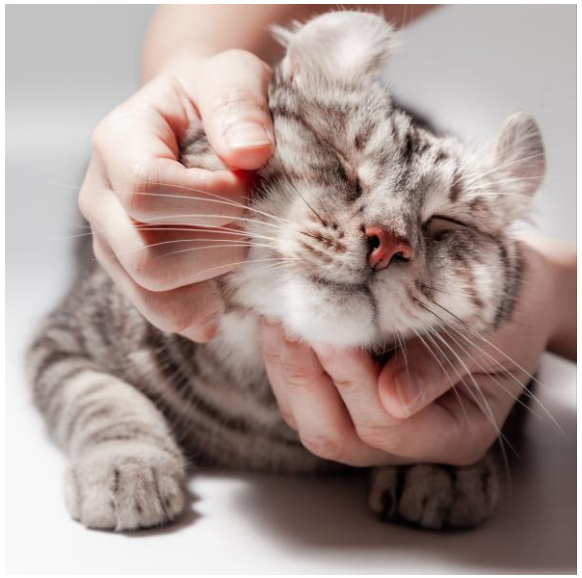
- Hinweis: In diesem Modul arbeiten wir nicht mit unüberwachtem Lernen und Reinforcement Learning

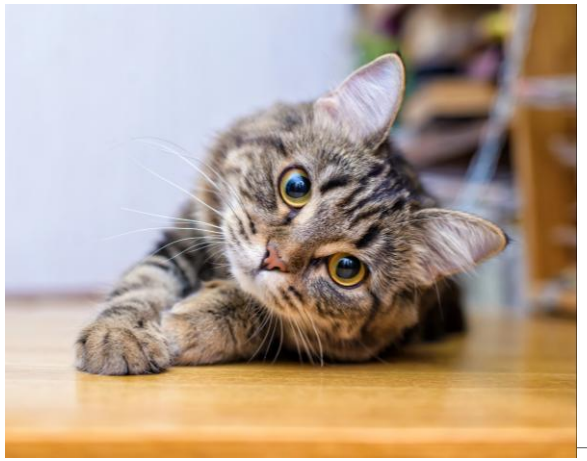
Überwachtes Lernen - Klassifikation

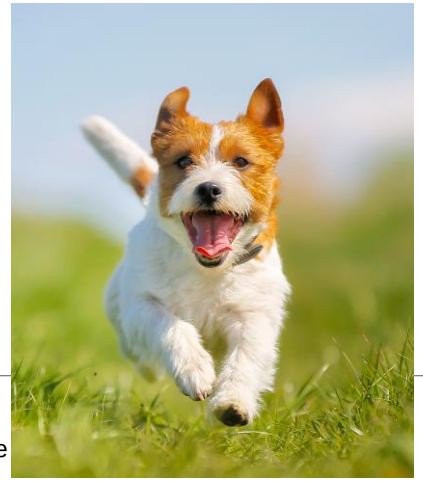
Klassifizieren Sie alle Hauskatzen













Making Friends with Machine Learning: The Entire Course, 1:57:30, https://www.youtube.com/watch?v=1vkb7BCMQd0&list=PLRKtJ4IpxJpDsOT_8YDREJrO8cQUtPUVg&t=8s

Überwachtes Lernen - Klassifikation

Konfusionsmatrix

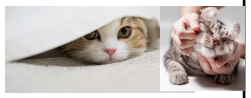
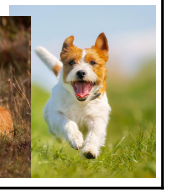
Perfekter Klassifikator:









		ML system says	
		Cat	**No Cat**
Truth	**Cat**	4   	0
	No Cat	0	2  

Making Friends with Machine Learning: The Entire Course, 1:57:30, https://www.youtube.com/watch?v=1vkb7BCMQd0&list=PLRKtJ4IpxJpDsOT_8YDREJrO8cQUtPUVg&t=8s

Überwachtes Lernen - Klassifikation

Konfusionsmatrix









		ML system says	
		Cat	**No Cat**
Truth	**Cat**	Richtig	Falsch
	No Cat	Falsch	Richtig

Überwachtes Lernen - Klassifikation

Konfusionsmatrix









		ML system says	
		Cat	**No Cat**
Truth	**Cat**	Positive	Negative
	No Cat	Positive	Negative

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Making Friends with Machine Learning: The Entire Course, 1:57:30, https://www.youtube.com/watch?v=1vkb7BCMQd0&list=PLRKtJ4IpxJpDsOT_8YDREJrO8cQUtPUVg&t=8s

Überwachtes Lernen - Klassifikation

Konfusionsmatrix









		ML system says	
		Cat	**No Cat**
Truth	**Cat**	Richtig Positive	Falsch Negative
	No Cat	Falsch Positive	Richtig Negative

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Making Friends with Machine Learning: The Entire Course, 1:57:30, https://www.youtube.com/watch?v=1vkb7BCMQd0&list=PLRKtJ4IpxJpDsOT_8YDREJrO8cQUtPUVg&t=8s

Überwachtes Lernen - Klassifikation

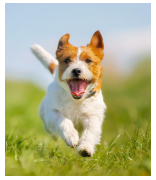
Konfusionsmatrix und Genauigkeit









		ML system says	
		Cat	**No Cat**
Truth	**Cat**	3   	1 
	No Cat	1 	1 

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Making Friends with Machine Learning: The Entire Course, 1:57:30, https://www.youtube.com/watch?v=1vkb7BCMQd0&list=PLRKtJ4IpxJpDsOT_8YDREJrO8cQUtPUVg&t=8s

Überwachtes Lernen - Klassifikation

Konfusionsmatrix und Genauigkeit

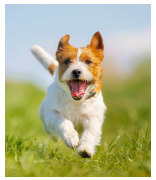
Genauigkeit = 4/6 = 66 %









		ML system says	
		Cat	**No Cat**
Truth	**Cat**	3   	1 
	No Cat	1 	1 

Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
- Training von Machine Learning Modellen mit und ohne Überwachung

- Grundlegende Visualisierungsmöglichkeiten von Daten

- Wie gut ist das trainierte Machine Learning Modell?

- **Machine Learning und Deep Learning Algorithmen**
  - **Logistische Regression, Entscheidungsbäume, neuronale Netze**

- Wie funktioniert ChatGPT & Co.?

Machine Learning und Deep Learning Modelle

Machine Learning

- Lineare Regression
- Logistische Regression
- Entscheidungsbäume
- …

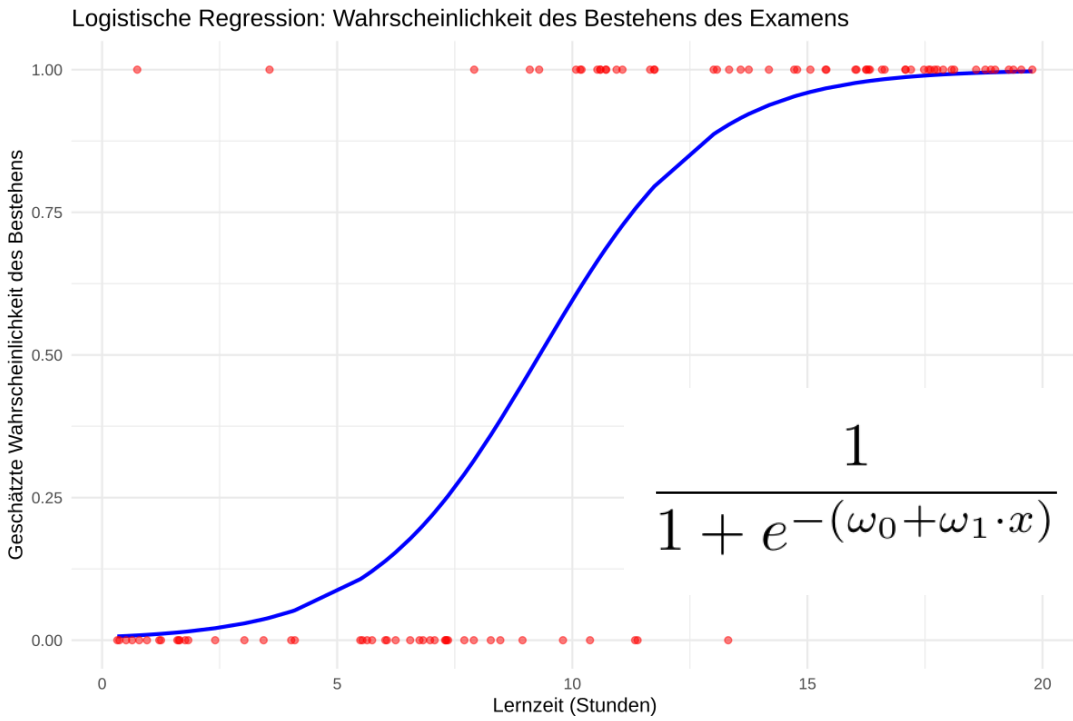
Deep Learning

- Tiefe Neuronale Netze

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Machine Learning und Deep Learning Modelle
Logistische Regression

- Modell für Ja/Nein-Entscheidungen (binäre **Klassifikation**)
- Statt einer Geraden (wie bei linearer Regression) nutzt das Modell eine Sigmoid-Funktion
-
-

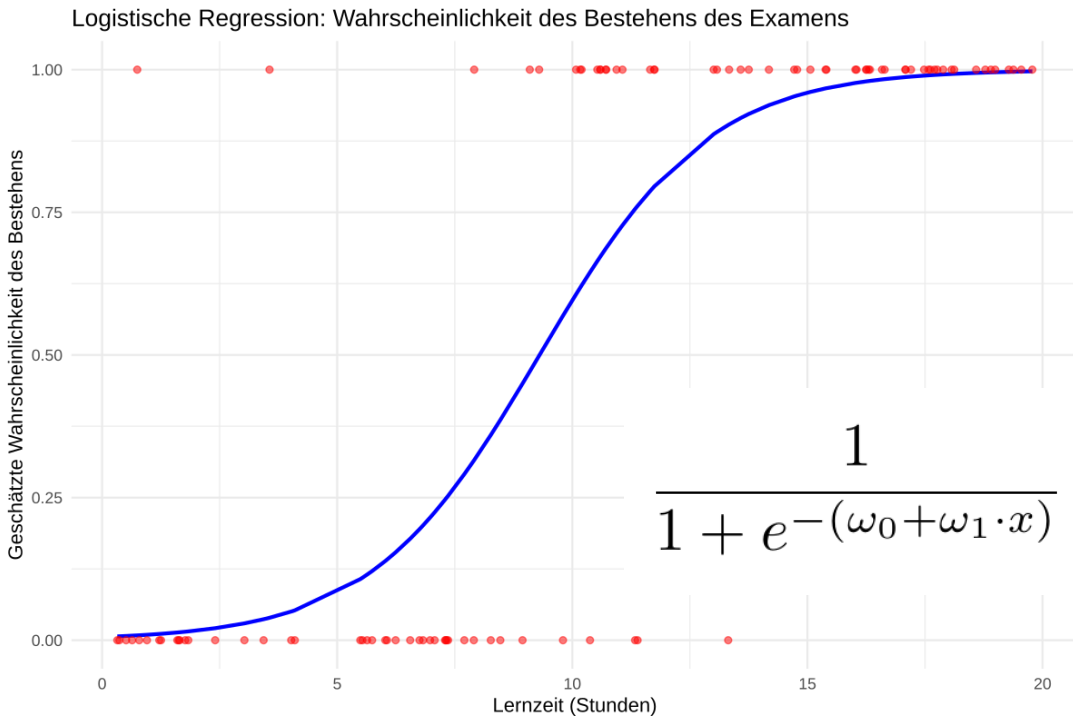


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: https://de.wikipedia.org/wiki/Logistische_Regression

Machine Learning und Deep Learning Modelle
Logistische Regression

- Modell für Ja/Nein-Entscheidungen (binäre **Klassifikation**)
- Statt einer Geraden (wie bei linearer Regression) nutzt das Modell eine Sigmoid-Funktion
- Nutzt Merkmale (z. B. Alter, Einkommen, Lernzeit) zur Vorhersage von Wahrscheinlichkeiten
-



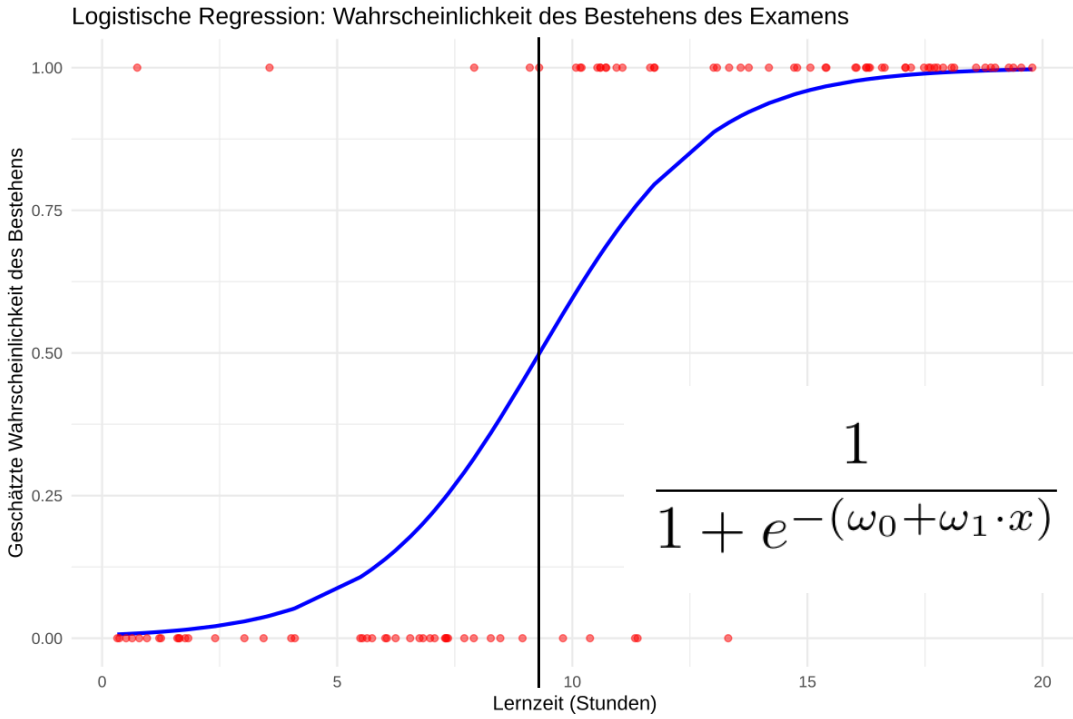
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: https://de.wikipedia.org/wiki/Logistische_Regression

Machine Learning und Deep Learning Modelle
Logistische Regression

- Modell für Ja/Nein-Entscheidungen (binäre **Klassifikation**)
- Statt einer Geraden (wie bei linearer Regression) nutzt das Modell eine Sigmoid-Funktion
- Nutzt Merkmale (z. B. Alter, Einkommen, Lernzeit) zur Vorhersage von Wahrscheinlichkeiten

- Ergebnis: Wahrscheinlichkeit zwischen 0 und 1 → Entscheidung durch Schwellwert (z. B. 0.5)



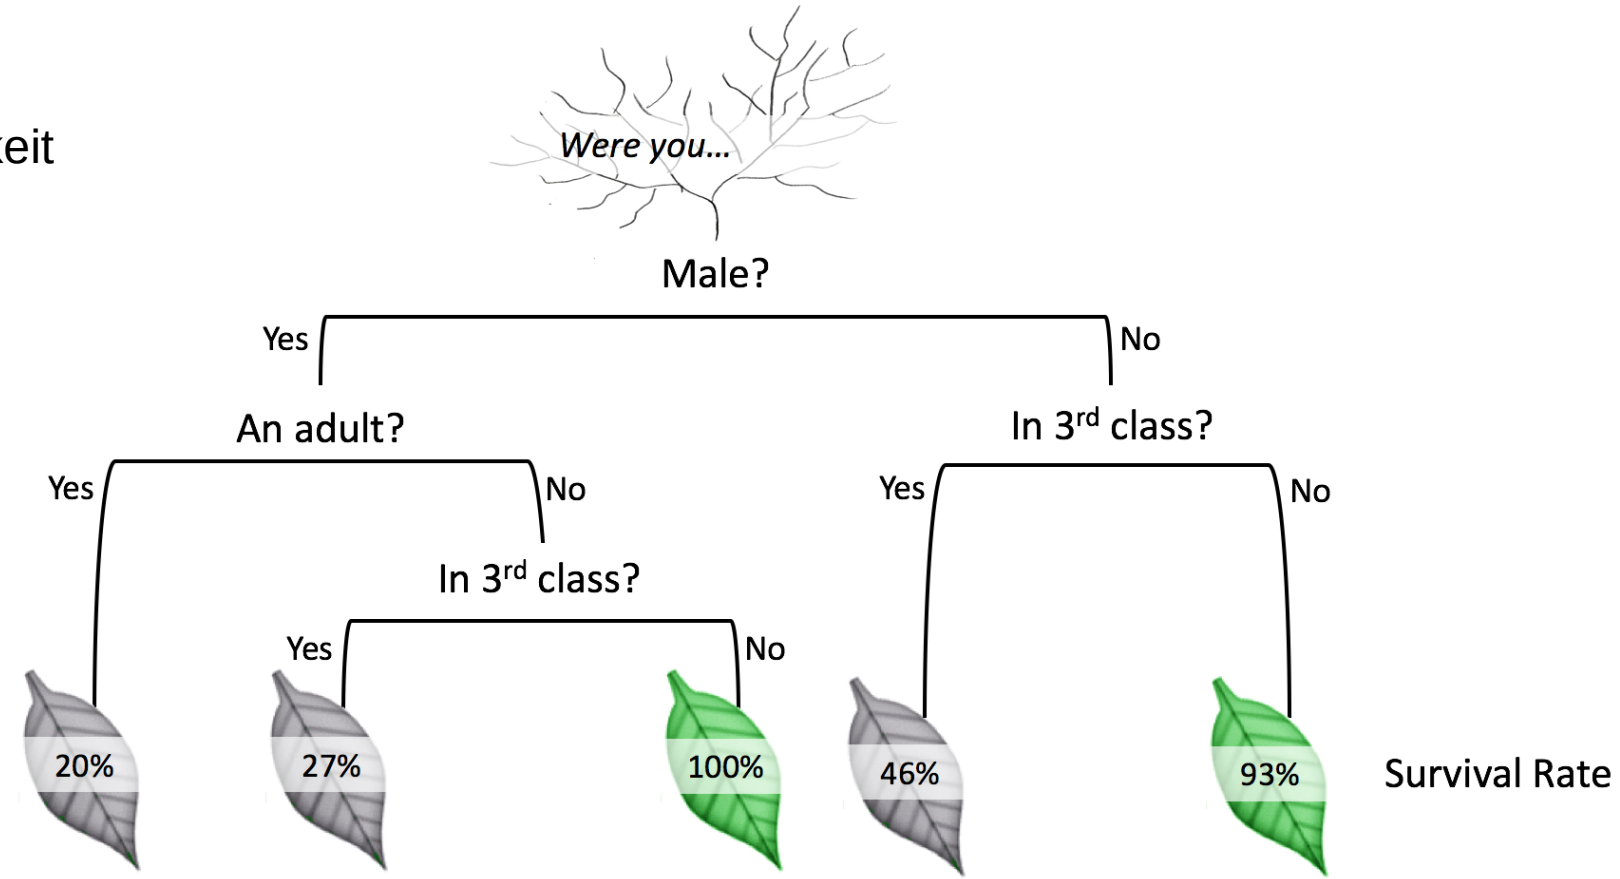
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: https://de.wikipedia.org/wiki/Logistische_Regression

Machine Learning und Deep Learning Modelle

Entscheidungsbaum

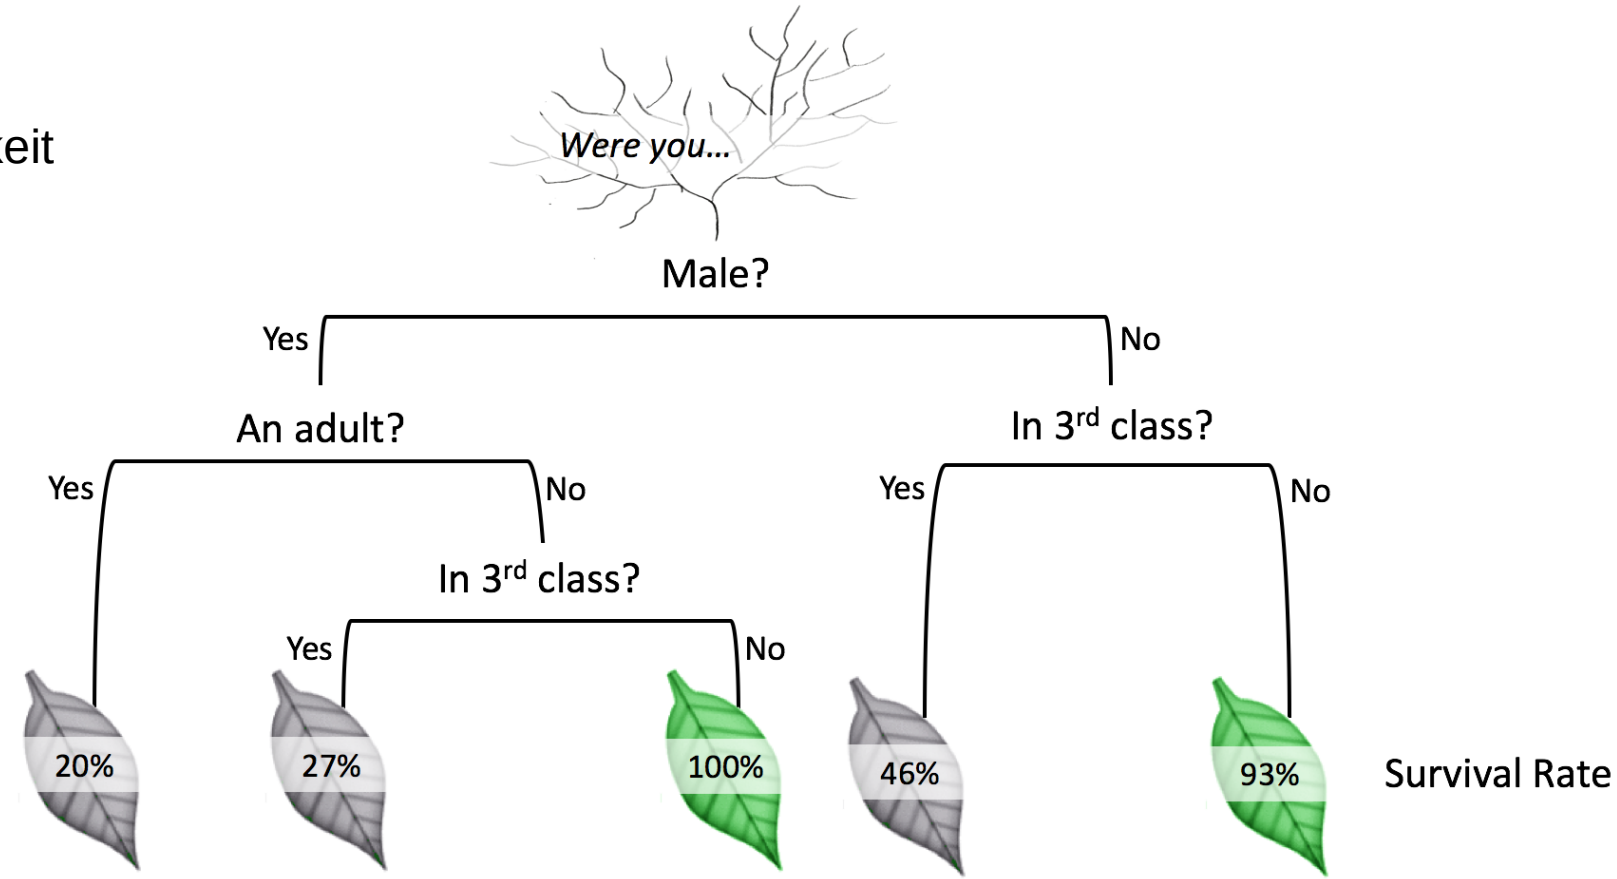
- Decision Tree
- Überlebenswahrscheinlichkeit auf der Titanic
- Modell wird aus Trainingsdaten gelernt
-



Machine Learning und Deep Learning Modelle

Entscheidungsbaum

- Decision Tree
- Überlebenswahrscheinlichkeit auf der Titanic
- Modell wird aus Trainingsdaten gelernt
- Geeignet für Regression und Klassifikation

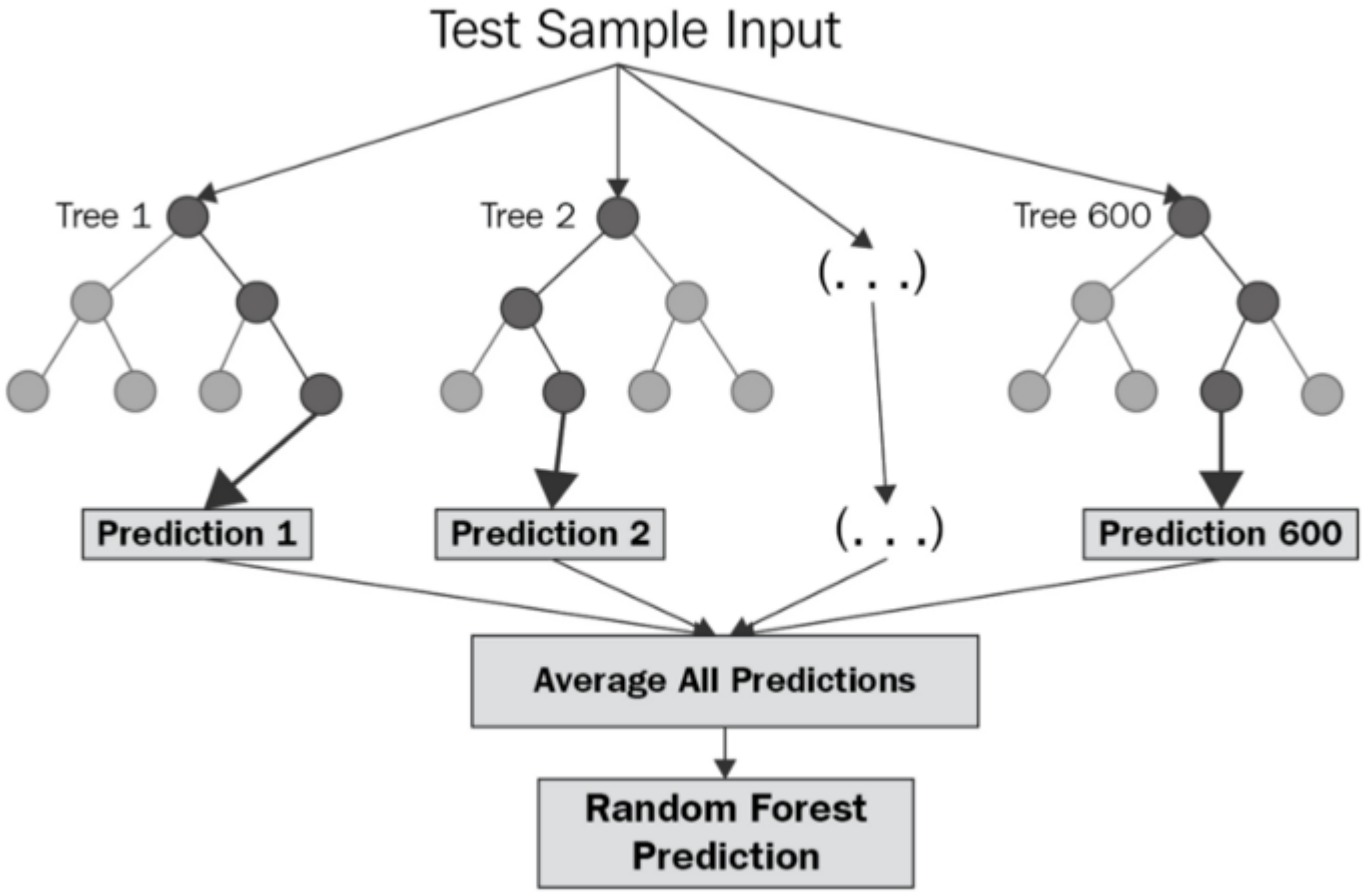


Machine Learning und Deep Learning Modelle

Wald von Entscheidungsbäumen

Random Forest

- RandomForestRegressor
- RandomForestClassifier

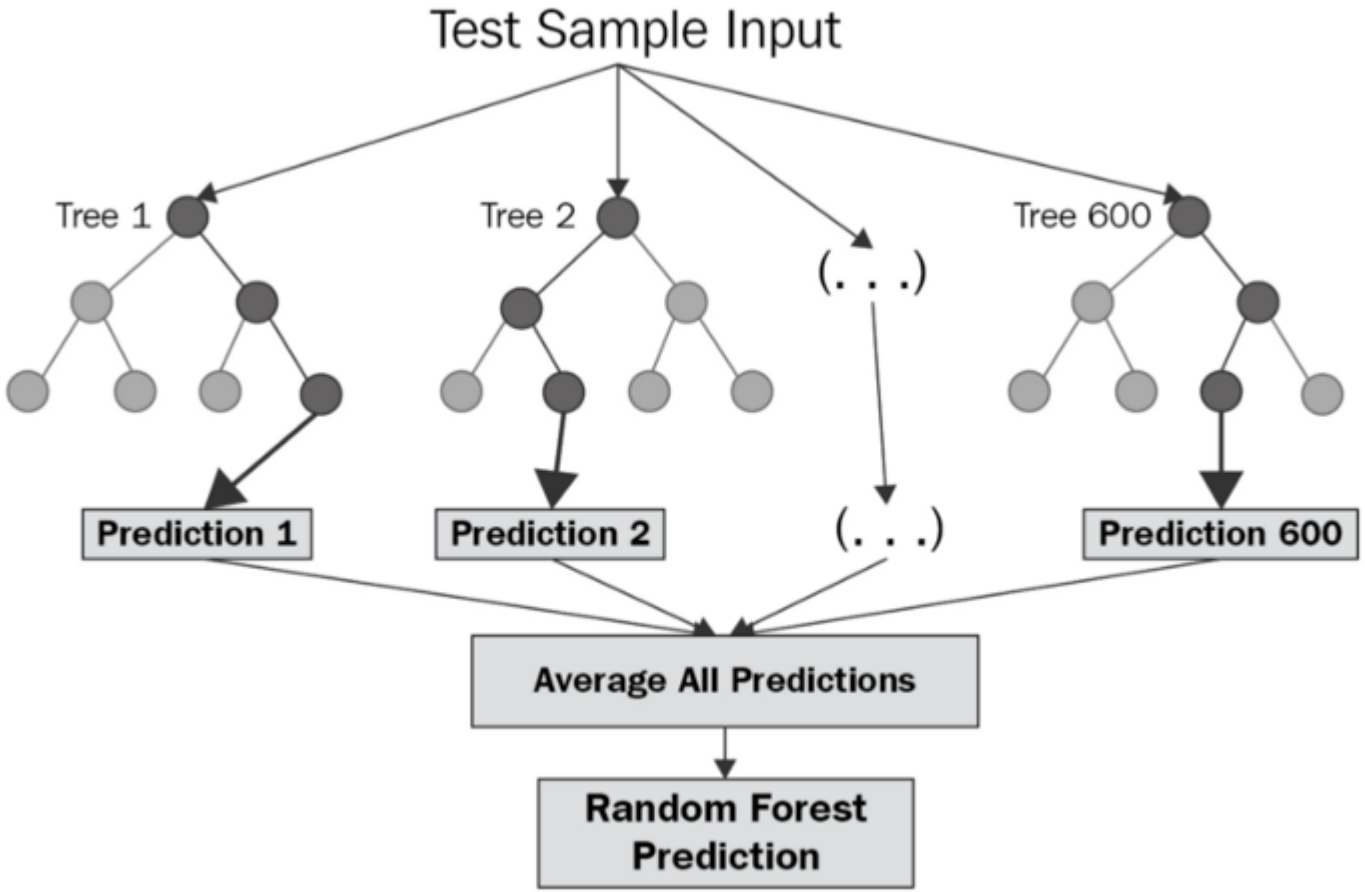


Machine Learning und Deep Learning Modelle

Wald von Entscheidungsbäumen

Random Forest

- RandomForestRegressor
- RandomForestClassifier



Gradient Boosted Decision Trees

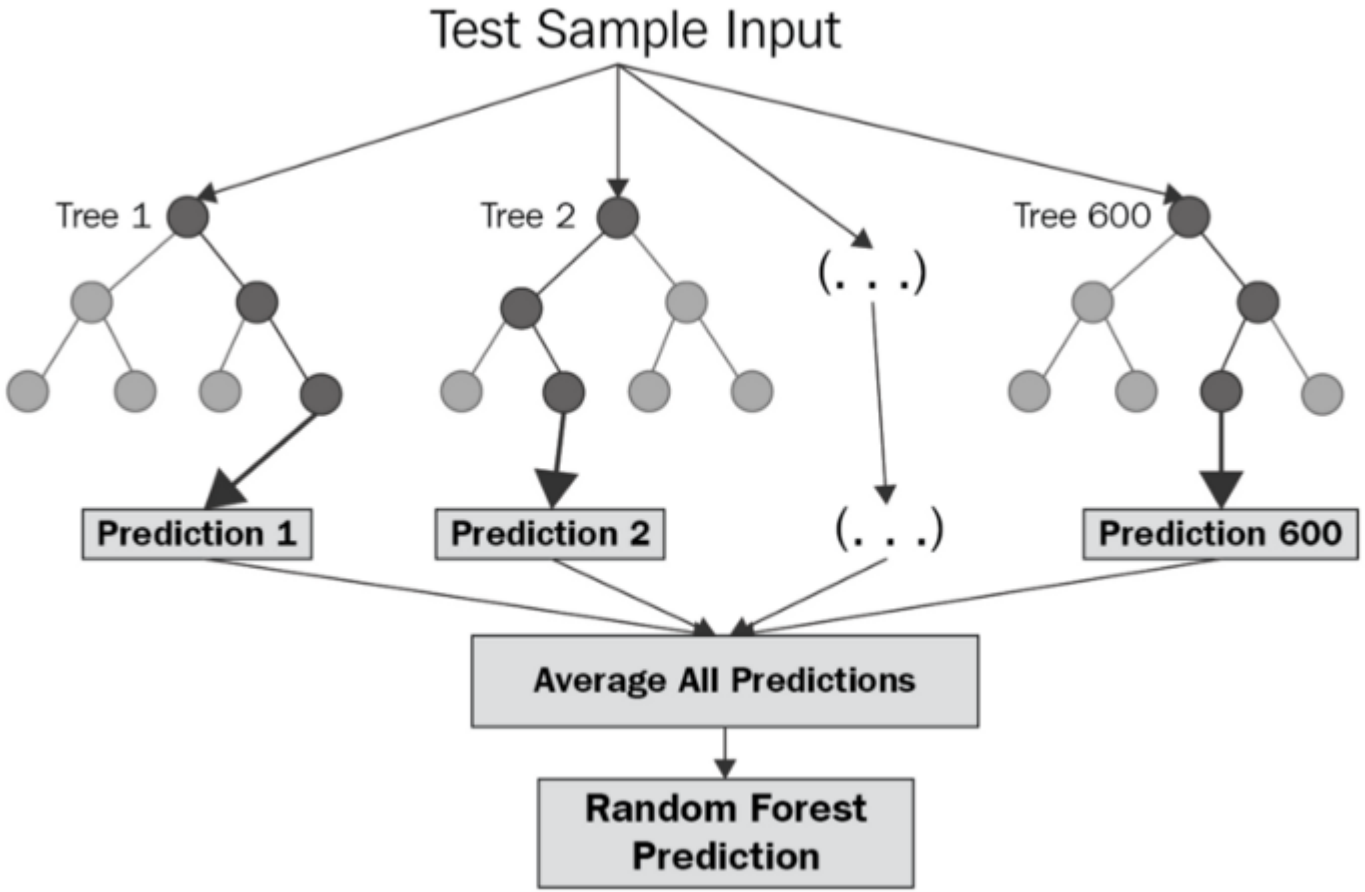
- Bäume werden sequenziell trainiert
-
-
-

Machine Learning und Deep Learning Modelle

Wald von Entscheidungsbäumen

Random Forest

- RandomForestRegressor
- RandomForestClassifier



Gradient Boosted Decision Trees

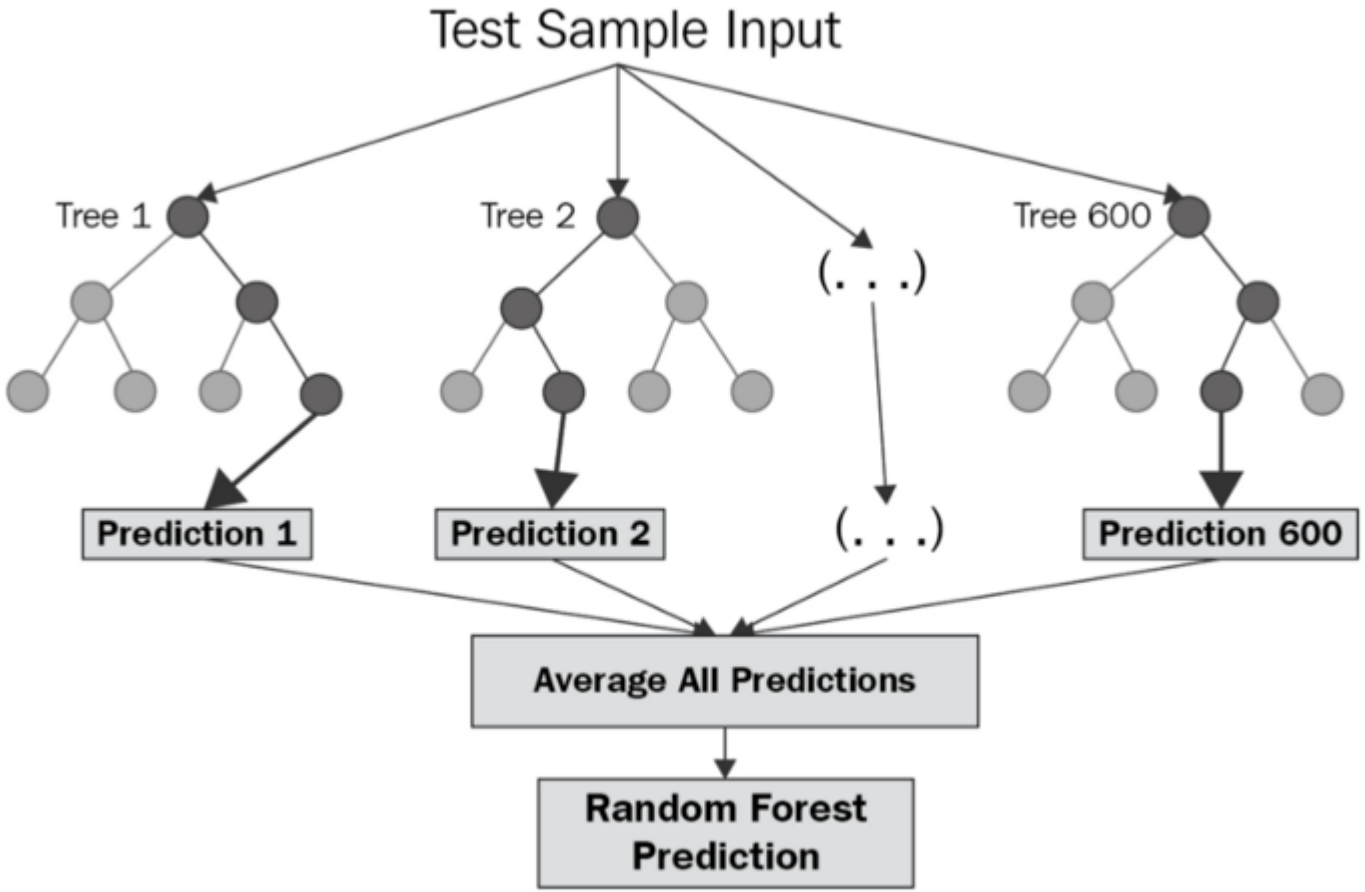
- Bäume werden sequenziell trainiert
- Der nächste Baum kompensiert die Fehler des vorherigen
-
-

Machine Learning und Deep Learning Modelle

Wald von Entscheidungsbäumen

Random Forest

- RandomForestRegressor
- RandomForestClassifier



Gradient Boosted Decision Trees

- Bäume werden sequenziell trainiert
- Der nächste Baum kompensiert die Fehler des vorherigen
- GradientBoostingClassifier
- GradientBoostingRegressor

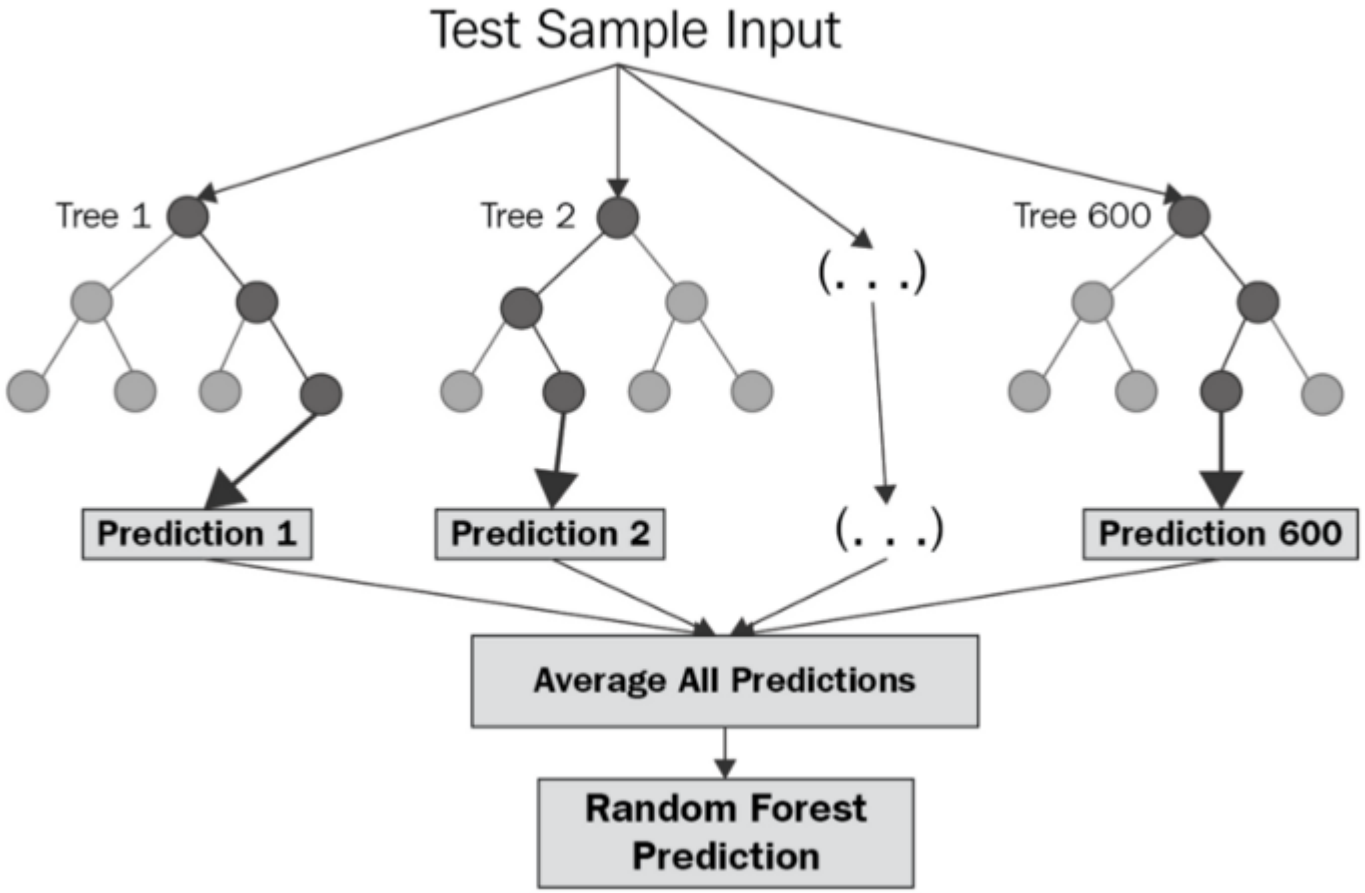
Machine Learning und Deep Learning Modelle

Wald von Entscheidungsbäumen

Übungsblatt 2:
Aufgabe 2 (g) und (h).

Random Forest

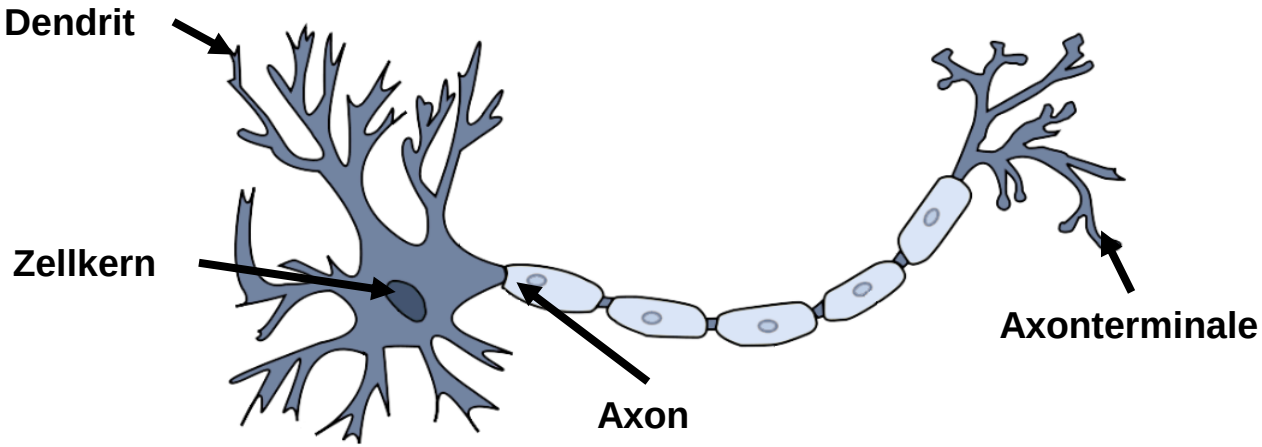
- RandomForestRegressor
- RandomForestClassifier



Gradient Boosted Decision Trees

- Bäume werden sequenziell trainiert
- Der nächste Baum kompensiert die Fehler des vorherigen
- GradientBoostingClassifier
- GradientBoostingRegressor

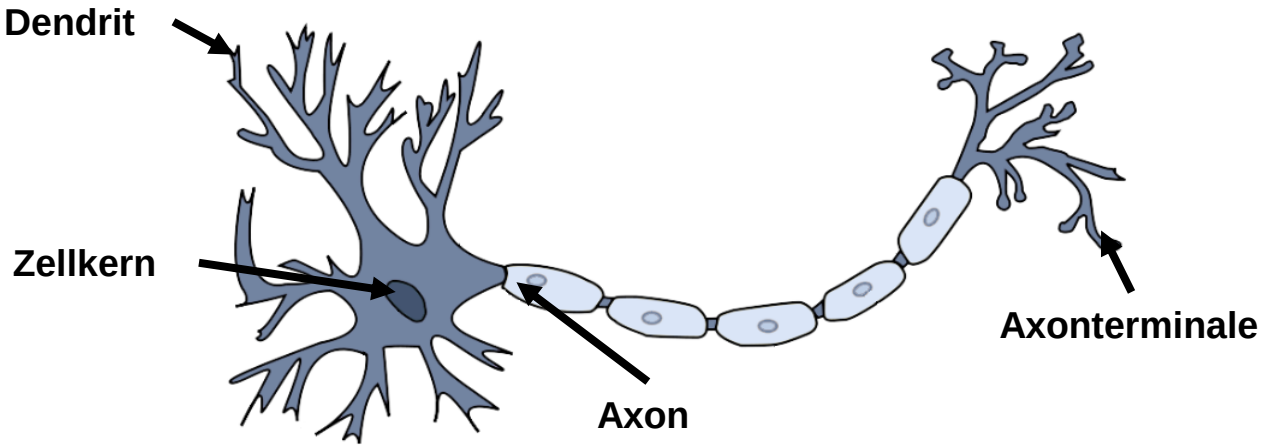
Künstliche Neuronale Netze
Das künstliche Neuron



Das biologische Neuron

- Elektrisch erregbare Zelle (Aufnahme, Verarbeitung und Weiterleitung von Informationen)
- Grundeinheit eines biologischen Gehirns
- Überträgt elektrische Signale von den Dendriten entlang des Axons zu den Terminalen
-
-
-
-

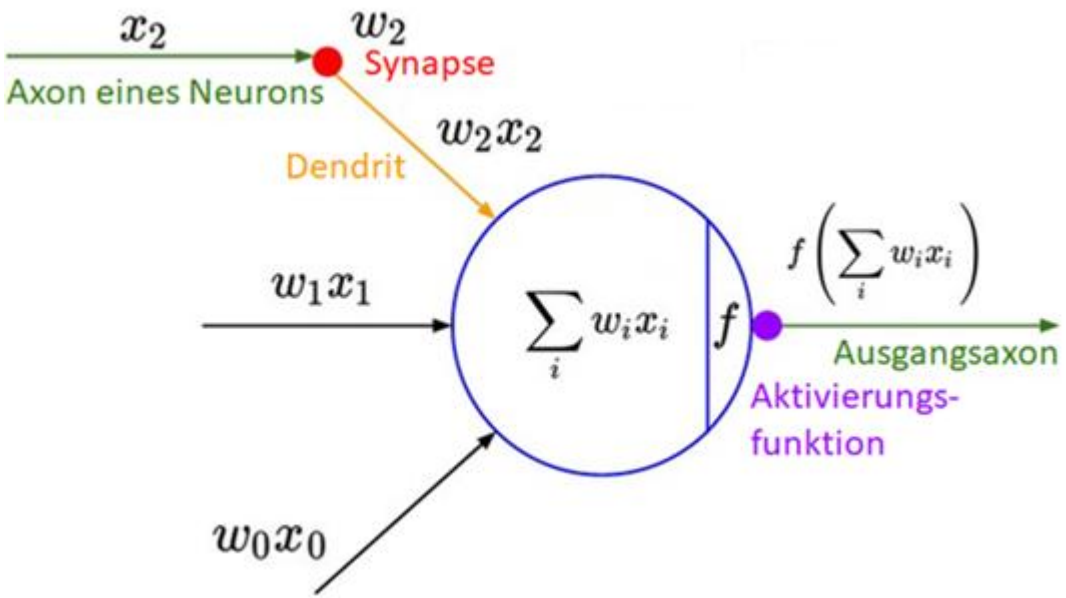
Künstliche Neuronale Netze
Das künstliche Neuron



Das biologische Neuron

- Elektrisch erregbare Zelle (Aufnahme, Verarbeitung und Weiterleitung von Informationen)
- Grundeinheit eines biologischen Gehirns
- Überträgt elektrische Signale von den Dendriten entlang des Axons zu den Terminalen
- Signale werden von Neuron zu Neuron übergeben
- Ausgangssignal entsteht nur, wenn die Eingabe ein Schwellwert überschreitet:
  - Das Neuron feuert
- Auf diese Weise nehmen wir Licht, Töne, Druck, Wärme, usw. wahr

Künstliche Neuronale Netze
Das künstliche Neuron

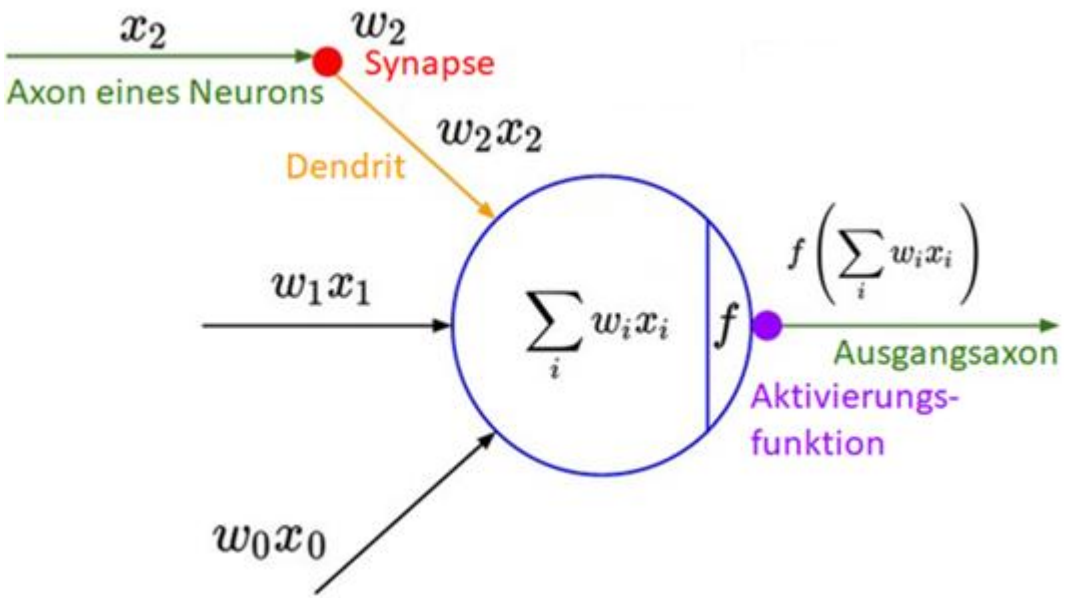


Das künstliche Neuron

- Grundeinheit eines neuronalen Netzes
- Ein- und Ausgänge sind Zahlen (anstatt binäre Ein/Aus Werte)
- Jede Eingangsverbindung ist mit einem Gewicht verbunden
- Die Gewichte sind die Modellparameter eines neuronalen Netzes
-
-
-

Quelle: Patrick Selle, Hahn-Schickard

Künstliche Neuronale Netze
Das künstliche Neuron

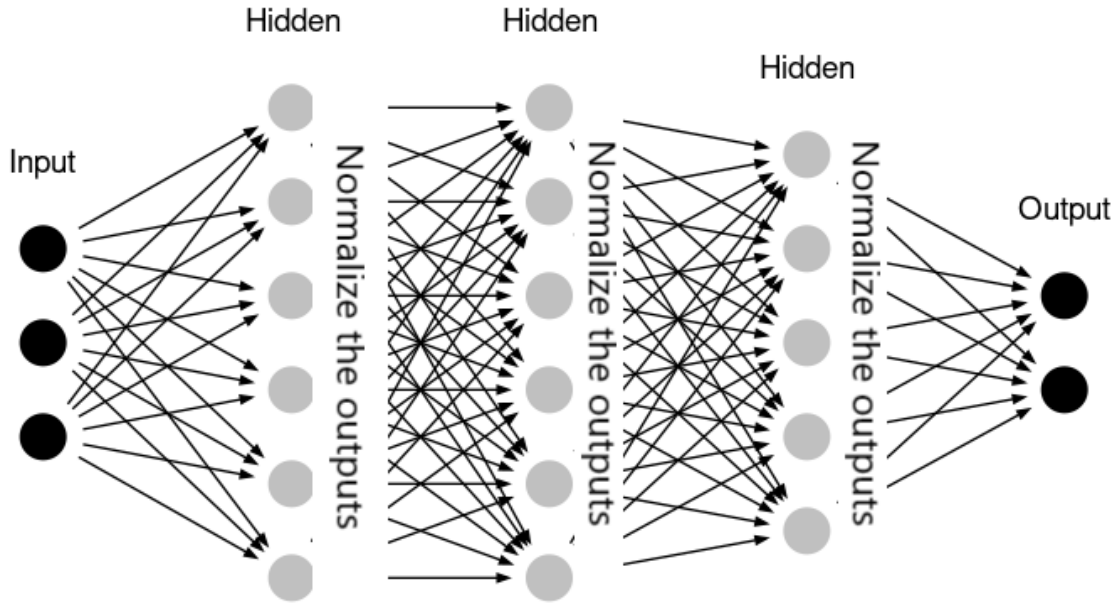


Das künstliche Neuron

- Grundeinheit eines neuronalen Netzes
- Ein- und Ausgänge sind Zahlen (anstatt binäre Ein/Aus Werte)
- Jede Eingangsverbindung ist mit einem Gewicht verbunden
- Die Gewichte sind die Modellparameter eines neuronalen Netzes
- Berechnung der gewichteten Summe aller Eingänge
- Anwenden einer Aktivierungsfunktion
- Verknüpfung dieser Bausteine bilden künstliche Neuronale Netze

Künstliche Neuronale Netze

- Neuronen sind schichtweise miteinander verbunden
- Eingangsschicht (Input Layer)
  - Hier 3 Neuronen
- Drei verdeckte (hidden) Schichten
- Ein Ausgangslayer
  - Hier 2 Neuronen
-
  -
  -



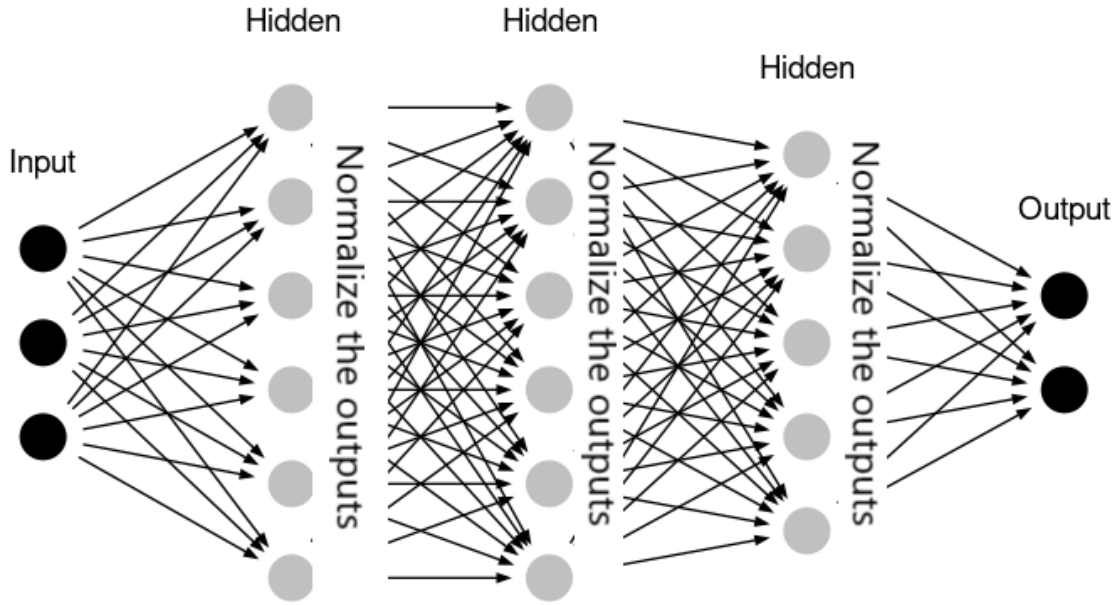
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle: Patrick Selle, Hahn-Schickard

Künstliche Neuronale Netze

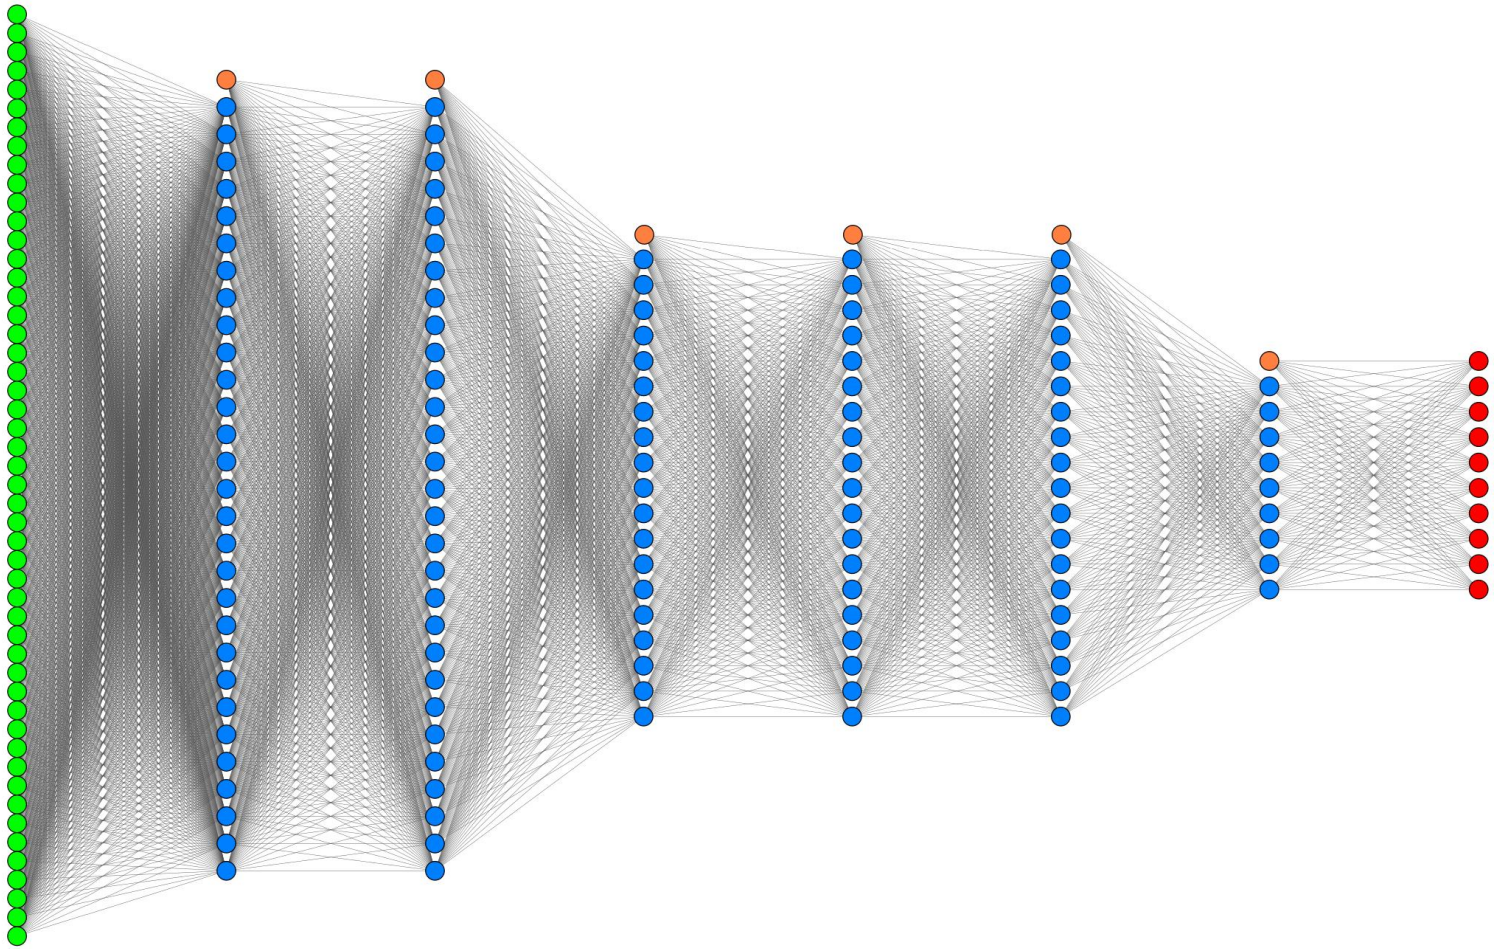
- Neuronen sind schichtweise miteinander verbunden
- Eingangsschicht (Input Layer)
  - Hier 3 Neuronen
- Drei verdeckte (hidden) Schichten
- Ein Ausgangslayer
  - Hier 2 Neuronen

- Künstliche neuronale Netze sind geeignet für
  - Klassifikation
  - Regression



Künstliche Neuronale Netze

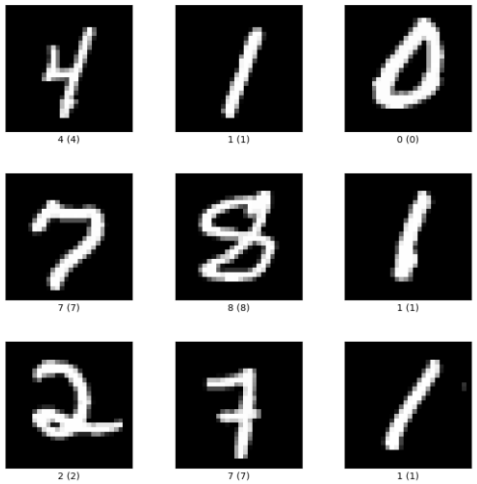
Tiefe neuronale Netze – Deep Learning

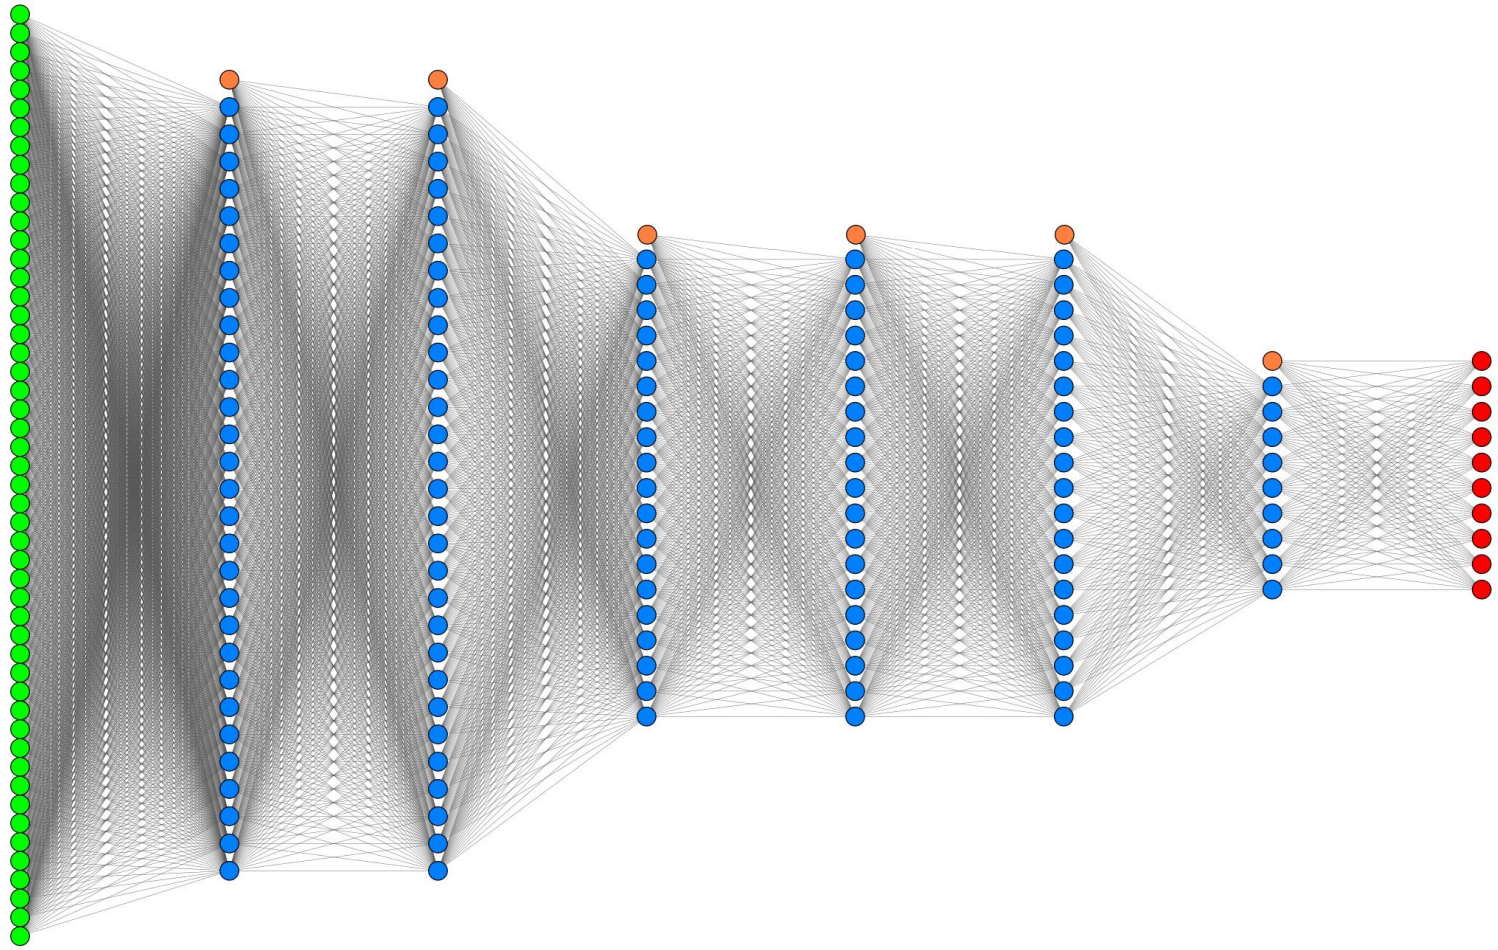


Künstliche Neuronale Netze

Tiefe neuronale Netze – Deep Learning

Eingabeschicht:
$28 \times 28 = 784$
Neuronen





Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

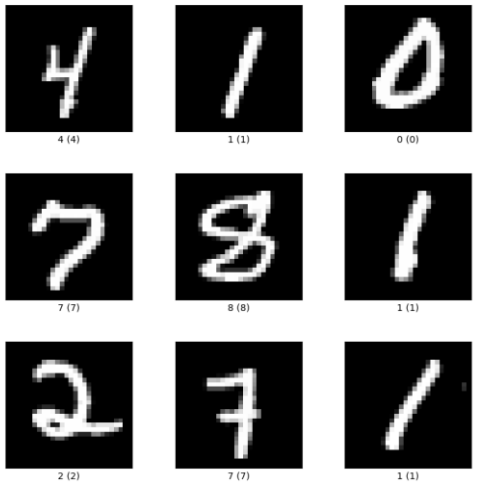
Quelle: Patrick Selle, Hahn-Schickard

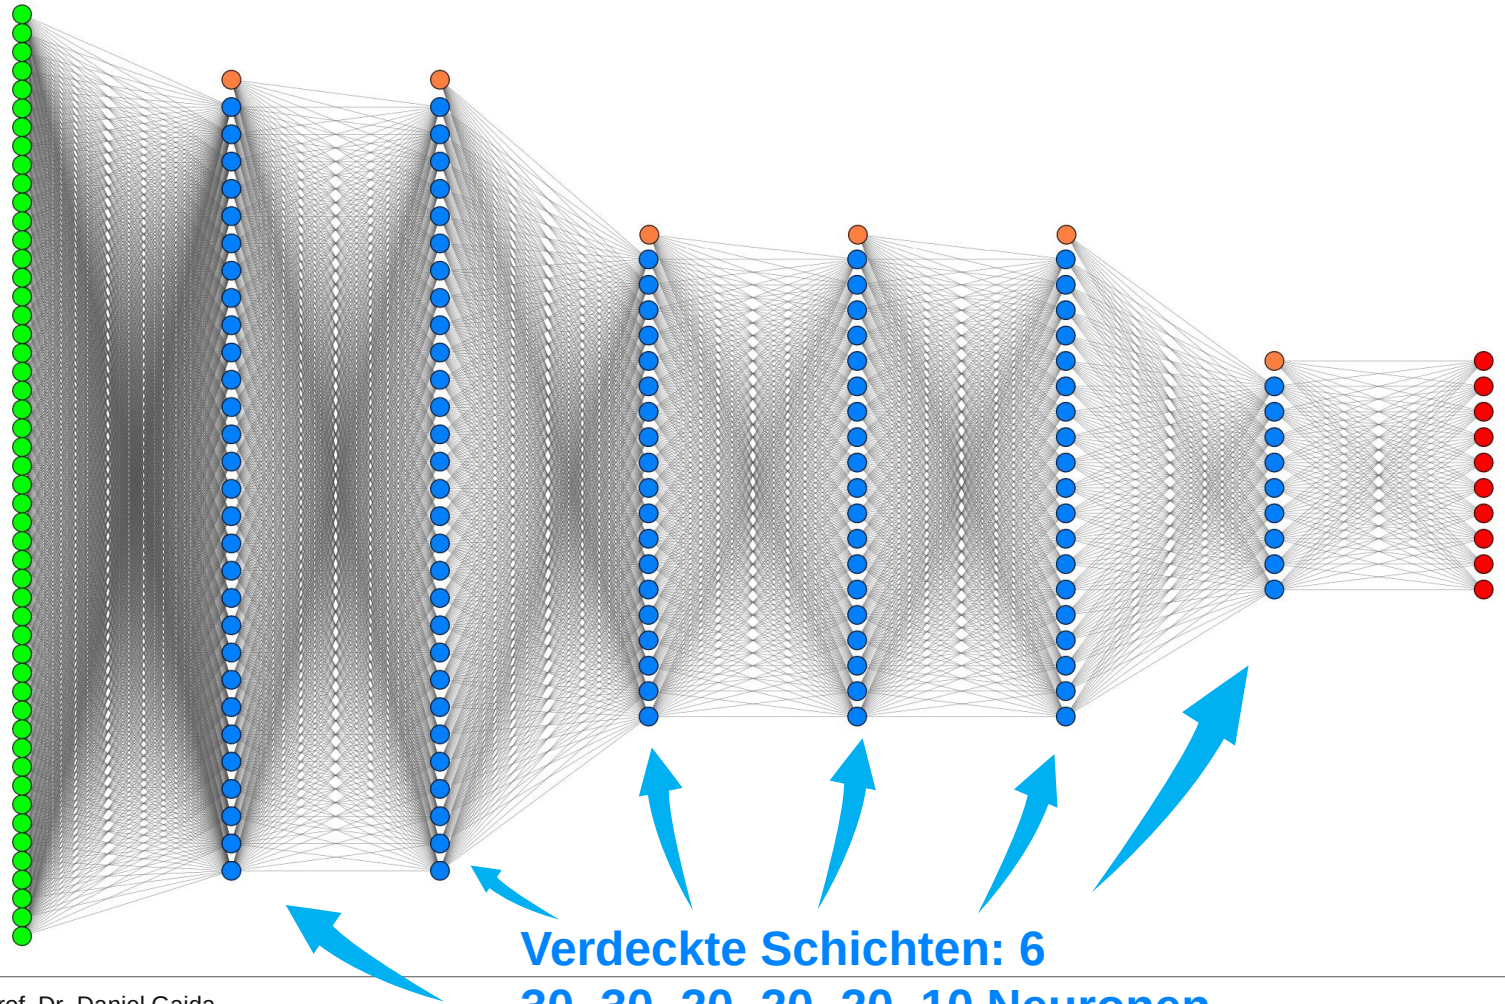
Technology
Arts Sciences
TH Köln

Künstliche Neuronale Netze

Tiefe neuronale Netze – Deep Learning

Eingabeschicht:
$28 \times 28 = 784$
Neuronen





Verdeckte Schichten: 6
30, 30, 20, 20, 20, 10 Neuronen

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

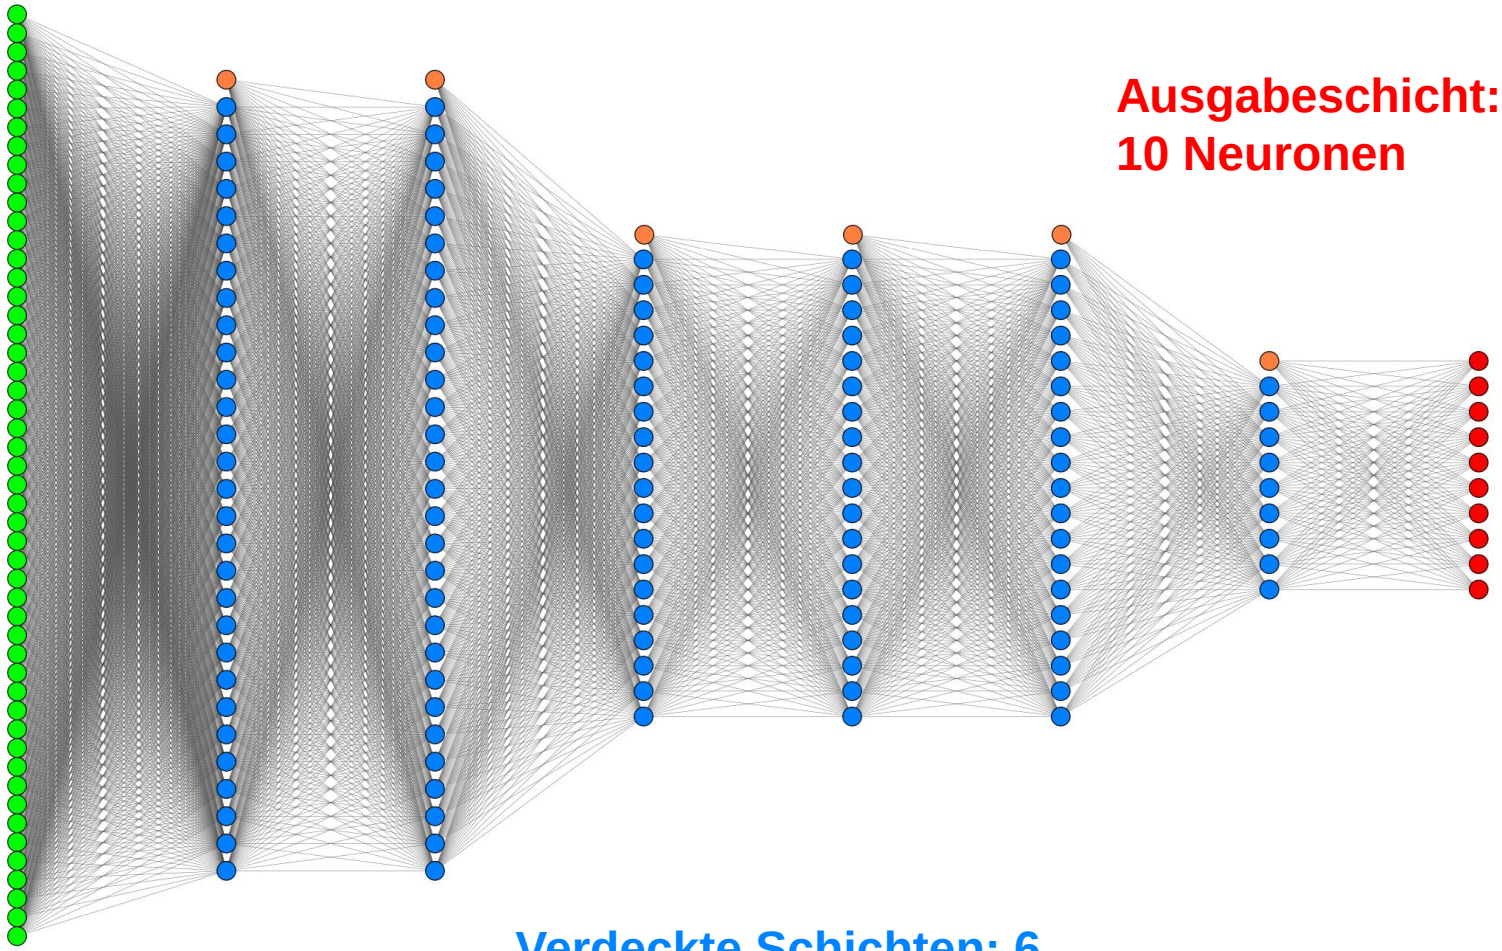
Quelle: Patrick Selle, Hahn-Schickard

Technology
Arts Sciences
TH Köln

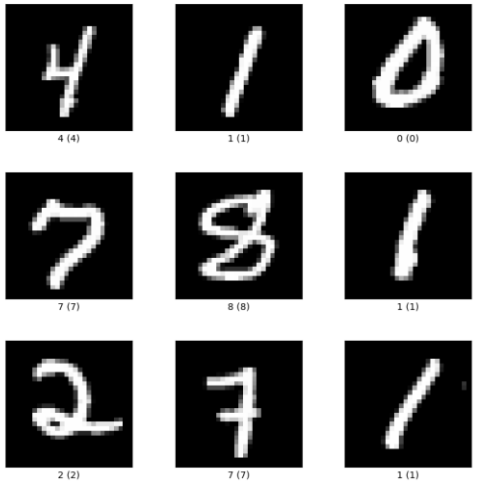
Künstliche Neuronale Netze

Tiefe neuronale Netze – Deep Learning

Eingabeschicht:
$28 \times 28 = 784$ Neuronen



Ausgabeschicht:
10 Neuronen



Verdeckte Schichten: 6
30, 30, 20, 20, 20, 10 Neuronen

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle: Patrick Selle, Hahn-Schickard

Technology
Arts Sciences
TH Köln

Training künstlicher neuronaler Netze

Training

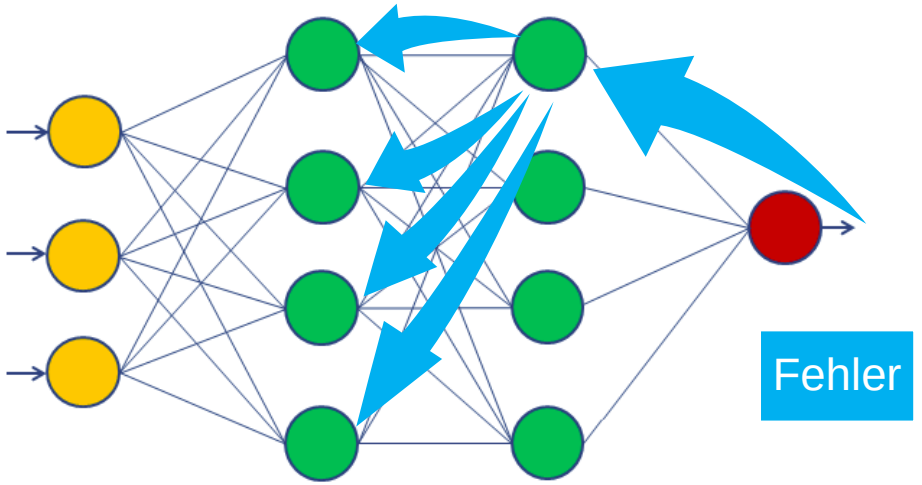
- Anpassen der Gewichte w_i der Neuronen
- Ziel: Minimierung des Vorhersagefehlers

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Bildquelle: Patrick Selle, Hahn-Schickard

Training künstlicher neuronaler Netze

Training

- Anpassen der Gewichte w_i der Neuronen
- Ziel: Minimierung des Vorhersagefehlers

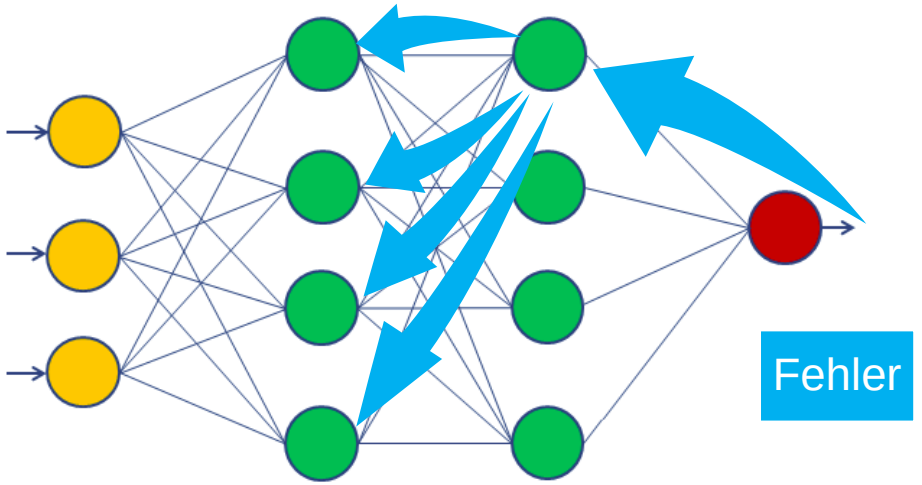


- Fehlerweitergabe (Backpropagation):
  - Der Vorhersagefehler wird rückwärts durch das Netz propagiert, um zu berechnen, wie stark jedes Gewicht zum Fehler beigetragen hat.
-
  -

Training künstlicher neuronaler Netze

Training

- Anpassen der Gewichte w_i der Neuronen
- Ziel: Minimierung des Vorhersagefehlers



- Fehlerweitergabe (Backpropagation):
  - Der Vorhersagefehler wird rückwärts durch das Netz propagiert, um zu berechnen, wie stark jedes Gewicht zum Fehler beigetragen hat.

- Anpassung der Gewichte (Gradientenabstieg):
  - Die Gewichte werden schrittweise so verändert, dass der Fehler kleiner wird — das Netz lernt, Muster in den Daten besser zu erkennen.

Machine Learning und Deep Learning Modelle

Deep Learning Modelle

- Es gibt unterschiedliche Arten von Deep Learning Modelle für verschiedene Anwendungen
- Bilderkennung
  - Convolutional neuronale Netze
  - Beispiel Modelle:
    - https://keras.io/api/applications/mobilenet/
-
  -
  -

Machine Learning und Deep Learning Modelle

Deep Learning Modelle

- Es gibt unterschiedliche Arten von Deep Learning Modelle für verschiedene Anwendungen
- Bilderkennung
  - Convolutional neuronale Netze
  - Beispiel Modelle:
    - https://keras.io/api/applications/mobilenet/
- Sprachverarbeitung
  - Transformer Netze
  - Beispiel: Large Language Modelle wie GPT-5, DeepSeek, …

Modelle im Überblick

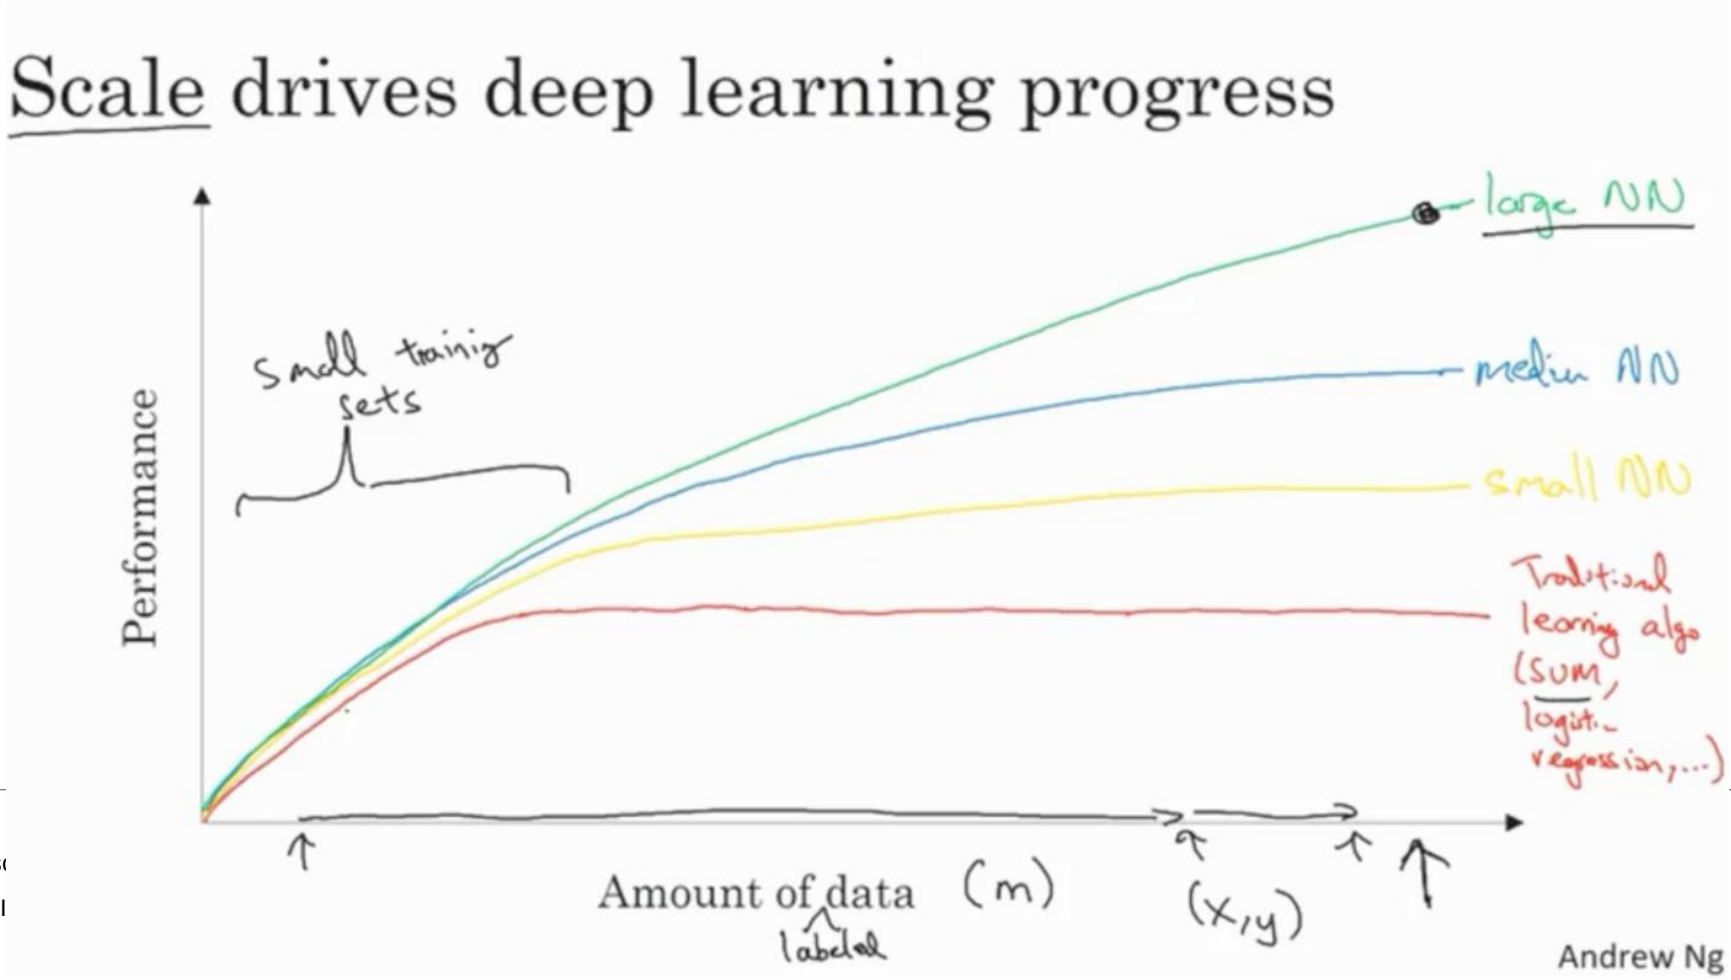
Modell geeignet für:	Regression	Klassifikation	Vorteile	Nachteile
Lineare Regression	Ja	Nein	Erklärbarkeit	Nur lineare Probleme
Logistische Regression	Nein	Ja	Erklärbarkeit	Nur linear separier-bare Probleme
Entscheidungsbaum	Ja	Ja	Erklärbarkeit	Nur strukturierte Daten
Random Forest	Ja	Ja	Gute Qualität	Nur strukturierte Daten
Gradient Boosted Decision Trees	Ja	Ja	Gute Qualität	Nur strukturierte Daten
Neuronales Netz	Ja	Ja	strukturierte und unstrukturierte Daten	BlackBox

Modelle im Überblick

- Viele Trainingsdaten (> 100.000): Deep Learning meistens besser geeignet als Machine Learning
- Wenig Trainingsdaten (< 1.000): Besser einfache Machine Learning Modelle nutzen oder kleine Entscheidungsbäume

Modelle im Überblick

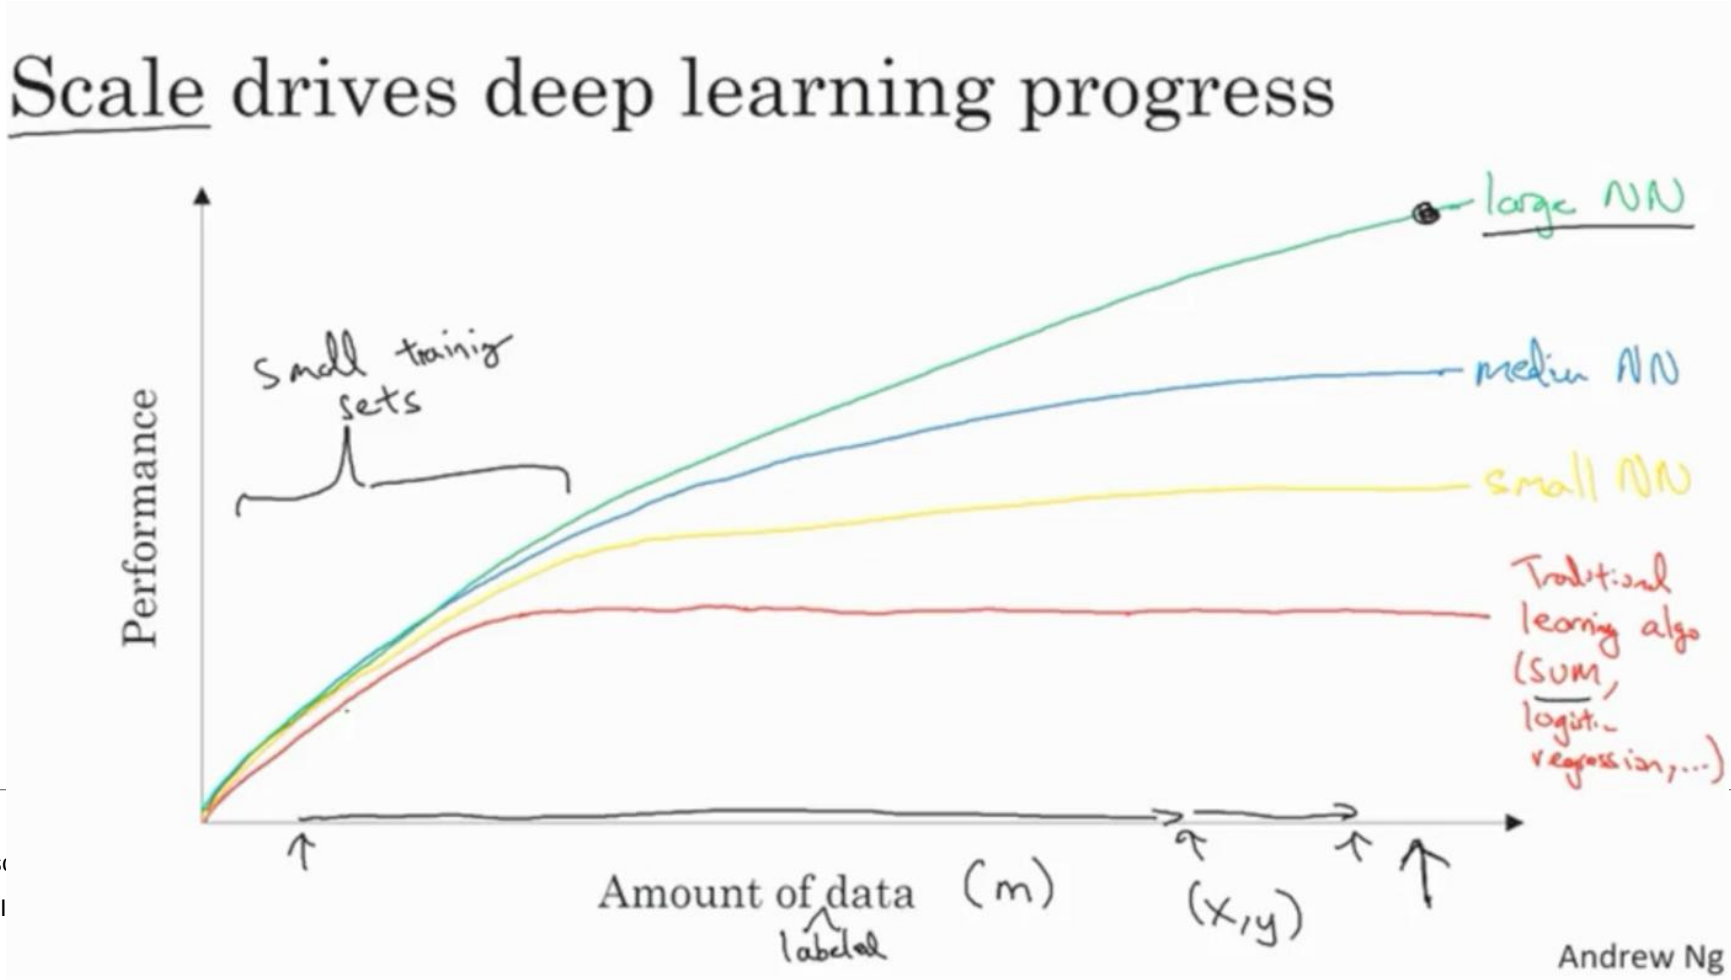
- Viele Trainingsdaten (> 100.000): Deep Learning meistens besser geeignet als Machine Learning
- Wenig Trainingsdaten (< 1.000): Besser einfache Machine Learning Modelle nutzen oder kleine Entscheidungsbäume



Modelle im Überblick

Übungsblatt 2:
Aufgabe 3

- Viele Trainingsdaten (> 100.000): Deep Learning meistens besser geeignet als Machine Learning
- Wenig Trainingsdaten (< 1.000): Besser einfache Machine Learning Modelle nutzen oder kleine Entscheidungsbäume



Lernraum 1: Grundlagen und methodische Basis

- Was ist und warum wird Machine Learning verwendet?
- Anwendungsbeispiele für Machine Learning und Deep Learning
- Training von Machine Learning Modellen mit und ohne Überwachung

- Grundlegende Visualisierungsmöglichkeiten von Daten

- Wie gut ist das trainierte Machine Learning Modell?

- Machine Learning und Deep Learning Algorithmen
  - Logistische Regression, Entscheidungsbäume, neuronale Netze

- **Wie funktioniert ChatGPT & Co.?**

Wie funktioniert ChatGPT?

- Hinter ChatGPT verbirgt sich ein
  - Large Language Model (LLM)
    - Eine Art tiefes neuronales Netz (Transformer Architektur)

Wie funktioniert ChatGPT?

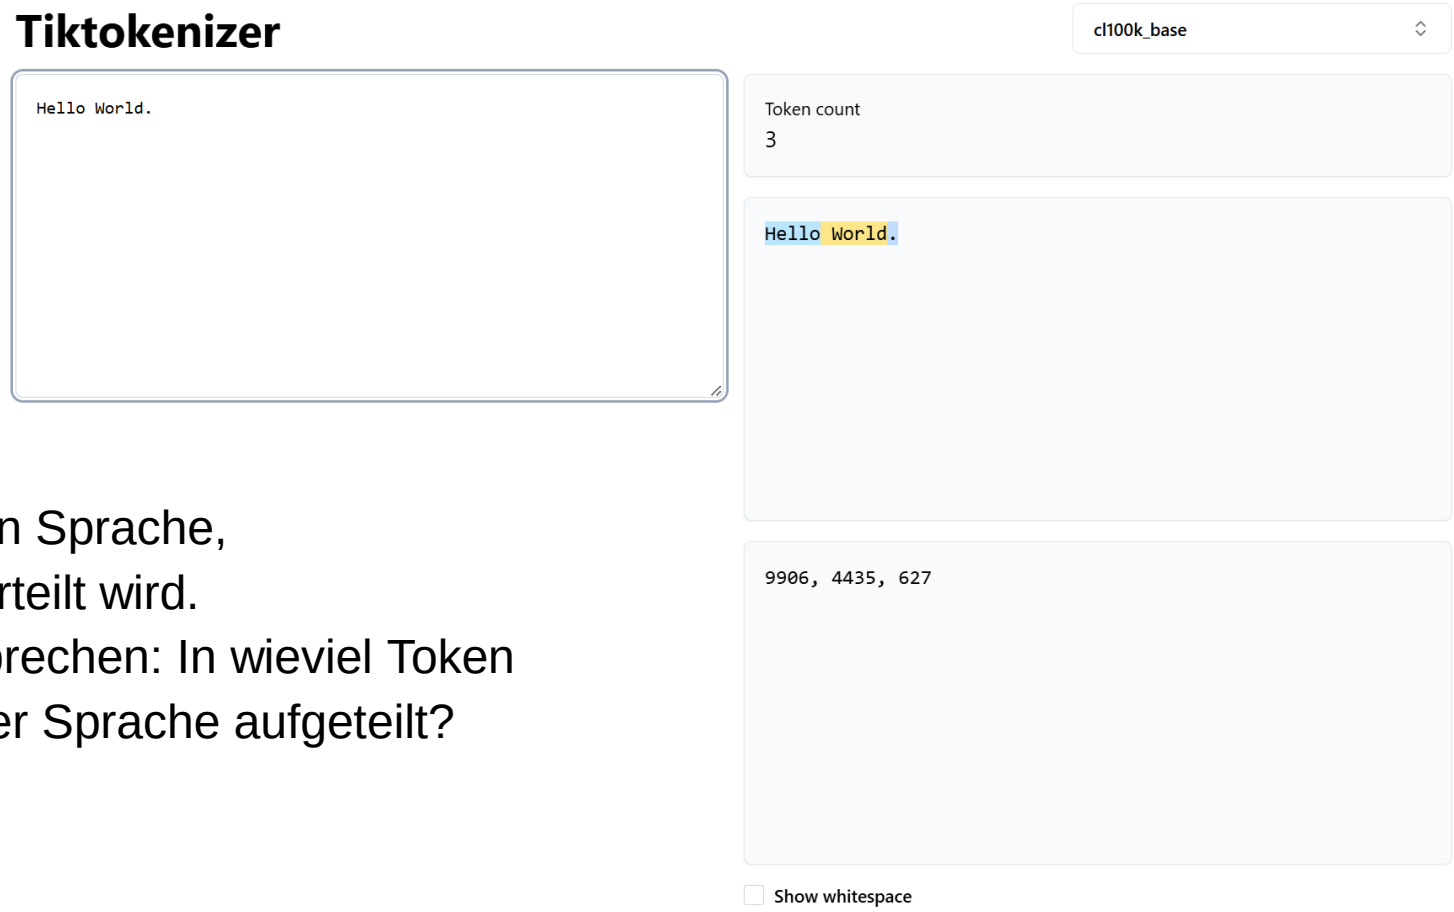
- Hinter ChatGPT verbirgt sich ein
  - Large Language Model (LLM)
    - Eine Art tiefes neuronales Netz (Transformer Architektur)

- Text wird als eine Sequenz von Wörtern oder Teilwörtern angesehen (Tokens)
  - Ein Token entspricht einem Wort, Teilwort oder einem Buchstaben/Satzzeichen
  - Text, den Sie in den Prompt von ChatGPT kopieren, muss in Tokens umgewandelt werden
    - Tokenization
  - Tokens sind das Vokabular

Tokenization

Übungsblatt 2:
Aufgabe 4 (a)

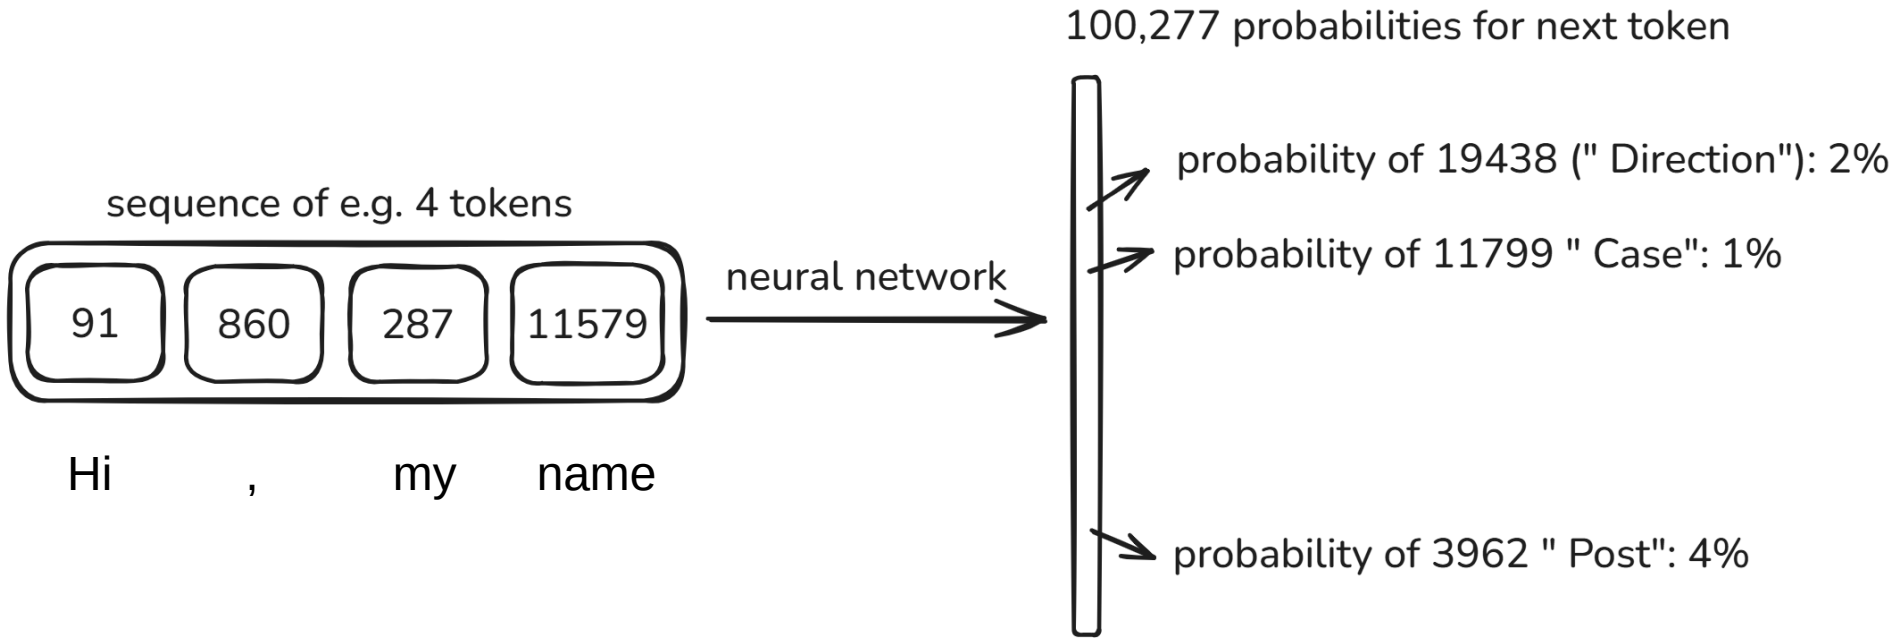
- Demo: https://tiktokenizer.vercel.app/



- Übung:
  - Suchen Sie ein Wort der deutschen Sprache, dass in möglichst viele Token unterteilt wird.
  - Wenn Sie eine weitere Sprache sprechen: In wieviel Token werden herkömmliche Wörter in der Sprache aufgeteilt?

LLM: Vorhersage einer Wahrscheinlichkeit für das nächste Token

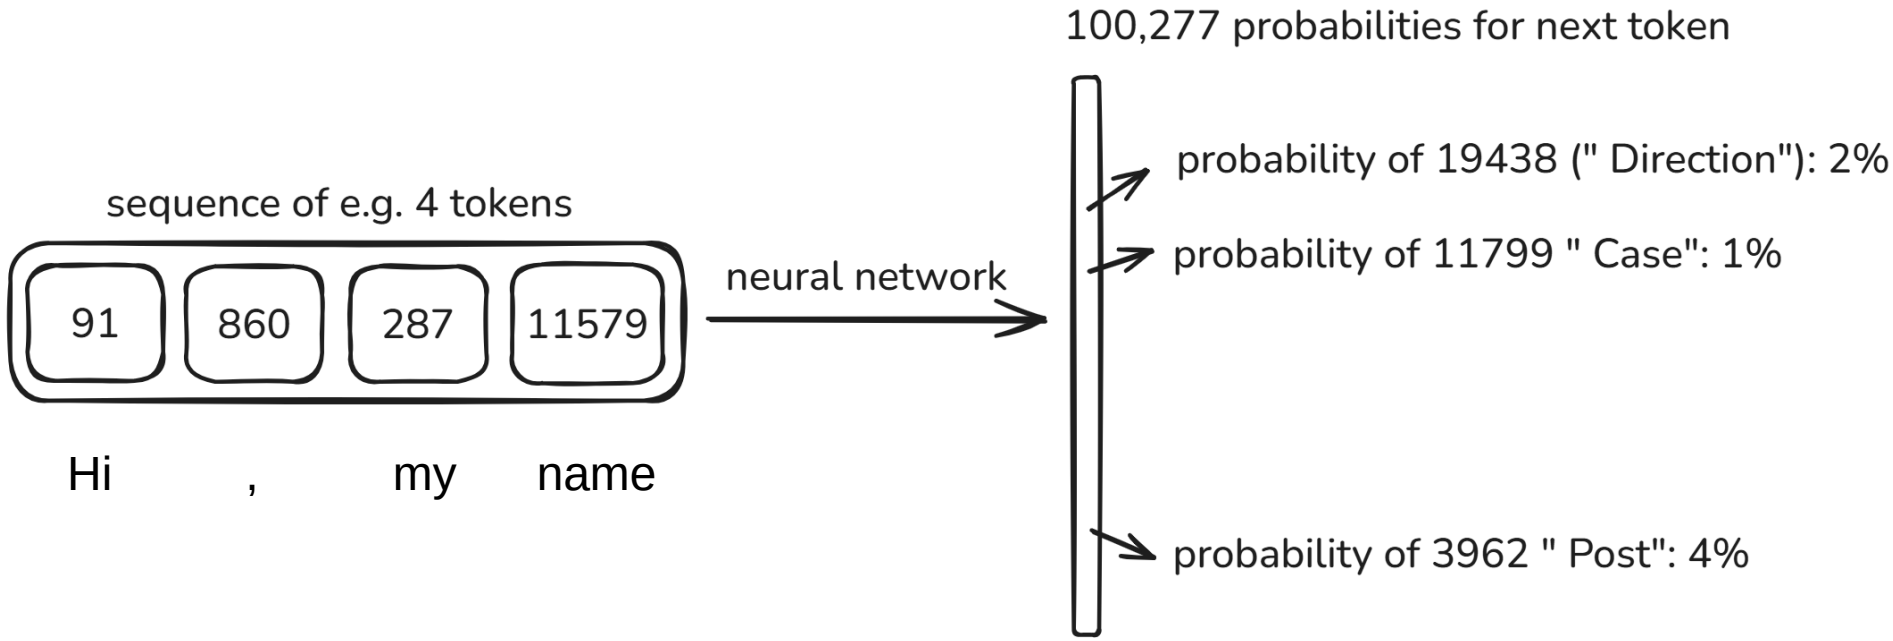
- Eingabesequenz der Tokens (Prompt) geht in das LLM rein
- LLM liefert für alle bekannten Tokens eine Wahrscheinlichkeit zurück
-



Quelle: Andrej Karpathy, Deep Dive into LLMs like ChatGPT, https://www.youtube.com/watch?v=7xTGNNLPyMI

LLM: Vorhersage einer Wahrscheinlichkeit für das nächste Token

- Eingabesequenz der Tokens (Prompt) geht in das LLM rein
- LLM liefert für alle bekannten Tokens eine Wahrscheinlichkeit zurück
- Tokens mit einer hohen Wahrscheinlichkeit folgten im Trainingsdatensatz häufig der Eingabesequenz von Tokens

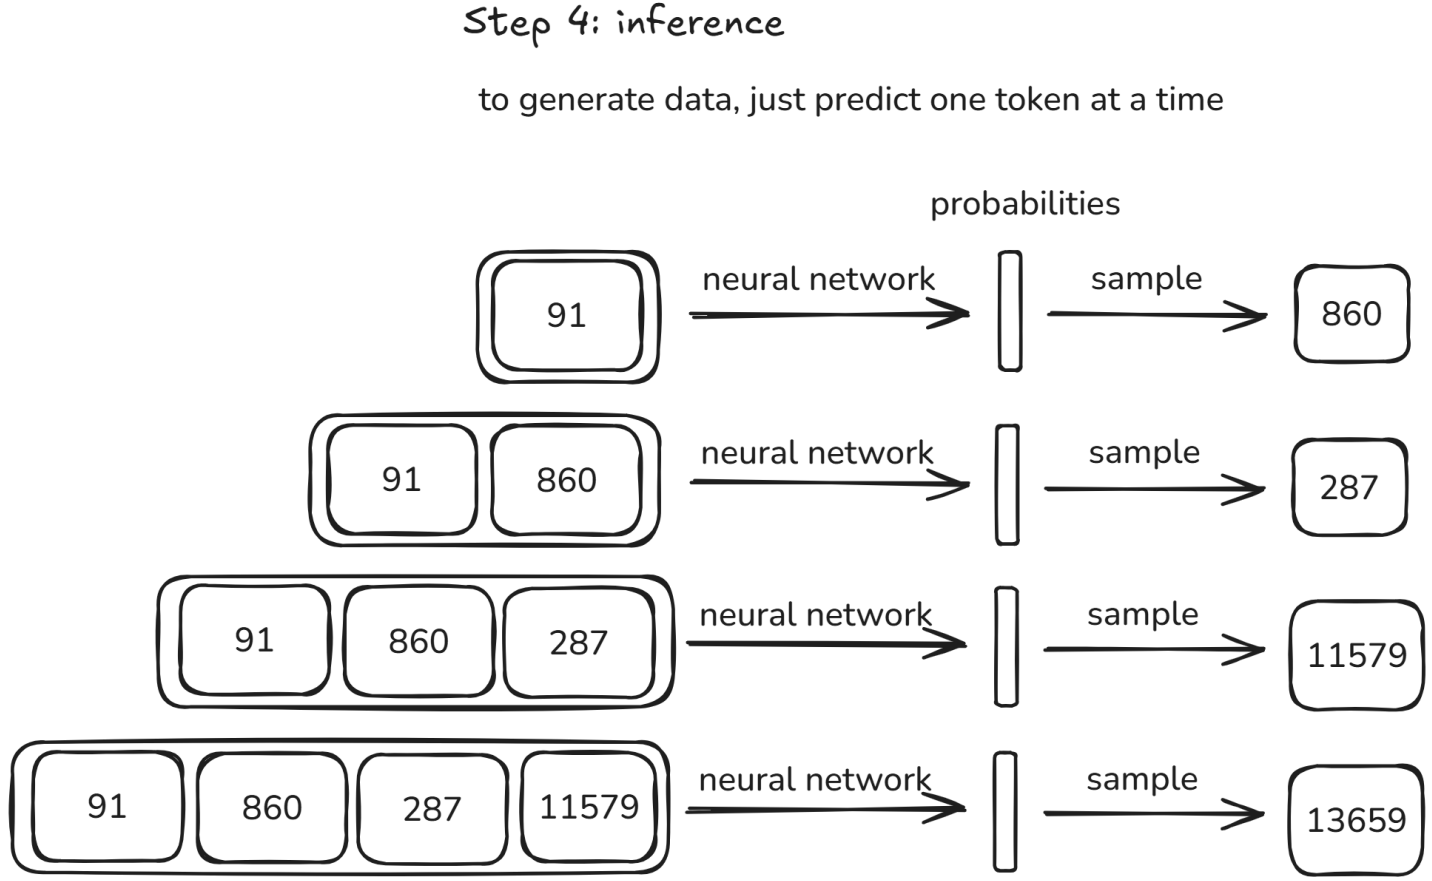


Quelle: Andrej Karpathy, Deep Dive into LLMs like ChatGPT, https://www.youtube.com/watch?v=7xTGNNLPyMI

LLM: Ein Autoregressives Modell

Quelle: Andrej Karpathy, Deep Dive into LLMs like ChatGPT, https://www.youtube.com/watch?v=7xTGNNLPyMI

LLMs sind autoregressive Modelle



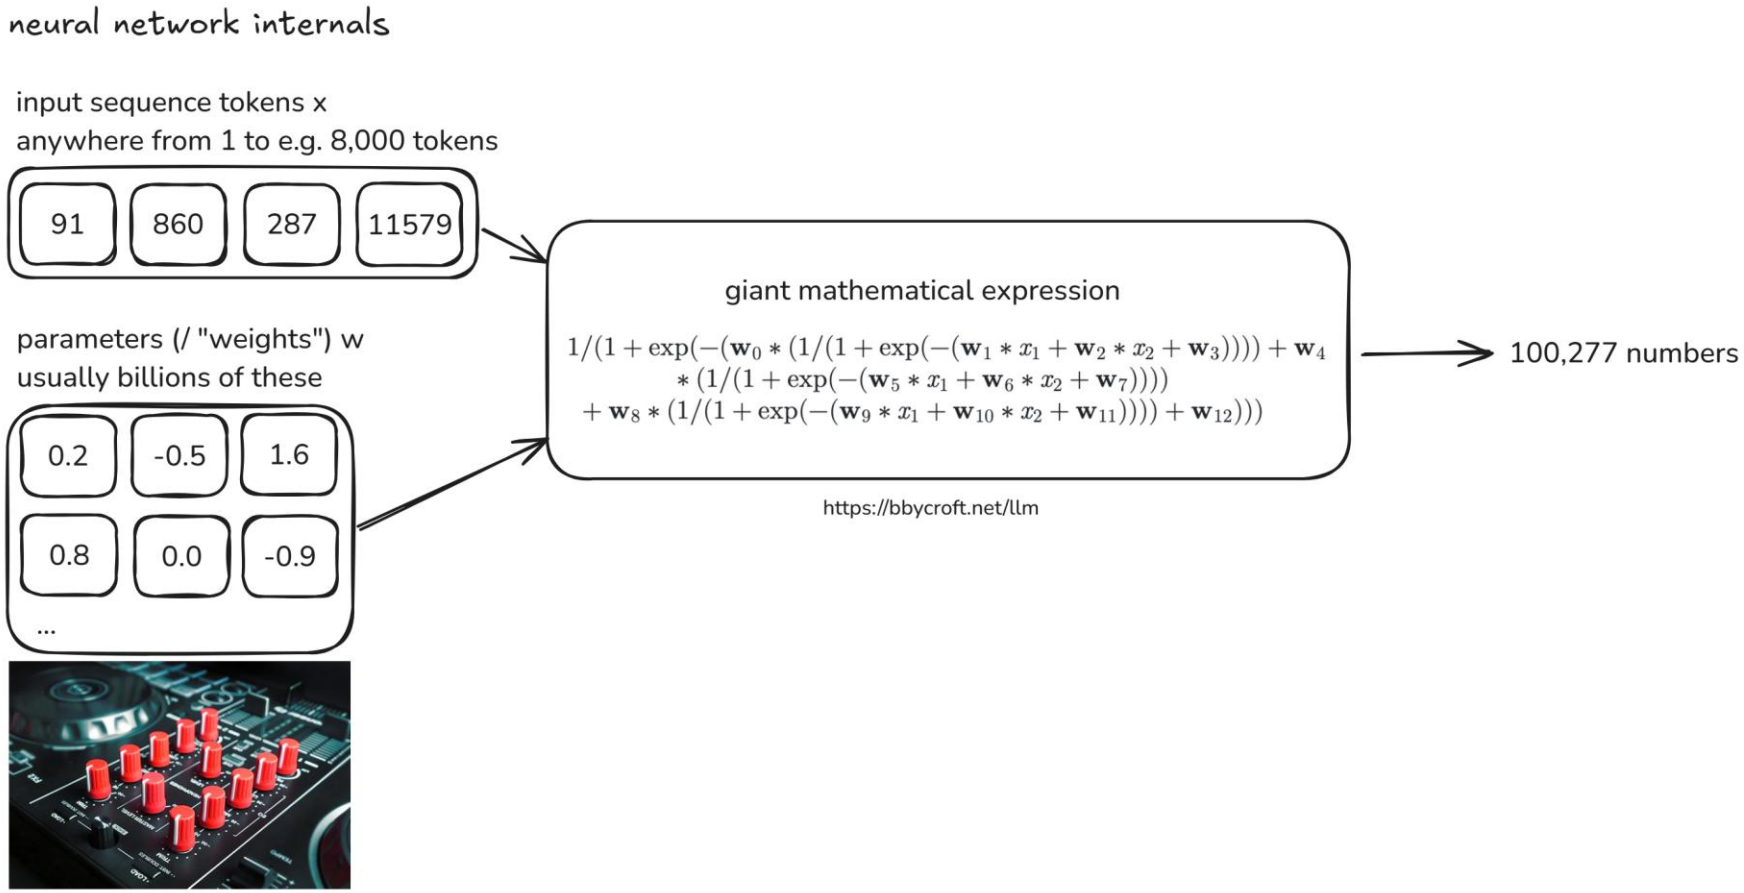
LLM: Ein Autoregressives Modell



Quelle: https://huggingface.co/learn/agents-course/unit1/what-are-llms

Large Language Modelle

Quelle: Andrej Karpathy, Deep Dive into LLMs like ChatGPT, https://www.youtube.com/watch?v=7xTGNNLPyMI



Eigenschaften von LLMs

- Trainiert auf Milliarden Wörtern – lernen Wahrscheinlichkeitsverteilungen
- Kein Verständnis, keine Intention, keine Wahrheit
  - wichtig für späteren ethischen Diskurs

- Warum sind LLMs oft so überzeugend – obwohl sie nichts verstehen?

Eigenschaften von LLMs

- Trainiert auf Milliarden Wörtern – lernen Wahrscheinlichkeitsverteilungen
- Kein Verständnis, keine Intention, keine Wahrheit
  - wichtig für späteren ethischen Diskurs

- Warum sind LLMs oft so überzeugend – obwohl sie nichts verstehen?
  - Statistisches Sprachgefühl auf Expertenniveau
    - Können juristische Texte verfassen, da sie sehr viele gesehen haben
  -
  -
    -

Eigenschaften von LLMs

- Trainiert auf Milliarden Wörtern – lernen Wahrscheinlichkeitsverteilungen
- Kein Verständnis, keine Intention, keine Wahrheit
  - wichtig für späteren ethischen Diskurs

- Warum sind LLMs oft so überzeugend – obwohl sie nichts verstehen?
  - Statistisches Sprachgefühl auf Expertenniveau
    - Können juristische Texte verfassen, da sie sehr viele gesehen haben
  - Der Kontext kann sehr lang sein (nimmt Bezug auf sehr langen Prompt), damit sind Antworten konsistent und widerspruchsfrei
  -
    -

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Eigenschaften von LLMs

- Trainiert auf Milliarden Wörtern – lernen Wahrscheinlichkeitsverteilungen
- Kein Verständnis, keine Intention, keine Wahrheit
  - wichtig für späteren ethischen Diskurs

- Warum sind LLMs oft so überzeugend – obwohl sie nichts verstehen?
  - Statistisches Sprachgefühl auf Expertenniveau
    - Können juristische Texte verfassen, da sie sehr viele gesehen haben
  - Der Kontext kann sehr lang sein (nimmt Bezug auf sehr langen Prompt), damit sind Antworten konsistent und widerspruchsfrei
  - Selbstsichere Sprache ohne Selbstzweifel und ohne Rechtschreibfehler
    - Wirkt kompetent

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Eigenschaften von LLMs

Quelle: Andrej Karpathy, Deep Dive into LLMs like ChatGPT, https://www.youtube.com/watch?v=7xTGNNLPyMI

Models can't count

Models are not good with spelling.

Remember they see tokens (text chunks), not individual letters!

Bunch of other small random stuff

What is bigger 9.11 or 9.9?

Models can (and should!) use tools!

Web search
Code (/ Python interpreter)

Eigenschaften von LLMs

Quelle: Andrej Karpathy, Deep Dive into LLMs like ChatGPT, https://www.youtube.com/watch?v=7xTGNNLPyMI

Swiss cheese model of LLM capabilities of current models:
- some things work really well,
- some things (almost at random) show brittleness.



Übungsblatt 2:
Aufgabe 4 (b) – (d)

Wie funktioniert Bildgenerierung?

Prinzip:

- KI-Modelle (z. B. DALL·E, Midjourney, Stable Diffusion) erzeugen Bilder aus Texteingaben
  - „Ein Student sitzt im Park und liest auf einem Tablet.“

Wie funktioniert Bildgenerierung?

Prinzip:

- KI-Modelle (z. B. DALL·E, Midjourney, Stable Diffusion) erzeugen Bilder aus Texteingaben
  - „Ein Student sitzt im Park und liest auf einem Tablet.“

Technische Grundlage:

- Diffusionsmodelle lernen, schrittweise Rauschen in strukturierte Bilder umzuwandeln
- https://poloclub.github.io/diffusion-explainer/

Wie funktioniert Bildgenerierung?

Prinzip:

- KI-Modelle (z. B. DALL·E, Midjourney, Stable Diffusion) erzeugen Bilder aus Texteingaben
  - „Ein Student sitzt im Park und liest auf einem Tablet.“

Technische Grundlage:

- Diffusionsmodelle lernen, schrittweise Rauschen in strukturierte Bilder umzuwandeln
- https://poloclub.github.io/diffusion-explainer/

Potenziale:

- kreative Gestaltung, Design-Ideen, Prototypen, inklusive Darstellungen möglich

Wie funktioniert Bildgenerierung?

Prinzip:

- KI-Modelle (z. B. DALL·E, Midjourney, Stable Diffusion) erzeugen Bilder aus Texteingaben
  - „Ein Student sitzt im Park und liest auf einem Tablet.“

Technische Grundlage:

- Diffusionsmodelle lernen, schrittweise Rauschen in strukturierte Bilder umzuwandeln
- https://poloclub.github.io/diffusion-explainer/

Potenziale:

- kreative Gestaltung, Design-Ideen, Prototypen, inklusive Darstellungen möglich

Herausforderungen:

- Bias: erzeugte Bilder spiegeln gesellschaftliche Stereotype wider
- Urheberrecht & Transparenz: Datenquellen oft unklar
- Manipulation: Realitätsverzerrung durch synthetische Bilder

Machine Learning Grundlagen

Zusammenfassung und Fragen

- Beim Machine Learning geht es darum, Maschinen bei der Lösung einer Aufgabe zu verbessern, indem sie aus Daten lernen, anstatt explizit definierte Regeln zu erhalten.
-
-
-
  -

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Machine Learning Grundlagen

Zusammenfassung und Fragen

- Beim Machine Learning geht es darum, Maschinen bei der Lösung einer Aufgabe zu verbessern, indem sie aus Daten lernen, anstatt explizit definierte Regeln zu erhalten.
- In einem ML-Projekt sammeln Sie Daten in einem Trainingsdatensatz und speisen diesen in einen Lernalgorithmus ein. Während des Trainings tunt der Algorithmus einige Parameter, um das Modell an die Trainingsdaten anzupassen (d.h., um gute Vorhersagen auf den Trainingsdaten selbst zu treffen).
-
-
  -

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Machine Learning Grundlagen

Zusammenfassung und Fragen

- Beim Machine Learning geht es darum, Maschinen bei der Lösung einer Aufgabe zu verbessern, indem sie aus Daten lernen, anstatt explizit definierte Regeln zu erhalten.
- In einem ML-Projekt sammeln Sie Daten in einem Trainingsdatensatz und speisen diesen in einen Lernalgorithmus ein. Während des Trainings tunt der Algorithmus einige Parameter, um das Modell an die Trainingsdaten anzupassen (d.h., um gute Vorhersagen auf den Trainingsdaten selbst zu treffen).
- Beim Test prüfen Sie ob das Modell in der Lage ist, auch für neue Daten gute Vorhersagen zu treffen.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Machine Learning Grundlagen

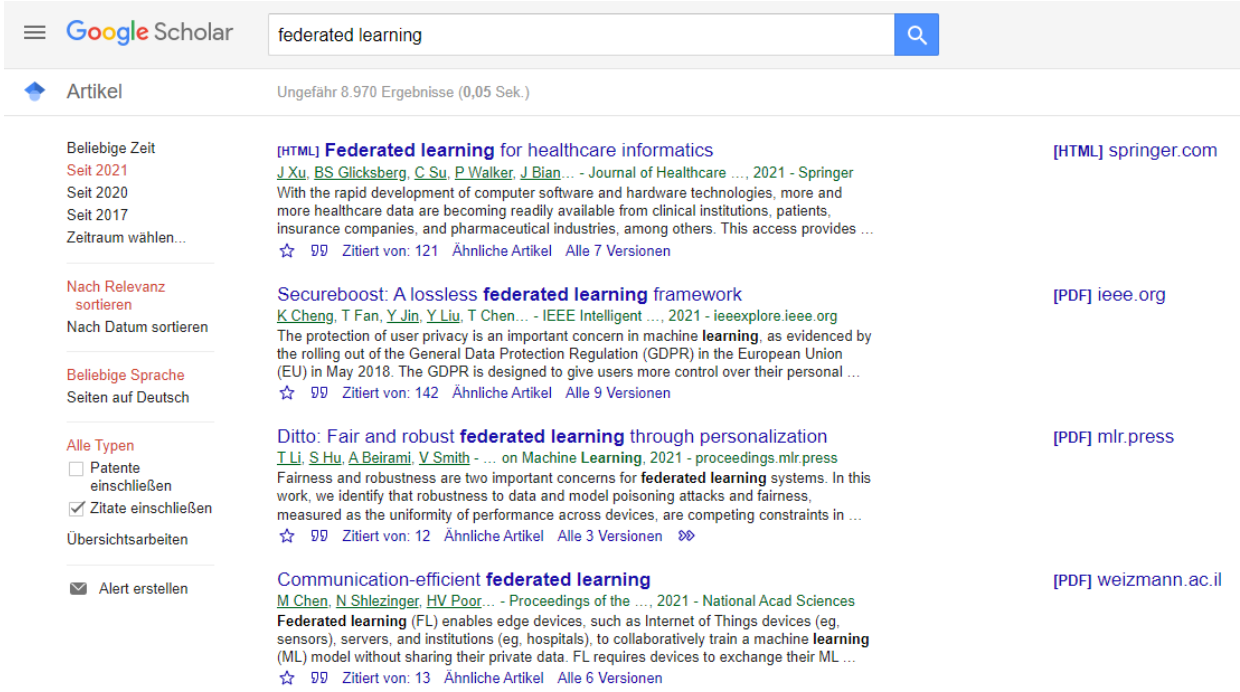
Zusammenfassung und Fragen

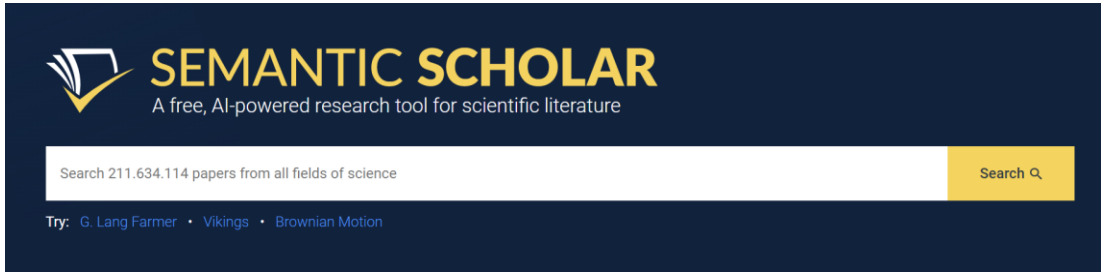
- Beim Machine Learning geht es darum, Maschinen bei der Lösung einer Aufgabe zu verbessern, indem sie aus Daten lernen, anstatt explizit definierte Regeln zu erhalten.
- In einem ML-Projekt sammeln Sie Daten in einem Trainingsdatensatz und speisen diesen in einen Lernalgorithmus ein. Während des Trainings tunt der Algorithmus einige Parameter, um das Modell an die Trainingsdaten anzupassen (d.h., um gute Vorhersagen auf den Trainingsdaten selbst zu treffen).
- Beim Test prüfen Sie ob das Modell in der Lage ist, auch für neue Daten gute Vorhersagen zu treffen.

- Es gibt verschiedene Machine Learning und Deep Learning Algorithmen
  - Je nach Anwendung und Ziel (Genauigkeit vs. Erklärbarkeit) können Sie mehrere Algorithmen ausprobieren und schauen welcher am Besten performt

Recherche von Veröffentlichungen (und Datensätzen)

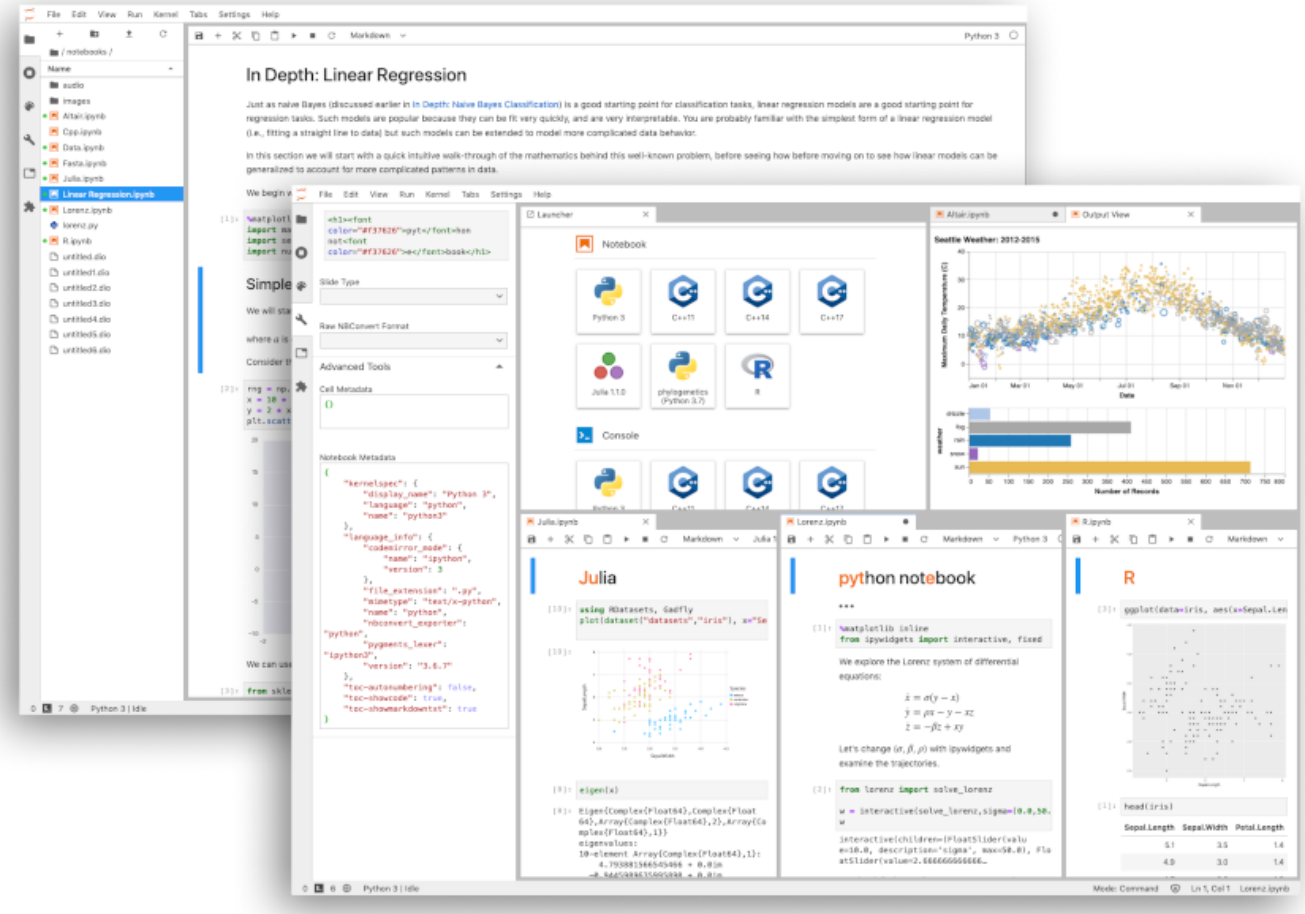
- scholar.google.de
- paperswithcode.co
- semanticscholar.org





Falls Sie Google Colab nicht nutzen möchten…

- Lokale Installation:
  - Anaconda (oder Miniconda), https://www.anaconda.com/products/individual
    - Enthält Python und viele Standard Bibliotheken
    - Jupyter Notebook oder Jupyter Lab
    - Pandas, Scikit-learn, Matplotlib
    - TensorFlow

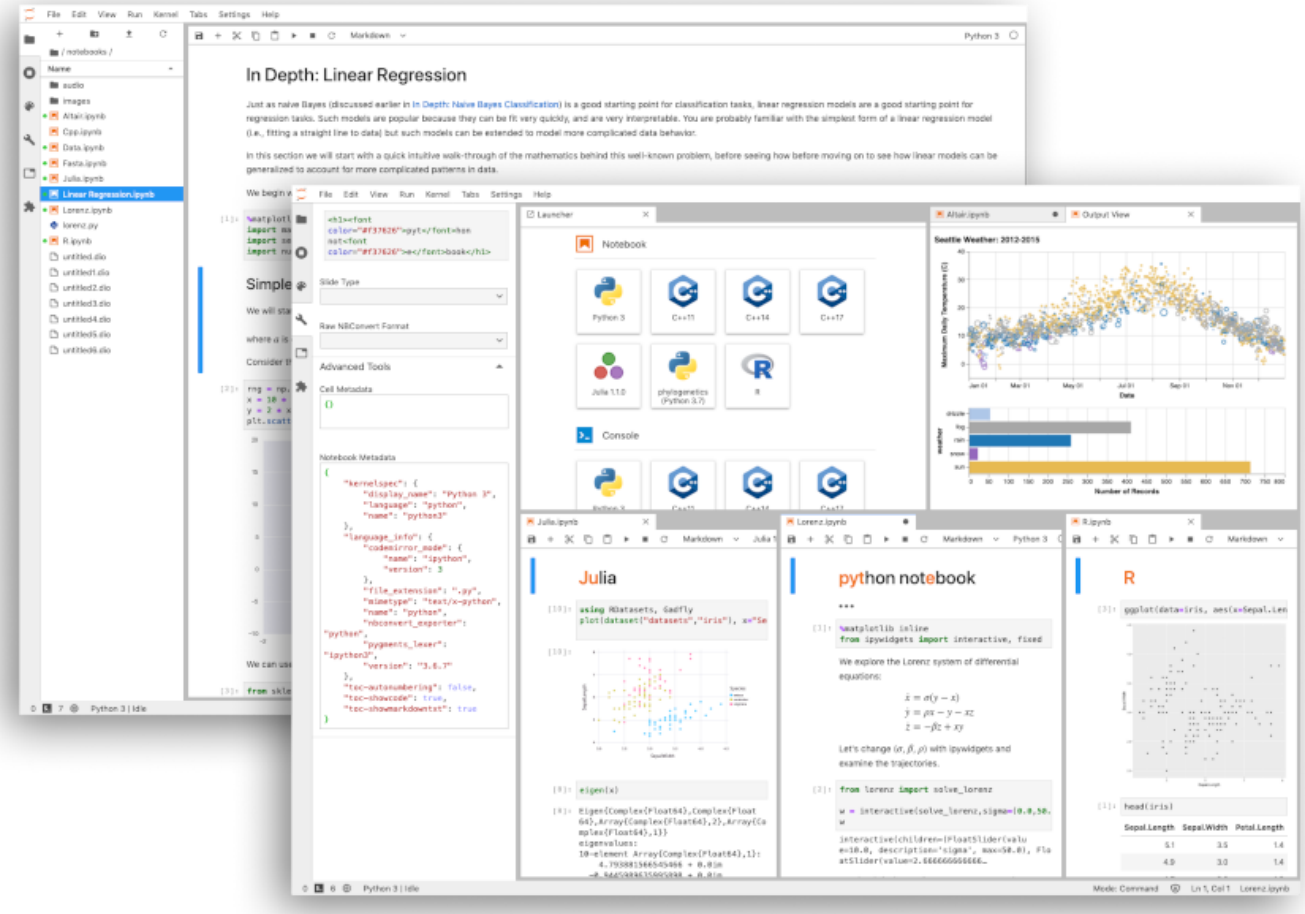


Quelle: jupyter.org

Falls Sie Google Colab nicht nutzen möchten…

- Lokale Installation:
  - Anaconda (oder Miniconda), https://www.anaconda.com/products/individual
    - Enthält Python und viele Standard Bibliotheken
    - Jupyter Notebook oder Jupyter Lab
    - Pandas, Scikit-learn, Matplotlib
    - TensorFlow

- Empfohlen: Cloud Umgebung:
  - Google Colab



Quelle: jupyter.org

Nächste Vorlesung und Fragen

- Bias und Fairness
- Fragen?

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln